


제 1 장 국내외 인공지능 반도체 시장 현황 및 전망

제 1 절 국내외 반도체 시장 현황

1. 전세계 반도체 시장 현황 및 전망

- 2023년 글로벌 반도체 시장은 수요부진으로 전년 대비 11.1% 축소된 5,330억 달러 규모로 추정되며, 2023년부터 2027년까지 연평균 9.4% 성장률을 기록하여 2027년에는 7,646억 달러에 이를 것으로 전망됨
- － 분야별로 비메모리 반도체는 2022년 5.5%에서 2023년 -3.0% 마이너스 성장 전환하고, 메모리반도체는 2022년 -13.7%에 이어 2023년 -37.0%로 부진 심화
- － 이에 따라, 글로벌 반도체 시장에서 메모리가 차지하는 비중은 2022년 23.9%에서 2023년 16.9%로 7.0%p 하락할 것으로 추정됨

[그림 1-1] 글로벌 반도체 시장규모 현황 및 전망(2022년~2027년)




주: 매출 기준임

자료: Gartner(2023. 12a)

— 그러나 AI 서비스 확산에 따른 수요 증가로 2023년부터 2027년까지 비메모리 반도체 및 메모리 반도체 각각 연평균 7.0%, 19.7% 성장하여 메모리가 차지하는 비중은 2027년 24.2%로 회복할 것으로 기대됨


[그림 1-2] 글로벌 메모리 및 비메모리 반도체 시장 현황 및 전망(2022년~2027년)



주: 매출 기준임

자료: Gartner(2023. 12a)

[그림 1-3] 글로벌 메모리 및 비메모리 반도체 시장 점유율 현황 및 전망(2022년~2027년)




주: 매출 기준임

자료: Gartner(2023. 12a)

- 품목별로는 매출액 기준 2022년 가장 큰 규모를 형성한 DRAM, 마이크로프로세서, 플래시메모리(NAND)는 2023년 두 자릿수 마이너스 성장한 반면, GPU는 60% 가까운 성장률 기록
 - DRAM과 플래시메모리는 2023년 반도체 품목 중 가장 크게 전년 대비 각각 -38.5%, -37.5%씩 하락하면서 전체 반도체 시장에서 차지하는 비중도 2022년 대비 2023년 각각 DRAM은 13.1%에서 9.1%로, 플래시메모리는 9.7%에서 6.8%로 하락한 것으로 추정됨
 - 반면, GPU는 2023년 품목 중 가장 높은 성장률(58.1%)로 전체 반도체에서 차지하는 비중은 2022년 2.5%에서 2023년 4.4%로 확대된 것으로 예상되며, 2022년부터 2027년까지도 전체 반도체 품목 중 가장 높은 15.0%의 연평균 성장률 기록할 것으로 전망됨

[그림 1-4] 반도체 품목별 시장규모(2022년 및 전망, 2022년~2027년)



주: 버블의 크기는 2022년 매출액 기준임

자료: Gartner(2024. 1a)

- 수요처 별로는 자동차 분야가 2022년에 이어 2023년에도 두 자릿수의 성장률을 기록한 반면, 각각 1/3을 차지하는 통신기기와 컴퓨팅기기 분야는 두 자릿수 하락 추정
 - 자동차용 반도체 분야의 2023년부터 2027년까지 연평균 성장률은 11.4%로 수요처 중 가장 높으며, 통신 및 컴퓨팅 기기도 9.3%의 성장률로 반도체 수요를 이끌 것으로 전망됨

- 수요처별 비중의 경우, 통신기기와 컴퓨팅 기기 분야의 점유율이 유지되는 가운데 자동차 분야 비중이 2022년 11.3%에서 2027년 16.0%로 4.7%p 증가하며 수요처 중 확대폭이 가장 클 것으로 예상됨


〈표 1-1〉 수요 분야별 글로벌 반도체 시장 현황 및 전망(2022년~2027년)
(단위: 백만 달러, 전년동기 대비 성장률)

		2022년	2023년	2024년	2025년	2026년	2027년	2023~ 2027년 CAGR
자동차 (Automotive Electronics)	매출규모	67,530	79,287	89,571	104,583	114,900	122,173	11.4%
	성장률	23.8%	17.4%	13.0%	16.8%	9.9%	6.3%	
통신기기 (Communication Electronics)	매출규모	192,841	155,578	189,638	213,230	225,946	221,863	9.3%
	성장률	0.9%	-19.3%	21.9%	12.4%	6.0%	-1.8%	
소비자기기 (Consumer Electronics)	매출규모	66,739	59,512	68,298	73,282	75,230	75,602	6.2%
	성장률	-1.0%	-10.8%	14.8%	7.3%	2.7%	0.5%	
컴퓨팅기기 (Data Processing Electronics)	매출규모	198,764	164,652	198,560	233,892	249,726	235,357	9.3%
	성장률	-9.4%	-17.2%	20.6%	17.8%	6.8%	-5.8%	
산업, 국방/항공 (Industrial and Military/ CivilAerospace Electronics)	매출규모	73,688	73,996	83,859	93,055	102,126	109,559	10.3%
	성장률	11.7%	0.4%	13.3%	11.0%	9.7%	7.3%	
총 합계	매출규모	599,562	533,025	629,927	718,042	767,928	764,554	9.4%
	성장률	0.2%	-11.1%	18.2%	14.0%	6.9%	-0.4%	

주: 매출 기준임

자료: Gartner(2023. 12a)

[그림 1-5] 수요 어플리케이션별 글로벌 반도체 시장점유율 현황 및 전망



주: 매출 기준임

자료: Gartner(2023. 12a)

- 글로벌 반도체 기업별로는 2023년 메모리 반도체 시장의 부진으로 삼성전자와 SK하이닉스의 순위가 하락한 가운데 GPU의 수요 확대로 NVIDIA의 순위는 2022년 12위에서 5위로 대폭 상승한 것으로 추정
 - － 삼성전자와 하이닉스는 2023년 글로벌 상위 10개 기업 중 가장 높은 30%대의 마이너스 매출 하락을 기록하여 삼성전자는 2022년 1위에서 2023년 2위로 한단계 하락하고 동기간 SK하이닉스는 4위에서 6위로 두단계 하락
 - － NVIDIA는 2023년 전년 대비 매출액이 56.4% 증가하고 점유율은 4.5%를 기록하며 4.3%의 SK하이닉스 추월

〈표 1-2〉 전세계 반도체 기업의 시장 점유율(2022년~2023년)

2022 Rank	2023 Rank	Vendor	2022 Revenue (Billions of Dollars)	2023 Revenue (Billions of Dollars)	2022-2023 Growth	2023 Market Share
2	1	Intel	58.436	48.664	-16.7%	9.1%
1	2	Samsung Electronics	63.823	39.905	-37.5%	7.5%
3	3	Qualcomm	34.780	29.015	-16.6%	5.4%
6	4	Broadcom	23.868	25.585	7.2%	4.8%
12	5	NVIDIA	15.331	23.983	56.4%	4.5%
4	6	SK hynix	33.505	22,756	-32.1%	4.3%
7	7	AMD	23.620	22.305	-5.6%	4.2%
11	8	STMicroelectronics	15.842	17.057	7.7%	3.2%
9	9	Apple	18.099	17.050	-5.8%	3.2%
8	10	Texas Instruments	18.844	16.537	-12.2%	3.1%

주: 2023년 매출액은 추정치


자료: Gartner(2023. 12b)

2. 전세계 파운드리 현황 및 전망

- 2023년 전세계 반도체 파운드리 시장은 반도체 시장 부진으로 전년 대비 10.8% 감소한 1,164억 달러 규모로 동기간 11.1% 축소된 반도체시장¹⁾ 보다 소폭 낮은 하락률을 기록할 것으로 추정

- 2023년부터 2027년까지 글로벌 파운드리 시장은 연평균 9.8% 증가할 것으로 전망되며, 이는 전체 반도체시장 성장률 9.4%를 소폭 상회하는 수준임

[그림 1-6] 글로벌 파운드리 시장규모 현황 및 전망(2022년~2027년)




주: 매출 기준임

자료: Gartner(2024. 1b)

- 수요 어플리케이션의 경우, 클라우드의 고성능 컴퓨팅 분야가 지난 10년간 수요를 견인한 PC와 스마트폰 분야를 상회하며 시장 성장을 이끌어 갈 것으로 전망
- 2023년 컴퓨팅기기 분야는 전년 대비 성장률은 -7.3%로 통신 및 소비자기기 분야의 각각 -11.5%, -15.3% 보다 낮은 하락률을 기록할 것으로 추정
- 2023년부터 2027년까지 연평균 성장률은 컴퓨팅기기(11.9%)가 소비자기기(7.9%)와 통신기기(7.4%)를 상회할 것으로 예상


1) 파운드리 분야가 제외된 규모임

[그림 1-7] 글로벌 파운드리 수요처별
성장률 추이 및 전망(2022년-2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)


[그림 1-8] 글로벌 파운드리 수요처별 비중
추이 및 전망(2022년-2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)


- 2023년 고객 기준으로는 IDM 분야 매출액이 8.6% 증가했으나, 시장의 2/3을 차지하는 팹리스업체 수요가 전년 대비 14.0% 축소되며 부진 주도

[그림 1-9] 글로벌 파운드리 고객별 성장
률 추이 및 전망(2022년-2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)


[그림 1-10] 글로벌 파운드리 고객별 비중
추이 및 전망(2022년-2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)


- 지역별로는 미국 제재로 자체 생산에 주력한 중국이 2023년 가장 낮은 마이너스 성장률을 기록하며 점유율을 확대한 것으로 추정
- 대만과 우리나라의 시장점유율이 유지되는 가운데 중국은 2023년부터 2027년까지 주요 지역 중 가장 높은 연평균 14.6%의 성장률을 기록하여 점유율은 2022년 11.8%에서 14.0%로 확대될 전망

[그림 1-11] 글로벌 파운드리 지역별 성장률 추이 및 전망 (2022년~2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)

[그림 1-12] 글로벌 파운드리 지역별 비중 추이 및 전망(2022년~2027년)



주: 매출 기준임
자료: Gartner(20241b)

- 업체별 파운드리 매출액 기준, 2022년 글로벌 상위 5개업체 모두 두자릿수 성장률을 기록하였으며 TSMC가 약 60%의 점유율과 가장 높은 증가율로 시장을 선도하는 가운데 나머지 상위 4개 업체는 한 자릿수 점유율로 경쟁열위 구도 지속

〈표 1－3〉 글로벌 상위 5개 파운드리업체 매출액 및 점유율(2021년~2022년)


(단위: 백만 달러)

2021년 순위	2022년 순위	업체명	2021년	2022년	성장률
1	1	TSMC	56,674	75,798	33.7%
2	2	삼성전자	8,537	10,291	20.5%
3	3	UMC	7,606	9,356	23.0%
4	4	GlobalFoundries	6,585	8,108	23.1%
5	5	SMIC	5,443	7,273	33.6%

주: 삼성전자는 내부 거래 제외 규모임

자료: Gartner(2023. 4)

〔그림 1－13〕 글로벌 파운드리업체 점유율 추이(2021년~2022년)



주: 삼성전자는 내부 거래 매출 제외 규모임

자료: Gartner(2023. 4)

제2 절 국내외 인공지능 반도체 시장 현황 및 전망

1. 인공지능 반도체 개념²⁾

- AI에 사용되는 DNN과 관련된 알고리즘 및 프로그래밍 모델을 실행하도록 특별히 설계된 장치와 관련된 반도체로 GPU, FPGA, ASIC(NPU), CPU 등이 있음
- － (GPU) 그래픽 처리 장치인 GPU(Graphic Processing Unit)는 그래픽 연산을 빠르게 처리하여 결과값을 모니터에 출력하는 연산장치로 VPU(Visual Processing Unit)이라고도 불림
- GPU는 병렬성이 우수하고 초당 처리할 수 있는 명령어의 수가 많다는 점에서 인공지능 알고리즘 구현 시 높은 성능을 보임
- 계산 효율이 높지만, 내부 메모리 용량이 CPU에 비해 높지 않아 내부 메모리 용량을 초과하는 양의 연산이 이루어져야 할 때 외부 메모리에 접근하는데 드는 시간이 많이 소요되어 효율이 급격하게 감소할 수 있음
- 최근까지도 인공지능 학습 구현을 위한 하드웨어로 GPU가 가장 많이 활용되고 있음
- NVIDIA가 가장 높은 GPU 시장점유율을 기록하고 있으며, Intel, ARM, AMD 등 전통적인 CPU 주력 기업들도 자사의 GPU를 개발하여 CPU-GPU 및 관련 소프트웨어가 모두 통합된 제품군을 제공하고 있음
- － (FPGA) FPGA(Field Programmable Gate Array)는 설계 가능 논리소자와 프로그래밍이 가능한 내부 회로가 포함된 반도체 소자
- 재설계가 가능하여 한 번 디자인한 후에도 수정을 거쳐 재설계할 수 있어 프로토타입 제작용이나 ASIC 설계 테스트용으로 사용될 수 있다는 장점이 있음
- 인공지능 모델은 application마다 구조가 달라 각각의 최적화된 하드웨어 구조 역시 다르다는 사실을 고려한다면 FPGA가 다양한 인공지능 모델에 적합한 하드웨어일 수 있음
- 높은 단위 시간당 처리량과 낮은 latency, 제작에 소요되는 시간과 비용이 낮고 전력효율이 높아 많은 기업에서 꾸준히 개발을 진행하고 있음


2) 윤성욱 외(2021)

- 대표적인 기업으로는 Xilinx, Intel, Microsoft가 있음
- (ASIC) 특정 용도용 집적회로인 ASIC(Application-Specific Integrated Circuit)는 범용 용도가 아닌 특정 용도에 맞게 맞춤 제작된 반도체로 이때 application을 인공지능으로 두어 설계된 회로를 일반적으로 NPU(Neural Processing Unit)로 지칭함
- 인공지능 구현에 많이 활용되는 GPU의 원래 목적이 인공지능 관련 연산 수행이 아니었기 때문에 면적, 전력효율, 수행 시간 면에서 인공지능 구현에 최적화가 되어있지 않음
- 이를 해결하기 위해 제작에 많은 시간과 비용이 소요됨에도 불구하고 글로벌 IT 기업을 포함한 많은 기업이 인공지능용 ASIC인 NPU 개발에 힘쓰고 있음
- 대표적인 NPU 개발 기업으로는 Google, Tesla, Amazon, GraphCore, ARM, Intel, Habana Labs(Intel), Cerebras 등이 있음
- (CPU) 중앙 처리 장치인 CPU(Central Processing Unit)은 범용 컴퓨팅 시스템을 통제하고, 프로그램의 연산을 실행·처리하는 가장 핵심적인 컴퓨터의 제어장치
- CPU는 GPU보다 코어당 성능은 우수하지만 병렬처리의 한계가 존재한다는 이유로 인공지능 반도체로 분류하지 않는 경우도 존재
- 하지만 가격이 저렴하고, 내부 메모리 용량이 높고, 모든 device에 포함되어 있으므로 접근성이 높다는 점에서 인공지능 알고리즘을 구동할 하드웨어에서 주요한 역할을 수행
- 대표적 CPU 설계 기업인 Intel, ARM, AMD는 각 사의 주력 제품인 CPU의 성능을 지속적으로 개선하여 deep learning 구동용 solution을 개발

2. 전세계 인공지능 반도체 시장 현황 및 전망

- 2023년 글로벌 인공지능 반도체 시장은 전체 반도체시장 부진에도 불구하고 생성형 AI로 촉발된 AI서비스 확산으로 전년 대비 23.3% 증가한 약 523억 달러로 추정되며, 2023년부터 2027년까지 연평균 27.9%의 고성장을 지속할 것으로 전망
- 이에 따라 전체 반도체시장에서 인공지능 반도체시장이 차지하는 비중은 2022년 7.1%에서 2023년 9.8%로 증가한 것으로 추정되며, 2027년에는 2023년의 약 두배인 18.3%까지 확대될 것으로 전망


[그림 1-14] 글로벌 AI 반도체 시장 현황 및 전망(2022년~2027년)



주: 매출 기준임

자료: Gartner(2023. 12c)

[그림 1-15] 글로벌 AI 반도체 시장이 글로벌 반도체 시장에서 차지하는 비중 추이 및 전망(2022년~2027년)



주: 매출 기준임

자료: Gartner(2023. 12c)

- 수요 어플리케이션별 글로벌 인공지능 반도체 시장을 살펴보면 2022년 기준 60% 넘는 점유율로 수요를 이끌던 통신기기를 컴퓨팅기기 분야가 빠르게 대체하여 2027년 전

체 시장의 50%를 상회할 것으로 전망

- 2023년 전년 대비 통신기기만 -9.3% 마이너스 성장하고 저장기기(143.5%), 산업기기(126.2%), 소비자기기(95.1%), 컴퓨팅기기(90.5%), 자동차(40.5%) 순으로 높은 성장률을 기록할 것으로 추정
- 2023년부터 2027년까지 통신기기와 컴퓨팅기기는 각각 연평균 10.7%, 39.9% 성장하며 전체 AI시장에서 차지하는 비중은 각각 2022년 63.3%, 24.3%에서 2027년 26.2%, 53.9%로 전환될 것으로 전망


〈표 1-4〉 수요 분야별 AI 반도체 시장 현황 및 전망(2022년~2027년)

(단위: 백만 달러)

분야		2022년	2023년	2024년	2025년	2026년	2027년	2023년~ 2027년 CAGR
자동차 (Automotive Electronics)	매출규모	3,921	5,507	7,594	10,370	12,740	14,626	27.7%
	성장률	38.0%	40.5%	37.9%	36.5%	22.9%	14.8%	
통신기기 (Communications Electronics)	매출규모	26,890	24,391	28,293	31,239	33,648	36,658	10.7%
	성장률	24.0%	-9.3%	16.0%	10.4%	7.7%	8.9%	
컴퓨팅기기 (Compute Electronics)	매출규모	10,320	19,657	27,294	38,374	56,119	75,320	39.9%
	성장률	32.8%	90.5%	38.9%	40.6%	46.2%	34.2%	
소비자기기 (Consumer Electronics)	매출규모	700	1,366	1,946	2,782	4,183	6,633	48.4%
	성장률	159.8%	95.1%	42.5%	42.9%	50.4%	58.6%	
산업 기기 (Industrial Electronics)	매출규모	603	1,365	2,209	3,482	5,012	6,286	46.5%
	성장률	152.9%	126.2%	61.9%	57.6%	43.9%	25.4%	
저장 기기 (Storage Electronics)	매출규모	16	39	80	122	191	302	67.2%
	성장률	140.7%	143.5%	108.0%	51.5%	56.9%	57.9%	
전체	매출규모	42,451	52,325	67,418	86,369	111,894	139,825	27.9%

자료: Gartner(2023. 12c)

[그림 1-16] 글로벌 AI 반도체 시장의 수요처별 비중 추이 및 전망(2022년~2027년)



자료: Gartner(2023. 12c)

- 품목별로는 2022년 기준 개별 애플리케이션/멀티미디어 프로세서(Discrete Application/Multimedia Processor)와 통합 베이스밴드/멀티미디어 프로세서(Integrated Baseband/Application Processor)가 AI반도체 시장을 양분하고 있었으나, 향후 마이크로프로세서(컴퓨팅)(Microprocessor, Compute)가 높은 수요로 시장을 견인할 것으로 예상
 - － 마이크로프로세서(컴퓨팅)는 2023년부터 2027년까지 연평균 166.8% 증가하여 전체 AI반도체 시장에서 차지하는 비중은 2022년 0.9%에서 2027년 28.9%로 대폭 확대
 - － 이는 2027년 개별 애플리케이션/멀티미디어 프로세서의 점유율(27.7%)을 추월한 것으로 품목 중 가장 큰 비중임

〈표 1－5〉 AI 반도체 종류별 시장 현황 및 전망(2022년~2027년)


(단위: 백만 달러, %)

분야		2022년	2023년	2024년	2025년	2026년	2027년	2023년~ 2027년 CAGR
Digital Signal Processor	매출규모	35	73	104	163	235	370	50.0%
	성장률	137.5%	107.8%	41.9%	56.7%	44.5%	57.6%	
Discrete Application/ Multimedia Processor	매출규모	17,602	19,886	23,612	29,017	34,303	38,771	18.2%
	성장률	20.2%	13.0%	18.7%	22.9%	18.2%	13.0%	
Discrete Graphics Processing Unit	매출규모	5,546	13,689	16,363	18,558	20,369	22,676	13.4%
	성장률	15.8%	146.8%	19.5%	13.4%	9.8%	11.3%	
FPGA	매출규모	404	764	1,236	1,688	2,233	2,630	36.2%
	성장률	105.8%	89.0%	61.7%	36.5%	32.3%	17.7%	
Integrated Baseband/Application Processor	매출규모	17,352	14,431	17,252	18,779	20,312	22,093	11.2%
	성장률	40.3%	-16.8%	19.5%	8.8%	8.2%	8.8%	
Microcontroller 32-bit	매출규모	105	210	278	464	708	894	43.7%
	성장률	135.4%	99.1%	32.4%	67.2%	52.5%	26.2%	
Microprocessor - Compute	매출규모	97	798	4,469	11,678	25,331	40,429	166.8%
	성장률	13,346.3%	726.3%	459.9%	161.3%	116.9%	59.6%	
Microprocessor - Embedded	매출규모	196	313	497	729	1,005	1,324	43.5%
	성장률	110.6%	59.9%	58.9%	46.7%	37.8%	31.8%	
기타	매출규모	1,113	2,162	3,607	5,293	7,397	10,639	48.9%
	성장률	69.8%	94.2%	66.9%	46.7%	39.8%	43.8%	

주: 매출 기준임

자료: Gartner(2023. 12c)

[그림 1-17] 글로벌 AI 반도체 시장의 품목별 비중 추이 및 전망(2022년 ~2027년)



주: 매출 기준임

자료: Gartner(2023. 12c)


제2장 AI 반도체 선도기업 기술 동향 및 혁신전략

제1절 인공지능 반도체 기술 개요

- 인공지능 알고리즘을 구동할 수 있는 프로세싱 유닛의 타입은 CPU, GPU, APU, FPGA, ASIC으로 구분할 수 있음
- CPU(중앙 처리 장치)
 - CPU는 GPU보다 코어당 성능은 우수하지만 병렬 처리의 한계성이 존재한다는 이유로 인공지능 반도체로서의 중요성이 두드러지지 않는 면이 있음
 - 하지만, 가격이 저렴하다는 점과 내부 메모리 용량이 높다는 점(수백 기가바이트), 그리고 모든 device에 포함되어 있으므로 접근성이 높다는 점에서 인공지능 알고리즘을 구동할 HW에서 빼놓을 수 없는 주요한 항목
 - 제한된 연산만을 지원하는 다른 가속기 프로세서와 비교하면 다양하고 복잡한 연산이 가능하다는 점에서 높은 활용성을 보임
 - 대표적 CPU 설계 기업인 Intel, ARM, AMD는 각 사의 주력 제품인 CPU의 성능을 지속해서 개선하여 딥러닝 워크로드 구동용 solution을 개발
- GPU(그래픽 처리 장치)
 - GPU는 병렬성이 우수하고 초당 처리할 수 있는 명령어의 수가 더 많다는 점에서 인공지능 알고리즘 구현에 있어 높은 성능을 보여온 반도체
 - 특히 인공지능 학습 구현은 최근까지도 GPU의 활용이 가장 높은 비율로 이루어지고 있음
 - 계산 효율이 높지만, 내부 메모리 용량이 CPU에 비해 높지 않아(수십 기가바이트) 내부 메모리 용량을 초과하는 양의 연산이 이루어져야 할 때 외부 메모리에 접근하는데 드는 시간이 많이 소요되어 효율이 급격하게 감소할 수 있음

- NVIDIA가 가장 높은 GPU 시장 비율을 차지하지만, Intel, ARM, AMD 등 전통적인 CPU 주력 기업들도 자사의 GPU를 개발하여 CPU-GPU 및 관련 SW가 모두 통합된 제품군을 제공하고 있음

[그림 2-1] NVIDIA vs AMD vs Intel의 데이터 센터 구축 수익 비교




자료: Visualcapitalist(2023. 8. 25.),

□ APU(가속 처리 장치)

- Accelerated processing unit(APU)는 CPU와 GPU, 그리고 메모리 컨트롤러를 단일 컴퓨터 칩에 집적하여 연산을 가속하는 마이크로프로세서 타입
- AMD의 fusion project에서 처음으로 시도된 프로세싱 유닛 타입이며 AMD의 첫 APU는 2011년 1월에 출시(Denis et al., 2011)
- 같은 해 Intel도 Sandy Bridge라는 코드네임으로 APU를 런칭하였으며 NVIDIA는 Project Denver라는 코드네임으로 자사의 APU를 런칭
- 두 프로세싱 유닛이 하나의 칩에 집적되면서 리소스를 공유할 수 있게 되고, 그 때문에 데이터 전송 속도가 빠르고 전력 소모가 낮다는 장점이 있음
- 하지만, 두 프로세싱 유닛을 하나의 칩에 집적하므로 설계 및 집적이 매우 복잡하다는 어려움이 있으며 두 유닛이 일반적으로 공통의 메모리에 접근하므로 메모리 대역폭의 제한이 있다는 특징이 있음
- 위의 설계적 어려움을 해결하기 위하여 칩렛 기반의 첨단 이중 집적 기술을 이용하며 제작하는 경향이 있으며, 메모리 대역폭을 늘리기 위하여 HBM을 적재하는 연구 움직임이 존재

[그림 2-2] 전 세계 APU 시장 매출규모



자료: Statista(2024)

□ FPGA(필드 프로그래머블 게이트 어레이)

- FPGA는 디자인을 reprogram 가능하여 한 번 디자인한 후에도 수정을 거쳐 재설계할 수 있어 프로토타입 제작용이나 ASIC 설계 테스트용으로 사용하기에 장점이 있음
- 인공지능 모델은 application마다 구조가 달라 각각의 최적화된 하드웨어 구조 역시 다르다는 사실을 고려한다면 FPGA가 다양한 인공지능 모델에 적합한 하드웨어를 설계해볼 수 있다는 장점이 있음
- FPGA는 일반적으로 높은 단위 시간당 처리량과 낮은 latency뿐만 아니라 제작에 드는 가격과 시간이 짧고 power 효율이 높아 다양한 기업에서 꾸준히 개발을 진행하고 있음
- 2015년 Intel은 FPGA 세계 2위 기업인 Altera를 인수하였고, 2020년 10월 AMD는 FPGA 세계 1위 기업인 Xilinx 인수에 착수한 후 2022년 2월 500억 달러 규모의 Xilinx를 인수


□ ASIC(특정 용도용 집적 회로)

- ASIC은 용도에 특화된 회로를 의미하는 것으로, 이때 application을 인공지능으로 두어 설계된 회로를 일반적으로 NPU로 지칭함
- GPU의 원래 목적이 인공지능 관련 연산 수행이 아니었기 때문에 면적, 전력, 수행 시간 면에서 최적화되지 않은 여러 문제를 가짐
- 이를 해결하기 위하여 높은 제작 비용 및 시간에도 불구하고 대기업과 스타트업을 포함한 많은 기업이 인공지능용 ASIC인 NPU 개발에 힘쓰고 있음
- 대표적인 NPU 개발 기업으로는 Google, Tesla, Amazon, ARM, Intel, Habana Labs(Intel)와 같은 대기업과 SambaNova Systems, Cerebras Systems, Graphcore, Groq, Tenstorrent와 같은 신생 기업들이 있음

제2절 AI 반도체 선도기업 기술 동향

- 최근 ChatGPT와 같은 거대언어모델이 활발하게 개발되고 다양한 분야에서의 활용을 보임에 따라 인공지능 반도체의 개발 방향도 이와 같은 거대모델을 처리하기 위한 방향으로 설정되고 있음(Zhao et al., 2023)

[그림 2-3] 최근 개발된 10B 이상 크기의 대규모 언어모델(음영: 코드공개)



자료: Zhao et al.,(2023), A survey of large language models. arXiv preprint arXiv:2023.18223.

- 주로 Intel, AMD, NVIDIA과 같은 인공지능 반도체 대기업은 클라우드 서버형 컴퓨팅 유닛을 중심으로 활발하게 개발하고 있으며, Tenstorrent, Hailo, DeepX와 같은 스타트업 기업들이 엣지 기기 전용 가속기를 개발
- 클라우드 서버형 컴퓨팅 유닛은 거대 모델의 추론 및 학습, 그리고 필요할 시 엣지 디바이스와의 통신을 통한 데이터 전송 등을 담당하며, 엣지 컴퓨팅은 경량화된 거대 모델 혹은 기존의 딥러닝 모델의 추론을 제한된 디바이스의 컴퓨팅 자원을 이용하여 수행하는 역할을 담당

- 본 절에서는 인공지능 반도체의 프로세싱 유닛 타입에 따른 분류와 함께 선도기업 및 해당 기업의 팔목할 만한 기술 동향을 조사
- <표 2-1>에서는 프로세싱 유닛 타입을 CPU, GPU, APU, FPGA, ASIC으로 나누고, 타입 별 글로벌 인공지능 반도체 선도기업 및 해당 기업의 최신 인공지능용 하드웨어 제품명과 각 제품군의 사용 목적에 관해 기술

<표 2-1> 프로세싱 유닛 타입에 따른 인공지능 반도체 선도기업과 대표 제품

프로세싱 유닛 타입	기업	제품명
CPU	Intel	Xeon Scalable Processors
		Max Series Processors
	AMD	Ryzen 7040
	ARM	Cortex-X4
GPU	NVIDIA	H100
	AMD	Instinct MI300X
	ARM	G720
APU (CPU+GPU)	NVIDIA	GH200
	AMD	Instinct MI300A
FPGA	AMD-Xilinx	Alveo
	SambaNova	Reconfigurable Dataflow Unit(RDU)
	Intel	Intel Agilex
	Google	TPU v5e
ASIC (NPU)	Intel-Habana Labs	Gaudi3
	Cerebras	WSE-2
	GraphCore	Bow IPU
	Groq	GroqChip
	Tenstorrent	Grayskull
	IBM	NorthPole
	Kneron	KL730
	DeepX	DX-M1
	Hailo	Hailo-15


자료: 저자정리

1. 중앙 처리 장치(CPU, Central Processing Unit)

□ Intel

- 인텔은 인공지능 워크로드 수행을 위해 가속기를 내장한 Intel Xeon Scalable Processor 라인과 Intel Xeon Max Series Processor를 출시해오고 있음
- Intel Xeon Scalable Processor는 cloud용 AI 연산 처리에 최적화된 하드웨어를 제공함과 동시에, 유연한 성능 달성을 목표
 - 유연한 성능 달성이란, 다양한 core 개수, 동작 frequency, power level을 제공함으로써 클라우드, 슈퍼컴퓨터뿐만 아니라 IoT 등 에지 기기에도 이용될 수 있도록 하는 것을 의미
- 4세대 Xeon Scalable Processor
 - 2023년 1월 인텔 7공정을 사용한 4세대 Xeon Scalable Processor가 출시되었으며 당시 시장에 출시된 CPU 중 가장 많은 12개의 가속기 유닛을 내장(Intel, 2023)
 - 고성능 CPU이므로 AI 워크로드 및 데이터 분석에 활용될 수 있을 뿐만 아니라 HPC에도 활용될 수 있음
 - 최대 코어 수가 60개이며 DDR5 RDIMM 메모리를 탑재하고 PCIe를 5세대로 업그레이드 하여 장착
 - Intel Advanced Matrix Extensions(AMX)라는 인공지능에 특화된 instruction set architecture(ISA)를 개발 및 활용(Abirami et al., 2023)
 - 전 세대와 대비하여 목표 워크로드 처리에 평균 2.9배 높은 와트당 성능을 보였으며 전력 최적화 모드를 활용할 시 성능 손실 없이 최대 70W 낮은 전력으로 구동 가능

[그림 2-4] 4세대 Intel Xeon Scalable Processor




자료: Intel 웹페이지

○ Intel Xeon CPU Max Series

- 기계학습 혹은 다양한 분야에 활용될 수 있는 HPC용 프로세서
- 최초로 x86 기반 CPU에 패키지당 64GB HBM2E를 내장하여 메모리 대역폭을 최대화
- 최대 56개 코어를 포함하고 있어 코어당 1GB 이상의 HBM 용량을 활용할 수 있다는 장점
- 인텔이 자체적으로 개발한 차세대 패키징 기술인 embedded multi-die interconnect bridge(EMIB) 기술을 활용하여 CPU와 메모리를 한 패키지로 묶어 코어와 메모리 간 병목현상을 줄임(Mahajan et al., 2016)
- Xeon Scalable Processor와 마찬가지로 Intel의 AMX를 활용하였으며 AMD EPYC 7R13 2개와 비교하여 거대모델 BERT-Large를 추론할 때 최대 20배 빠른 처리 성능을 달성

[그림 2-5] HBM을 장착한 AI/HPC용 Intel CPU, Intel Max Series Processor



자료: Intel 웹페이지

□ AMD

○ Ryzen 7040 Series

- 2023년 1월 TSMC 4nm FinFET 공정으로 제조된 Ryzen 7040 Series를 공개하였으며 LPDDR5x를 탑재하고 PCIe 4.0을 지원(Subramon et al., 2023)
- 시리즈 중 일부 모델은 Ryzen AI인 AMD XDNA AI 엔진이 탑재
- XDNA AI 엔진은 edge와 클라우드까지 모두 활용 가능한 높은 configurability를 가지는 아키텍처
- 뿐만 아니라, XDNA AI 엔진은 2D AI 엔진 타일로 구성되어 있고, 디바이스 당 수십 혹은 수백 개의 AI 엔진 타일로 구성할 수 있어 높은 scalability를 가짐
- 각 AI 엔진 타일은 기계학습에 특화된 VLIW, SIMD vector processor로 구성되어 있으며 각 AI 엔진 프로세서는 1.3 GHz까지 구동 가능
- 각 엔진 타일은 프로그램 메모리와 데이터 메모리를 포함하고 있어 프로세서가 구동할 명령어와 연산 시 사용할 데이터를 모두 저장할 수 있음
- Ryzen 9 7940HS 칩을 탑재한 Asus Strix Scar 17 노트북을 플랫폼으로 시연하였을 때, Intel Core i9-13900H Raptor Lake보다 모든 벤치마크에 대하여 6%에서 41%의 성능 향상을 보임

- Apple M2 칩의 Neural Engine과 비교하였을 때는 모든 벤치마크에 대하여 1%에서 11%의 성능 향상을 보임

[그림 2-6] AMD의 XDNA AI 엔진 개념도



자료: AMD웹페이지

2. 그래픽 처리 장치(GPU, Graphics Processing Unit)

□ NVIDIA

- NVIDIA는 AI 반도체로서의 가장 높은 점유율과 입지를 다지고 있는 GPU 선도기업
- 세계적인 클라우드 컴퓨팅 환경 제공 업체인 Amazon의 AWS와 Microsoft의 Azure는 NVIDIA의 GPU를 활용하여 컴퓨팅 환경을 구성하였다고 알려져 있음


<표 2-2> Amazon AWS의 인스턴스별 GPU 환경

Amazon EC2 P3	8 NVIDIA Tesla V100 GPUs
Amazon EC2 P4	8 NVIDIA Tesla A100 GPUs.
Amazon EC2 G3	4 NVIDIA Tesla M60 GPUs.
Amazon EC2 G4	4 NVIDIA T4 GPUs.
Amazon EC2 G5	8 NVIDIA A10G GPUs.

자료: Amazon 웹페이지

- Google도 Next23에서 NVIDIA와 협력하여 H100을 탑재한 슈퍼컴퓨터 A3VMs를 출시한다고 밝힘
- H100
 - GTC 2022에서 Hopper 아키텍처를 사용한 H100 GPU를 공개(Elster et al., 2022)
 - H100 GPU 출시는 PCIe와 SXM5 두 개의 폼팩터를 제공
 - PCIe는 일반적인 PC의 마더보드 PCIe 슬롯에 장착하는 방법으로 탈부착 및 설치가 간단
 - SXM5는 특화된 하드웨어와 커넥터가 필요하지만 NVSwitch를 활용하여 더 높은 성능과 multi-node 설치 용도로 적합
 - H100 SXM은 세계 최초로 4.8Gbps HBM3를 채택하였으며 3TB/s의 메모리 대역폭을 달성
 - H100 PCIe는 3.2Gbps HBM2E를 장착하였으며 2TB/s의 메모리 대역폭을 달성
 - H100 SXM은 이전 세대인 A100SXM과 비교하여 2배가 넘는 CUDA core와 528개의 Tensor core를 탑재

[그림 2-7] NVIDIA H100



자료: NVIDIA 웹페이지


- H100은 800억 개에 달하는 트랜지스터를 포함하며 TSMC 4N technology node를 이용하여 생산
- 2023년 5월, 4세대 Xeon과 H100을 활용한 데이터센터용 슈퍼컴퓨터 DGX H100을 출시

□ AMD

○ Instinct MI300X

- AMD는 AMD DCAITP에서 AMD의 CDNA3 GPU 코어를 이용하여 설계된 인공지능 반도체인 Instinct MI300X를 공개(Alok, 2020)
- Instinct MI300X는 24GB HBM3 모듈 8개를 장착하여 총 192GB 메모리 용량과 5.2TB/s의 메모리 대역폭을 가지고 있음
- Instinct MI300X에 탑재되는 HBM3은 삼성전자와 SK하이닉스가 전량 공급할 것으로 예상
- AMD는 CPU 설계부터 적극적으로 활용하던 칩렛 기술을 MI300X에도 적용하여 TSMC 5nm급 공정에서 생산된 12개의 칩렛을 결합
- 칩렛 간 연결은 인피니티 패브릭을 사용하였으며 대역폭은 896GB/s를 달성
- H100보다 2.4배 높은 메모리 밀도와 1.6배 높은 대역폭을 제공하며 마이크로소프트, 오픈 AI, 오라클, 델, 시스코 등 10개사가 MI300X를 채택할 것으로 예정되어 있음
- 2024년 AMD의 AI 반도체 매출 전망은 20억 달러로 예상되었으며, 2023년 12월 AMD가 수주한 MI300 시리즈의 물량은 25~30억 달러 수준으로 전망
- 1,750억 개 파라미터를 가지는 GPT3도 5개의 MI300X를 이용하면 모든 파라미터를 저장할 수 있다는 점을 강조

[그림 2-8] AMD Instinct MI300X의 아키텍처 구조도



자료: ascii 웹페이지


3. 가속 처리 장치(APU, Accelerated Processing Unit)

□ AMD

- AMD는 CPU와 GPU를 결합한 APU의 첫 번째 세대를 Llano라는 이름으로 2011년에 출시
- 이후 2012년 2세대인 고성능 라인 Trinity와 저전력 라인 Brazos-2 출시를 시작으로 현재까지 꾸준히 APU 제품을 생산
- MI300A
 - － MI300X를 공개하기 약 반년 전 1월 CES 2023에서 AMD는 MI300A를 공개하였으며 MI300A는 MI300X의 8개의 GPU 칩셋 중 두 개를 세 개의 CPU 칩셋으로 바꾼 새로운 APU
 - － Zen4 CPU 코어 24개와 CDNA3 아키텍처 기반의 GPU, 그리고 128GB의 HBM3를 탑재
 - － TSMC 5nm를 이용하여 제작되었으며 1,460억 개의 트랜지스터를 탑재하고 있음
 - － MI300X와 마찬가지로 칩셋 기반의 디자인이므로 최첨단 패키징 기술이 요구되며

AMD는 3.5D 패키징으로 명명하고 substrate 위에 인터포저, I/O 칩렛, GPU 칩렛 (XCD) 및 CPU 칩렛(CCD)를 차례로 집적하여 패키징

[그림 2-9] AMD Instinct MI300A의 아키텍처 구조도




자료: ascii 웹페이지

□ NVIDIA

○ GH200

- 2023년 5월, ARM 기반 NVIDIA 그레이스 CPU와 호퍼 GPU 아키텍처를 결합하여 하나의 칩에 집적한 GH200 그레이스 호퍼 슈퍼칩의 정보를 공개
- CPU 메모리는 최대 480GB의 LPDDR5X이며 GPU는 7배 빠른 메모리인 HBM3 94GB 또는 8배 빠른 메모리인 HBM3E 144GB에 연결되어 있음
- NVIDIA의 NVLink 기술을 칩 간 상호 연결로 확장한 NVLink-C2C 인터커넥트 기술을 활용하면 256개의 GPU가 연결되어 단일의 GPU인 듯 기능하며 이를 이용하면 총 1엑사플롭스의 성능과 144테라바이트의 공유 메모리를 제공할 수 있음 (Ying et al., 2023)
- NVLink 기술은 최대 900GB/s의 총대역폭을 제공하며 이는 PCIe Gen5 레인보다 7배 높은 대역폭 성능

[그림 2-10] 그레이스 호퍼 슈퍼칩(GH200)의 구조도



자료: NVIDIA 웹페이지(NVIDIA Grace Hopper Superchip Data Sheet)

4. 필드 프로그래머블 게이트 어레이(FPGA, Field Programmable Gate Array)

□ Xilinx

○ Xilinx Alveo Family

- Xilinx는 다양한 application에 적용할 수 있는 data center 워크로드 용 가속기 카드인 Alveo를 출시해오고 있음
- Alveo 카드 라인업에 따라 개발할 인공지능 반도체의 사이즈를 결정하는 LUT 크기, HBM 탑재의 여부, memory 용량, 대역폭, 파워 등이 다양하므로 표적으로 하는 인공지능 애플리케이션 워크로드에 따라 적합한 카드를 선택하여 FPGA 개발을 수행할 수 있음

〈표 2-3〉 Xilinx Alveo Family 라인업

구분	Alveo U50	Alveo U55C	Alveo U200	Alveo U250	Alveo U280
LUTs	872k	1304k	892k	1341k	1079k
Dimensions	Single Slot Half Height	Single Slot Full Height	Dual Slot Full Height	Dual Slot Full Height	Dual Slot Full Height
Memory	8GB HBM2 316 GB/s	16GB HBM2 460 GB/s	64GB DDR 77GB/s	64GB DDR 77GB/s	8GB HBM2 460GB/s
Physical Interface	PCIe Gen3x16, Gen4x8, CCIX	PCIe Gen3x16, Gen4x8	PCIe Gen3x16	PCIe Gen3x16	PCIe Gen4x8 with CCIX
Power	<75W	<150W	<225W	<225W	<225W

자료: NVIDIA 웹페이지(NVIDIA Grace Hopper Superchip Data Sheet)

- 여러 카드를 PCIe로 서버에 설치하여 병렬 구동이 가능하므로 데이터센터 및 클라우드 컴퓨팅 애플리케이션에도 적합
- 인공지능 반도체 설계에 필수적인 하드웨어와 상호작용하는 소프트웨어인 runtime을 Xilinx Runtime(XRT) 라는 이름으로 제공
- XRT를 통하여 개발자들은 메모리를 할당하고 이동할 때 등 다수의 소프트웨어 기능을 함께 제공받을 수 있음
- FPGA 설계에 하드웨어 설계에 대한 높은 배경 지식을 요구하므로 Xilinx는 AMD Vivado 및 AMD Vitis라는 두 가지 개발 플랫폼을 제공함으로써 하드웨어 및 소프트웨어 개발을 용이하게 함
- Vivado는 전통적인 FPGA 개발자를 위해 design suite를 제공하며 Vitis는 설계자가 C, C++, OpenCL을 활용하여 하드웨어를 디자인할 수 있도록 소프트웨어 플랫폼을 제공

[그림 2-11] Xilinx Alveo U280




자료: AMD웹페이지

□ Sambanova

- Sambanova는 reconfigurable 로직을 활용한 고유의 아키텍처인 reconfigurable dataflow unit 아키텍처(RDA)를 활용하여 인공지능 반도체를 개발하는 스타트업 기업
- FPGA는 개발이 복잡하고 수준급의 low-level 프로그래밍을 필요로 하며 매우 긴 컴파일 타임을 소모한다는 단점이 있지만, RDA는 경량화된 프로그래밍을 통하여 configuration에 수십 마이크로초만을 소요
- Sambanova는 2023년 기준 AI chip maker 중 가장 많은 펀딩을 수주한 스타트업으로 꼽힘(Sambanova Systems, 2021)
- Sambanova는 2023년 2월 ChatGPT와 같은 Generative AI의 성공을 배경으로 삼아 “Sambanova suite for generative AI”라는 슬로건을 내세우며 차기 AI 칩 개발에 박차를 가함

[그림 2-12] 투자 수주액으로 나열한 상위 5개 AI Chip maker 및 Sambanova의 SL40L



자료: Reuters(2021. 11. 11.)

○ SN40L

- 2023년 9월 Sambanova는 5조 개의 파라미터를 저장할 수 있는 새로운 칩 SN40L을 발표
- SN40L은 TSMC 5나노 공정을 사용하여 제작되었으며 각 칩은 1,040개 코어를 가지고 있으며 1,020억 개 트랜지스터를 포함
- 메모리 중심 컴퓨팅인 거대언어모델을 처리하기 위하여 세 단계의 메모리 계층을 추가하여 차별화를 두었음
- 먼저 520MB의 온 칩 메모리가 탑재되었으며 1.5TB의 외부 메모리, 그리고 64GB의 HBM을 추가 탑재
- NVIDIA H100(80GB HBM)과 AMD MI300X(192GB HBM)보다는 적은 용량을 탑재하였지만 세 개의 메모리 층 사이에 발생하는 부하를 분할하여 처리하도록 하는 자체 소프트웨어 컴파일러를 개발

5. 특정 용도용 집적 회로(ASIC, Application-Specific Integrated Circuit)


□ Google

○ TPU v5e

- 2023년 8월, 구글은 TPU의 후속 버전인 Cloud TPU v5e를 발표


- 거대언어모델의 크기가 지난 5년 동안 매년 10배씩 증가하는 추세이므로 이에 대응하기 위한 방향으로 TPU 개발 방향이 설정
- TPU v4와 비교하여 학습 성능은 가격당 2배, 추론 성능은 가격당 2.5배를 달성
- TPU v5의 주요한 장점 중 하나는 인터커넥트로, 여러 TPU v5 칩을 연결하여 동작할 수 있는 scalability를 위하여 multislice 기술을 새롭게 개발
- 이전에는 한 슬라이스의 TPU만 사용하는 것으로 제한되어 최대 슬라이스 크기가 3,072개의 TPU v4칩으로 한정
- Multislice 기술을 이용하면 하나의 pod에 수만 개의 chip을 inter-chip interconnect (ICI)를 통하여 연결할 수 있게 되었으며 여러 개의 pod는 data center network(DCN)을 통하여 연결

[그림 2-13] Google TPU v5e AI 보드



자료: STH(2023. 11. 14)

[그림 2-14] Google의 multislice 기술도



자료: GoogleCloud(2023. 9. 1.)


□ Intel-Habana Labs

- 2019년 인텔은 인공지능 반도체 가속기 기업인 Habana Labs를 20억 달러에 인수하였으며 2022년에 Gaudi2를 출시하였으며 2023년 Gaudi3의 시제품을 공개하고 출시 예정임을 밝힘
- Gaudi2(Habana Labs, 2022)
 - 2022년 5월, 인텔은 TSMC 7nm 공정으로 제작되었으며 HBM2E 6개를 탑재한 Gaudi2를 발표
 - 경쟁사 제품인 NVIDIA의 H100보다 3배 이상의 가성비를 가지고 있고 제품 공급 측면에서도 NVIDIA 대비 빠른 공급이 가능하여 리드 타임(반도체 상품의 주문 일시와 인도 일시 사이의 경과 시간) 면에서 우수하다는 점을 강조
 - Gaudi2의 컴퓨팅 아키텍처는 프로그래머블한 tensor processor core(TPC)와 matrix multiplication engine(MME)로 구성되어 있음
 - TPC는 VLIW SIMD 프로세서로 MME에서 가속할 수 있는 operator들을 제외한 모든 operation를 가속하는 데 사용
 - MME에서 가속할 수 있는 operator는 matrix의 곱으로 lowering 가능한 모든 operator를 포함하며 fully connected layer, convolution, GEMM과 같은 연산자가

이에 속함

- DMA 엔진은 tensor shape을 변형하는 데 사용되며 transformation 엔진과 coupled 되어있음
- Gaudi2의 네트워킹 아키텍처는 24개의 100Gbps RoCE V2 RDMA NICs를 통해 2.4Tb/s의 네트워킹 대역폭을 달성하였으며 Gaudi2간의 커뮤니케이션은 direct routing 혹은 표준 이더넷 스위칭을 사용
- Gaudi2의 메모리 시스템은 6개의 HBM2E가 총 96GB의 메모리 용량을 제공하며 48MB의 로컬 SRAM이 함께 탑재되어 있음

[그림 2-15] Habana Labs의 Gaudi12 제품 사진 및 아키텍처



자료: habana(2022. 6)

○ Gaudi3

- 2023년 12월, 인텔은 TSMC 5nm 노드로 제작된 Gaudi3의 시제품을 공개하고 2024년 출시할 것임을 밝힘(Kif Leswing, 2023)
- Gaudi2 대비 BF16 자료형을 처리하는 데 처리 속도가 4배 향상되었으며 HBM 탑재 용량을 1.5배 늘려 거대언어모델 처리를 목표로 함
- HBM3 또는 HBM3E를 탑재할 것으로 예상되어 메모리 용량뿐만 아니라 메모리 대역폭 및 전송 속도의 향상을 기대할 수 있음

[그림 2-16] Gaudi2와 비교한 Gaudi3의 specification



자료: wccftech(2023. 12. 18)

□ GraphCore

○ Bow IPU

- 2022년 3월 GraphCore는 3세대 intelligent processing unit(IPU)인 Bow IPU를 출시
- Bow IPU는 이전 세대와 마찬가지로 1GB의 on-chip SRAM을 포함하지만 40% 빠른 access가 가능해져 65Tb/s 속도로 접근할 수 있음
- 또한, 이전 세대와 마찬가지로 1,472개의 IPU tile을 포함하고 있으며 각각 6개의 독립적인 프로그램 수행이 가능
- 각 IPU tile은 8,832개의 병렬적으로 수행 가능한 프로그램 스레드를 가진 IPU-Core와 900MB의 In-Processor-Memory를 포함하고 있음
- 10개의 IPU는 IPU-Link로 연결되어 320GB/s의 대역폭으로 chip 간 통신이 가능
- Bow IPU는 mixed-precision 연산에 대해 peak 350TFLOPS를 달성하였으며 FP32 연산에 대해서는 peak 87.5TFlops를 달성
- Bow IPU는 4개가 패키징 되어 Bow-2000 IPU 머신을 구성하며 Bow-2000은 4개가 패키징 되어 Bow Pod16을 구성하고, Bow Pod16은 256개가 패키징 되어 Bow Pod1024를 구성

- Bow-2000은 FP32 연산 기준 peak 350TFLOPS, Bow Pod16은 peak 1.4PFLOPS, 그리고 Bow Pod1024는 peak 89.6 PFLOPS를 달성


[그림 2-17] GraphCore의 Bow IPU(좌측) 및 Bow-2000(우측)



자료: GraphCore웹페이지

- GraphCore의 Bow IPU에서 주목할 점은, TSMC 7nm 공정으로 제작되었으며 TSMC의 3D wafer-on-wafer(WoW) 패키징 기술을 활용하였다는 점임(TSMC, 2023)
- WoW는 더 높은 die 간 interconnect density를 제공하는 패키징 기술
- 특히 상단의 wafer는 많은 수의 deep-trench capacitor cell을 가지고 있어 더 원활한 power delivery를 제공하여 더 빠르고, 더 높은 voltage에서 동작할 수 있다는 장점이 있음
- 이와 같은 차세대 패키징 기술을 활용하여 Bow IPU는 이전 세대보다 전반적인 AI 워크로드에 대해 40%까지의 성능 향상을 보임
- 특히, object detection 워크로드에 대해 29%, NLP 및 이미지 분류 워크로드에 대해 39%의 성능 향상을 보였으며 이전 세대와 비교하면 16%의 전력 효율을 달성

[그림 2-18] IPU 및 Bow IPU의 구조 및 Chip 사진




자료: GraphCore웹페이지

□ IBM

○ NorthPole

- 2023년 10월, IBM은 뇌의 연산 방법에서 영감을 얻은 인공지능 가속기인 NorthPole을 발표(Dharmendra et al., 2023)
- NorthPole은 220억 개의 트랜지스터를 포함하고 있으며 12nm 공정으로 제작되었고 224MB의 온 칩 메모리를 포함하고 있음
- 아래 [그림 2-19]는 CPU(AMD Zen3), GPU(NVIDIA A100), TPU(Google TPuv4i), 그리고 NorthPole의 컴퓨팅 및 메모리 유닛의 레이아웃을 비교
- NorthPole은 centralized memory가 없이 분산된 on-chip 메모리를 탑재하고 있으며 16x16코어 어레이를 가지고 있어 data를 off-chip으로부터 로드할 필요가 없음


[그림 2-19] 다양한 프로세싱 유닛 타입의 compute 및 memory unit layout 비교



자료: Modha, Dharmendra S., et al.(2023)

- NorthPole의 연산기 종류로는 vector 연산기와 vector-matrix 연산기가 있으며 메모리 종류로는 partial sum을 저장하는 buffer, weight 저장 buffer, instruction을 저장하는 program buffer, 그리고 공유 메모리로 사용되는 weight/program/activation 메모리가 있음
- Core에 포함된 control unit은 8개의 thread를 포함하고 있으며 연산과 통신을 담당
- NorthPole의 네트워킹을 담당하는 NoC는 총 네 가지가 사용되며, 512-wire의 partial sum NoC는 근처 core의 vector 연산기 간 네트워킹을 담당함
- 256-wire의 activation NoC는 frame buffer에서 core로 image frame을 전달하고, core에서 frame buffer로 output frame을 전달하며, 공유 메모리 간 neuron activation을 shuffle 하는 역할을 포함
- 1024-wire의 model NoC는 synaptic weight를 weight buffer로 전송
- 256-wire의 instruction NoC는 program buffer로 instruction을 전송
- NorthPole은 ResNet50에 대해 비교한 성능에 따르면, 같은 12nm 공정을 이용하여 제작된 GPU인 V100과 비교하여 에너지 효율이 24.8배 향상된 결과를 달성함

[그림 2-20] IBM의 NorthPole 제품 사진 및 아키텍처



자료: Modha, Dharmendra S., et al.(2023)

□ Tenstorrent

○ Grayskull

- Tenstorrent는 PCI Gen4를 이용한 PCI 카드 형태의 AI 가속기인 Grayskull을 출시를 앞두고 있음
- Fast 버전인 e300, Medium 버전인 e150, Small 버전인 e75로 나뉨
- e300은 듀얼칩 PCI 카드이며 300W 소모, PCIe Gen4 16 lanes, 16GB의 DRAM과 200GB/sec의 속도를 보임
- e300의 Silicon TOPS는 600이며 소프트웨어를 이용하여 1700 TOPS까지 향상 가능
- e150은 150W 소모, PCIe Gen4 16 lanes, 8GB의 DRAM과 100GB/sec의 속도를 보이며 silicon TOPS는 360, 이에 소프트웨어를 이용하면 1000 TOPS까지 향상 가능
- e75는 75W 소모, 16 lanes의 PCIe Gen 4를 사용하였으며 8GB DRAM, 100GB/sec 속도를 보임
- e75의 Silicon TOPS는 250이며 소프트웨어를 이용한 최적화를 통하여 800 TOPS까지 향상 가능
- 삼성전자 미국 테일러 공장을 AI 칩렛 파트너로 정해 삼성전자 파운드리 4nm 공정인 SF4X를 적용해 AI 칩렛을 생산할 계획

[그림 2-21] Tenstorrent의 e300(좌측), e150(가운데), e75(우측)



자료: Tenstorrent 웹사이트

□ Groq

○ Groqchip

- Groq는 구글 출신의 엔지니어인 Jonathan Ross에 의해 2016년 설립된 인공지능 반도체 스타트업
- Groqchip은 14nm 공정으로 제조되었으며 900MHz에서 INT8 타입에 대해 750 TOPS, FP16 타입에 대해 188TFLOPS를 달성
- 칩마다 230MB의 SRAM을 포함하고 있으며 on-die memory bandwidth가 80TB/s까지 달성 가능
- PCIe Gen4 x 16 컨트롤러를 포함하며 Power는 Max 300W를 소모
- PCIe Gen4 x16 폼팩터에 Groqchip을 패키징하여 가속기를 제공
- 8개의 Groq card set를 활용하여 GroqNode를 구성하였으며 server의 CPU와 1TB의 DRAM을 메모리로 활용함으로써 INT8 타입에 대해 6 POPs, FP16 1.5PFLOPs를 달성
- Data center로의 도입을 위하여 8개의 GroqNode를 활용하여 GroqRack이라는 compute cluster를 구성하였으며 하나의 rack에 대해 네트워크의 end-to-end

- latency가 1.6us만을 소모하며 INT8 48POPs, FP16 12PFLOPs를 달성
- GroqWare라는 SW 스택을 함께 제공하며 이는 compiler, API, utilities를 포함
 - 프레임워크는 PyTorch, TensorFlow, ONNX를 지원하고 GroqView profiler, Performance estimator 등과 같은 utility tool을 제공

[그림 2-22] Groq의 chip, 카드, 노드, 랙 구성도



제3절 선도기업 전략기술 분석

- 2022년, 1,750억 개 이상의 파라미터를 가지는 ChatGPT의 등장을 시작으로 한 다양한 거대언어모델이 괄목할 만한 성과를 보이면서 인공지능 반도체 개발은 거대모델을 처리하기 위한 방향으로 개발되고 있으며, 이를 위해 글로벌 선도기업은 다양한 전략을 구축하여 대응 중

1. 메모리 용량 및 대역폭 증가를 위한 HBM 탑재

- 거대언어모델 처리는 메모리 용량 및 접근 속도에 직접적인 영향을 받는 memory-bounded 연산의 대표적인 예임
- 따라서, 기존의 DDR보다는 메모리 용량 및 접근 속도가 우수한 HBM을 탑재하는 것이 필수적인 요소가 됨

〈표 2-4〉 DDR 및 HBM의 specification 비교

	Bandwidth (Gbps)	Max Pin Data Rate (Gbps)	Interface width (bits)
LPDDR4x	136	4.266	32
LPDDR5	204	6.4	32
DDR4	200	3.2	64
GDDR6	512	16	32
HBM	128	1	1024
HBM2	256	2	1024
HBM2E	460	3.6	1024
HBM3	819	6.4	1024
HBM3E	1024	8	1024

자료: 저자 정리


- Intel의 HPC용 Max Series Processor는 최초로 x86 기반 CPU에 패키지당 64GB HBM2E를 내장하여 메모리 용량 및 대역폭을 최대화

- NVIDIA의 H100 SXM 폼팩터는 세계 최초로 4.8Gbps HBM3를 채택한 GPU이며 PCI 폼팩터는 3.2Gbps HBM2E를 장착
- AMD의 MI300X는 24GB HBM3 모듈 8개를 장착하여 총 192GB 메모리 용량과 5.2TB/s의 메모리 대역폭을 달성
- Xilinx의 Alveo 제품군 중 U50, U55C, 그리고 U280은 HBM2를 장착하였으며 각각 8GB, 16GB, 8GB의 용량과 316Gbps, 460Gbps, 460Gbps의 대역폭을 제공
- Sambanova의 SN40L은 온 칩 메모리와 외부 메모리 외에도 64GB의 HBM을 추가 탑재하여 메모리 중심 컴퓨팅에 대응
- Intel의 Gaudi2는 HBM2E 6개를 탑재하였으며 2024년 출시 예정인 Gaudi3는 1.5배 용량의 HBM3 또는 HBM3E를 탑재할 것으로 예상됨

2. 이중 집적을 위한 차세대 패키징 기술 접목

- 서로 다른 technology node 및 기술로 제작된 logic과 HBM 등의 메모리를 하나의 칩에 집적하기 위한 이중 집적 차세대 패키징 기술을 접목하는 것이 요구됨
- 병목현상을 줄이기 위하여 하나의 칩에 패키징하려는 움직임으로 인하여 고성능 저전력 반도체 생산의 수율을 높이고 효율적으로 칩을 생산하기 위한 칩렛 기반 설계 및 패키징 기술도 주목받고 있음
- Intel은 Max series processor를 제작하는 데 자체 개발한 차세대 패키징 기술인 EMIB 기술을 사용하여 CPU와 HBM 메모리를 한 패키지로 묶어 CPU와 메모리 간 병목현상을 줄임
- AMD는 과거 CPU 설계부터 칩렛 기반 설계를 적극적으로 활용하였으며 이를 MI300X에도 적용하여 12개의 칩렛을 3.5D 패키징을 활용하여 결합하여 생산
- GraphCore는 Bow IPU를 생산할 때 원활한 power delivery를 제공하여 높은 operating frequency와 높은 voltage로 동작할 수 있도록 TSMC의 3D WoW 패키징 기술을 활용

[그림 2-23] AMD Instinct MI300-series 가속기에 사용된 3.5D packaging 기술



자료: STH(2023. 12. 6)

3. 폰노이만 아키텍처 탈피 프로세서-메모리 구조 채택

- 메모리 접근 속도를 향상하는 방법으로 HBM을 채택하는 접근법 이외에 폰노이만 아키텍처를 탈피한 processor-in-memory(PIM) 혹은 near memory 구조를 채택하는 방법이 있음
- IBM은 centralized memory가 없으며 모든 컴퓨팅 유닛에 분산되어있는 on-chip memory를 탑재하여 weight나 instruction을 외부 메모리로부터 로드할 필요가 없음
- GraphCore는 in-processor-memory를 채택하여 IPU당 900MB의 in-processor-memory를 포함하고 있으며 IPU당 65.4TB/s 메모리 대역폭을 달성

4. 새로운 인터커넥트와 네트워킹 기술 접목

- 정해진 아키텍처에서 연산을 분산 및 병렬 수행하고자 하는 움직임으로 인하여 연산기 혹은 다이 간 데이터 전송의 필요성이 높아짐
- 데이터 전송 속도를 높이기 위하여 새롭게 개발한 인터커넥트와 네트워킹 기술을 접목하여 동작 성능을 높임

- Google은 multislice 기술을 새롭게 개발하여 하나의 pod에 수만 개의 TPU chip을 ICI로 연결할 수 있게 되었고, 여러 개의 pod은 DCN을 이용하여 연결할 수 있게 되었음
- NVIDIA는 NVLink-C2C 인터커넥트 기술을 보유하고 있으며 이를 이용하여 GH200 슈퍼 칩을 256개 결합하여 하나의 GPU인 듯 기능하는 것을 가능하게 하였으며 최대 900Gbps의 총대역폭을 제공하게 됨

제4절 국내 인공지능 반도체 연구 혁신을 위한 정책 제언

- 국내 팹리스 업체의 인공지능 반도체 개발 현황
- 국내 인공지능 반도체 업체는 데이터센터용 AI 반도체를 개발하는 리벨리온, 퓨리오사AI, 사피온코리아와 엣지용 AI 반도체를 개발하는 딥엑스, 모빌린트, 오픈엣지를 포함한 다수의 기업이 존재
 - 리벨리온은 자체 개발한 AI 반도체 ‘아툼’의 도입을 위해 IBM과 함께 성능을 평가하고 있고, 거대언어모델 처리용 ‘리벨’을 24년도 출시 예정이며 23년도 하반기 1,000억 원대 투자를 유치
 - 딥엑스는 25 TOPS, 16 TOPS 등의 성능을 보이는 엣지 추론용 반도체를 출시하고 있으며 2024년 CES에서 computer hardware, embedded technology, 그리고 robotics 세 개의 부문에서 혁신상을 수상
 - 특히, 리벨리온을 포함한 퓨리오사AI, 사피온코리아 등 데이터센터용 AI 반도체 기업은 올해부터 HBM을 본격적으로 도입한 칩을 출시할 것으로 알려져 거대모델 학습 및 추론을 본격화할 예정

〈표 2-5〉 국내 데이터센터용 AI 반도체 기업의 차세대 칩 출시 계획

	리벨리온	퓨리오사AI	사피온코리아
제품명	리벨	레니게이드	X430
출시	2024년 4분기	2024년 2분기	2025년 말 or 2026년
파운드리	삼성전자	TSMC	TSMC
공정	4나노	5나노	5나노 이상(미정)
디자인하우스	삼성전자	GUC(대만)	ASICLAND
HBM	HBM3E(삼성전자)	HBM3(SK 하이닉스)	HBM3E(SK 하이닉스)

자료: ZDNET Korea(2024. 2. 7.)

- 국내 인공지능 반도체 개발 환경의 강점
- 우리나라는 Gartner가 분류한 5가지 반도체 활용 분야의 모든 면을 아울러 삼성전자, LG전자, SK 하이닉스, 현대 자동차와 같은 세계적 기업들을 다수 보유한 국가

- 따라서 인공지능 반도체를 개발하는 국내 기업들은 자동차, 통신, 소비자 기기 등 다양한 반도체 활용 기업들로부터의 수요를 확보할 가능성을 보유
- 또한 인공지능 반도체를 개발하는 국내 팹리스 업체들은 삼성전자 공식 협력 디자인 하우스인 에이디테크놀로지, 가온칩스, 세미파이브, 코아시아 등 다수의 국내 기업들을 통하여 세계 2위 파운드리 기업인 삼성전자와의 협업이 매우 용이한 상황

[그림 2-24] 삼성전자 파운드리 공식 디자인하우스 협력 업체인 디자인 솔루션 파트너



자료: Samsung Electronics

□ 국내 인공지능 반도체 개발 현황의 한계점

- 국내 반도체 기업 간 협력 부재
 - － 인공지능 반도체 제작은 특히 HBM을 채택하는 세계적 추세를 따를 때 팹리스, 디자인 하우스, 파운드리 기업 뿐만 아니라 패키징 업체와 같은 반도체 후공정 업체와의 긴밀한 협력이 필요
 - － 예를 들어, 서로 다른 공정에서 제작되는 HBM과 로직을 하나의 제품으로 패키징하기 위하여 인터포저, 대면적의 기판, 배선, 테스트 등 다양한 후공정 기술들이 집약되어야 함
 - － 국내의 다양한 반도체 후공정 기업들이 있고 기업별로 수준 높은 기술력을 보유하고 있지만 기업 간 이해관계 상충 및 소통의 부재로 인하여 현실적으로 협력이 쉽

지 않은 실정

- 이를 극복하고 팹리스-디자인하우스-파운드리-반도체 후공정 업체 간 활발한 협력이 이루어진다면 국내 중소기업 반도체 생태계를 크게 확장할 기회가 될 수 있음
- 국내 파운드리 및 반도체 후공정 업체의 약세
 - 세계 2위 파운드리 기업인 삼성전자는 특히 인공지능 반도체의 대상 업체로서의 경쟁력이 두드러지게 낮은 편
 - AI 반도체 시장이 비교적 초기 단계로서 경쟁 강도가 높지 않아 세계 많은 팹리스 기업들이 AI 반도체 선도 기업을 선점하기 위한 사활을 걸어 파운드리 단계에서의 위험성을 최소화하고자 세계 1위 파운드리 기업인 TSMC에 수요가 집중

〈표 2-6〉 세계 AI 반도체 설계 팹리스 기업이 채택한 파운드리 업체와 technology node

파운드리	팹리스	AI 반도체 제품명	공정
TSMC	AMD	Ryzen7040	4 nm
		Instinct MI300X	5 nm
	NVIDIA	H100	4 nm
	SambaNova	SN40L	5 nm
	Habana Labs	Gaudi2	7 nm
		Gaudi3	5 nm
	Google	TPUv4	7 nm
	Cerebras	WSE-2	7 nm
	Graphcore	Bow IPU	7 nm
	퓨리오사 AI	레니게이드	5 nm(예정)
Samsung	사피온코리아	X430	5 nm ~(예정)
	Groq	GroqChip(next gen.)	4 nm(예정)
	딥엑스	DX-L1, L2, M1, H1	5 nm ~ 28 nm
Intel	리벨리온	리벨	4 nm(예정)
		Xeon Scalable Processor	intel 7(10 nm)
		Xeon Max Series	intel 7(10 nm)

자료: 저자 정리

- 반도체 후공정 업체 또한 국내 기업의 약세가 지속적인 문제로 대두되고 있으며 표 7과 같이 상위 10개의 반도체 후공정 업체에서 국내 기업이 이름을 올리지 못함
- 국내 기업의 약세로 인해 반도체 후공정 단계에서의 해외 의존도가 높아지면 장기적으로 국내 반도체 업계 전반의 경쟁력 약화로 이어질 위험이 있음
- 국내 파운드리 및 후공정 기업의 노하우 집적을 위해 전문 인력 생성, 연구 기관의 선도적 기술 제안 및 연구 수행, 팹리스의 파운드리 및 후공정 업체 채택 등의 산학연 협력이 수반되어야 함

〈표 2-7〉 상위 10개 글로벌 반도체 후공정 기업

Rank	Company	Country	2020 Revenue	2021 Revenue	2021 Market Share	2021 YoY Revenue Growth
1	ASE	대만	1,379	1,863	23.7%	35.1%
2	AmKor	미국	1,173	1,407	17.9%	19.9%
3	JCET	중국	879	1,099	14.0%	25.0%
4	SPIL	대만	910	931	11.8%	2.3%
5	PTI	대만	649	742	9.4%	14.3%
6	TFME	중국	351	591	7.5%	68.3%
7	Hua Tian	중국	284	467	5.9%	64.7%
8	KYEC	대만	256	274	3.5%	6.8%
9	ChipMOS	대만	182	251	3.2%	38.4%
10	Chipbond	대만	168	251	3.2%	49.6%

자료: TrendForce(2021)

- NVIDIA GPU의 지배적인 AI 반도체 시장 점유율 독식으로 인한 국내 기술 실증 사례 부족 및 지속적인 지원 부재
 - 국내외 많은 AI 컴퓨팅 인프라는 NVIDIA GPU를 채택하며 NVIDIA는 AI 반도체 시장의 80% 이상을 점유한 것으로 알려져 있음
 - 따라서 정부 R&D 예산 책정 부처 혹은 스타트업 투자자들은 AI 반도체 개발 기관이 비교적 막대한 비용을 투자받으면서도 일정 수준의 매출을 발생시키지 못하는 점에 대해 우려하는 시선이 있음

- NVIDIA의 GPU는 고유의 분산 컴퓨팅 구조를 이용한 아키텍처를 1990년대 후반부터 현재까지 지속해서 업그레이드하여 출시하고 있어 기술적 완성도가 높은 하드웨어임
- 반면, 대부분의 AI 반도체가 채택한 시스톨릭 어레이 구조 기반 AI 반도체 아키텍처는 불과 2016년 Google의 TPU를 시작으로부터 시작되었으며 기술적 완성도를 높이기엔 역사가 매우 짧은 편
- 따라서 국내 인공지능 반도체 개발 팹리스 업체의 제품을 채택한 AI 컴퓨팅 인프라를 구축함으로써 실증 사례를 충분하게 만들어야 하며, 이를 위해서는 지속적인 R&D 지원을 필요로 함

□ 국내 팹리스 업체의 경쟁력 혁신을 위한 정책 제언

- 국내 반도체 기업 간 협력 활성화
 - 반도체 제품 제작의 전주기를 아우르는 팹리스, 디자인하우스, 파운드리, 반도체 후공정 기업, 인공지능 반도체 수요 기업의 활발한 협력 생태계를 조성하는 정책을 제시해야 함
 - 각 기업은 소통 및 협력을 통해 각자가 보유하고 있는 기술의 고도화 및 노하우 집적을 통한 경쟁력 강화를 이룰 수 있다는 이해관계를 인지하고 서로의 공급업체이자 수요업체가 될 가능성에 관한 내용을 공유하고 공감할 수 있는 소통의 창구를 제시하는 정책 마련
 - 출연연 등 각 기업과 이해관계가 얹히지 않은 공공기관의 특성을 활용하여 다양한 국내 기업들이 하나의 프로젝트로 협력하고 성장할 기회를 제공하고, 이를 수행하는 기관과 업체에 재정적, 정책적인 지원을 마련
- 국내 파운드리 및 반도체 후공정 업체의 경쟁력 강화 지원
 - 인공지능 반도체 관련 설계 분야뿐만 아니라 소자, 장비, 차세대 패키징, 테스트, 소프트웨어 등 반도체 제작 전주기와 관련된 다양한 분야의 전문 인력 양성을 위한 정책 마련
 - 국내 파운드리 및 반도체 후공정 업체를 채택하는 수요 기업에 대한 정책적인 지원을 마련하여 국내 반도체 기업들의 상호 보완 및 성장의 생태계를 조성
- 국내 AI 반도체 기술 실증 사업 활성화 및 지속적인 지원 유지

- 국내 AI 반도체를 데이터센터에 채택하기 위한 성능 평가 인프라 구축 및 비용 지원을 통해 실증이 가능한 국산 반도체 확대 지원
- 국내 AI 반도체 채택 수요 기업과 해당 반도체 제작 업체에 대한 정책적 지원을 통해 실증 사례 확산 유도
- 기술적 역사가 짧지만 원천 기술을 확보하고자 하는 인공지능 반도체 R&D에 지속적인 투자를 유지하며 공격적인 기술 개발에 도전하는 연구자, 기관, 업체에 선제적 투자를 통한 R&D 지원