

AI반도체 글로벌 첨단 기술·산업 동향 조사 및 대응방향 연구

A Study on Global Technology and Industry
Trends and Directions for Responses in the Field of
Advanced AI Semiconductors

2024. 2

연구기관 : 정보통신정책연구원



과학기술정보통신부



정보통신기획평가원

방송통신정책연구 RS-2023-00260453

AI반도체 글로벌 첨단 기술·산업 동향 조사 및 대응방향 연구

(A Study on Global Technology and Industry
Trends and Directions for Responses in the Field
of Advanced AI Semiconductors)

윤성욱/김민식/오정숙

2024. 2

연구기관 : 정보통신정책연구원



과학기술정보통신부



정보통신기획평가원

이 보고서는 2023년도 과학기술정보통신부 방송통신발전기금 방송통신정책연구사업의 연구결과로서 보고서 내용은 연구자의 견해이며, 과학기술정보통신부의 공식입장과 다를 수 있습니다.

제 출 문

과학기술정보통신부 장관 귀하

본 보고서를 『AI반도체 글로벌 첨단 기술·산업 동향 조사 및
대응방향 연구』의 연구결과보고서로 제출합니다.

2024년 2월

연구기관: 정보통신정책연구원

총괄책임자: 윤성욱 연구위원

참여연구원: 김민식 부연구위원

오정숙 부연구위원

목 차

요약문	xi
제 1 장 국내외 인공지능 반도체 시장 현황 및 전망	1
제 1 절 국내외 반도체 시장 현황	1
1. 전세계 반도체 시장 현황 및 전망	1
2. 전세계 파운드리 현황 및 전망	6
제 2 절 국내외 인공지능 반도체 시장 현황 및 전망	11
1. 인공지능 반도체 개념	11
2. 전세계 인공지능 반도체 시장 현황 및 전망	12
제 2 장 AI 반도체 선도기업 기술 동향 및 혁신전략	18
제 1 절 인공지능 반도체 기술 개요	18
제 2 절 AI 반도체 선도기업 기술 동향	22
1. 중앙 처리 장치(CPU, Central Processing Unit)	2
2. 그래픽 처리 장치(GPU, Graphics Processing Unit)	7
3. 가속 처리 장치(APU, Accelerated Processing Unit)	3
4. 필드 프로그래머블 게이트 어레이(FPGA, Field Programmable Gate Array)	3
5. 특정 용도용 집적 회로(ASIC, Application-Specific Integrated Circuit)	53
제 3 절 선도기업 전략기술 분석	46
1. 메모리 용량 및 대역폭 증가를 위한 HBM 탑재	46
2. 이종 집적을 위한 차세대 패키징 기술 접목	47
3. 폰노이만 아키텍처 탈피 프로세서-메모리 구조 채택	48
4. 새로운 인터커넥트와 네트워킹 기술 접목	48
제 4 절 국내 인공지능 반도체 연구 혁신을 위한 정책 제언	50

제 3 장 AI 반도체와 가치사슬의 변화	56
제 1 절 AI 반도체와 수평적 가치 활동별 변화 현황	56
1. 개요	56
2. SIP(Semiconductor Intellectual Propriety)	95
3. EDA(Electronic Design Automation)	6
4. Design House	68
5. Foundry	72
6. OSAT	75
제 2 절 AI 반도체와 수평적 가치사슬의 변화	77
1. AI 반도체 등장에 따른 수평적 가치사슬의 변화 이슈	77
2. AI 반도체 등장에 따른 수평적 가치사슬의 변화 방향	79
제 3 절 AI 반도체와 ON Device AI	85
1. ON Device AI 이해	85
2. ON Device AI와 AI 반도체	87
제 4 절 활용처 분야별 인공지능 반도체 기술 분석	91
제 4 장 국내외 인공지능 반도체 정책 현황	97
제 1 절 국내 반도체 정책 현황	97
1. 우리나라의 반도체 및 인공지능 반도체 지원정책 개요	97
2. 국내 반도체 산업 육성을 위한 주요 전략 및 내용	99
3. 인공지능 반도체 산업 육성을 위한 정책 현황	105
제 2 절 해외 반도체 관련 주요 정책 현황	113
1. 주요 기술 선도국의 반도체 관련 정책 개요(2021년~2023년)	113
2. 미국	114
3. 중국	115
4. EU	117
5. 일본	118

제 5 장 인공지능 반도체 정책적 대응 방향 제언	120
참고문헌	123

표 목 차

〈표 1-1〉 수요 분야별 글로벌 반도체 시장 현황 및 전망(2022년~2027년)	4
〈표 1-2〉 전세계 반도체 기업의 시장 점유율(2022년~2023년)	6
〈표 1-3〉 글로벌 상위 5개 파운드리업체 매출액 및 점유율(2021년~2022년)	10
〈표 1-4〉 수요 분야별 AI 반도체 시장 현황 및 전망(2022년~2027년)	14
〈표 1-5〉 AI 반도체 종류별 시장 현황 및 전망(2022년~2027년)	16
〈표 2-1〉 프로세싱 유닛 타입에 따른 인공지능 반도체 선도기업과 대표 제품	23
〈표 2-2〉 Amazon AWS의 인스턴스별 GPU 환경	27
〈표 2-3〉 Xilinx Alveo Family 라인업	33
〈표 2-4〉 DDR 및 HBM의 specification 비교	46
〈표 2-5〉 국내 데이터센터용 AI 반도체 기업의 차세대 칩 출시 계획	50
〈표 2-6〉 세계 AI 반도체 설계 팹리스 기업이 채택한 파운드리 업체와 technology node	52
〈표 2-7〉 상위 10개 글로벌 반도체 후공정 기업	53
〈표 3-1〉 SIP 시장점유율(2021~2022)	63
〈표 4-1〉 우리나라(인공지능) 반도체 산업 육성정책 및 주요 내용	97
〈표 4-2〉 『K-반도체 전략』의 핵심 전략과 주요 내용	102
〈표 4-3〉 AI 기술경쟁력 확보를 위한 세부정책	106
〈표 4-4〉 인공지능(AI) 반도체 산업 발전전략의 12개 세부과제	107

그 립 목 차

[그림 1-1]	글로벌 반도체 시장규모 현황 및 전망(2022년~2027년)	1
[그림 1-2]	글로벌 메모리 및 비메모리 반도체 시장 현황 및 전망(2022년~2027년) ..	2
[그림 1-3]	글로벌 메모리 및 비메모리 반도체 시장 점유율 현황 및 전망 (2022년~2027년)	2
[그림 1-4]	반도체 품목별 시장규모(2022년 및 전망, 2022년~2027년)	3
[그림 1-5]	수요 어플리케이션별 글로벌 반도체 시장점유율 현황 및 전망	5
[그림 1-6]	글로벌 파운드리 시장규모 현황 및 전망(2022년~2027년)	7
[그림 1-7]	글로벌 파운드리 수요처별 성장률 추이 및 전망(2022년~2027년)	8
[그림 1-8]	글로벌 파운드리 수요처별 비중 추이 및 전망(2022년~2027년)	8
[그림 1-9]	글로벌 파운드리 고객별 성장률 추이 및 전망(2022년~2027년)	8
[그림 1-10]	글로벌 파운드리 고객별 비중 추이 및 전망(2022년~2027년)	8
[그림 1-11]	글로벌 파운드리 지역별 성장률 추이 및 전망 (2022년~2027년)	9
[그림 1-12]	글로벌 파운드리 지역별 비중 추이 및 전망(2022년~2027년)	9
[그림 1-13]	글로벌 파운드리업체 점유율 추이(2021년~2022년)	10
[그림 1-14]	글로벌 AI 반도체 시장 현황 및 전망(2022년~2027년)	13
[그림 1-15]	글로벌 AI 반도체 시장이 글로벌 반도체 시장에서 차지하는 비중 추이 및 전망(2022년~2027년)	13
[그림 1-16]	글로벌 AI 반도체 시장의 수요처별 비중 추이 및 전망(2022년~2027년) ..	15
[그림 1-17]	글로벌 AI 반도체 시장의 품목별 비중 추이 및 전망(2022년~2027년)	17
[그림 2-1]	NVIDIA vs AMD vs Intel의 데이터 센터 구축 수익 비교	19
[그림 2-2]	전 세계 APU 시장 매출규모	20
[그림 2-3]	최근 개발된 10B 이상 크기의 대규모 언어모델(음영: 코드공개)	22
[그림 2-4]	4세대 Intel Xeon Scalable Processor	25
[그림 2-5]	HBM을 장착한 AI/HPC용 Intel CPU, Intel Max Series Processor	26

[그림 2-6]	AMD의 XDNA AI 엔진 개념도	27
[그림 2-7]	NVIDIA H100	28
[그림 2-8]	AMD Instinct MI300X의 아키텍처 구조도	30
[그림 2-9]	AMD Instinct MI300A의 아키텍처 구조도	31
[그림 2-10]	그레이스 호퍼 슈퍼칩(GH200)의 구조도	32
[그림 2-11]	Xilinx Alveo U280	34
[그림 2-12]	투자 수주액으로 나열한 상위 5개 AI Chip maker 및 Sambanova의 SL40L	35
[그림 2-13]	Google TPU v5e AI 보드	36
[그림 2-14]	Google의 multislice 기술도	37
[그림 2-15]	Habana Labs의 Gaudi12 제품 사진 및 아키텍처	38
[그림 2-16]	Gaudi2와 비교한 Gaudi3의 specification	39
[그림 2-17]	GraphCore의 Bow IPU(좌측) 및 Bow-2000(우측)	40
[그림 2-18]	IPU 및 Bow IPU의 구조 및 Chip 사진	41
[그림 2-19]	다양한 프로세싱 유닛 타입의 compute 및 memory unit layout 비교	42
[그림 2-20]	IBM의 NorthPole 제품 사진 및 아키텍처	43
[그림 2-21]	Tenstorrent의 e300(좌측), e150(가운데), e75(우측)	44
[그림 2-22]	Groq의 chip, 카드, 노드, 랙 구성도	45
[그림 2-23]	AMD Instinct MI300-series 가속기에 사용된 3.5D packaging 기술	48
[그림 2-24]	삼성전자 파운드리외의 공식 디자인하우스 협력 업체인 디자인 솔루션 파트너	51
[그림 3-1]	반도체 가치시스템	56
[그림 3-2]	반도체 수평적 가치사슬의 범위	58
[그림 3-3]	반도체 설계 과정의 이해	60
[그림 3-4]	SIP의 구분	61
[그림 3-5]	SIP 분류별 시장규모 비중의 변화	63
[그림 3-6]	Electronic Design Automation Tools(EDA) 시장 규모	67
[그림 3-7]	디자인 하우스 기업의 역할과 변화	70

[그림 3-8] 삼성전자 파운드리 사업부의 DSP 현황	71
[그림 3-9] TSMC의 VCA 현황	71
[그림 3-10] 기존 반도체 가치시스템	77
[그림 3-11] AI 반도체와 수평적 가치사슬의 변화 I	80
[그림 3-12] AI 반도체와 수평적 가치사슬의 변화 II	81
[그림 3-13] AI 반도체와 수평적 가치사슬의 변화 III	83
[그림 3-14] AI 반도체와 수평적 가치사슬의 변화 IV	84
[그림 3-15] 클라우드 서버를 사용하는 인공지능과 온디바이스 인공지능의 비교	86
[그림 3-16] 중앙집중형 AI 방식 대비 온디바이스 AI 방식	86
[그림 3-17] 온 디바이스 장치 중심의 하이브리드 AI 아키텍처	88
[그림 3-18] NVIDIA Drive 개념도	94
[그림 3-19] 딥엑스의 DX-M1 AI chip	95
[그림 3-20] Mythic의 MM1076 M.2 M Key Card 제품 사진	96
[그림 4-1] '시스템반도체 비전과 전략' 정책의 구조	100
[그림 4-2] 정책효과 전망	105
[그림 4-3] 인공지능(AI) 반도체 산업 발전전략 목표 및 추진전략	107
[그림 4-4] 인공지능(AI) 반도체 산업 성장 지원대책 개요	110
[그림 4-5] 케이-클라우드 추진방안 개요	112

요 약 문

1. 제 목

AI반도체 글로벌 첨단 기술산업 동향 조사 및 대응방향 연구

2. 연구 목적 및 필요성

- 인공지능·데이터 생태계의 핵심기반 산업인 AI 반도체 시장에서 국내 AI 반도체 산업의 경쟁력 강화를 도모
 - － 인공지능반도체 산업의 글로벌 산업 동향 및 주요국 지원정책을 조사·분석하여, 국내 산업계 경쟁력을 진단하고, 차세대 인공지능 반도체 경쟁력 강화를 위한 전략 도출 기반 마련

3. 연구의 구성 및 범위

- AI반도체 산업 글로벌 트렌드와 국내외 산업 동향 분석
 - － AI반도체 산업 현황, 현재 기술 수준 등
 - － AI반도체 수요처 현황과 수요 변화 전망
 - － AI반도체 가치사슬의 현황과 구조 변화 전망
- AI 반도체 수요·공급망 분석 및 차세대 기술 현황 조사
 - － AI 반도체 시장 및 공급망 구조 분석
 - － 글로벌 공급-수요를 감안한 기술 발전 동향 분석
- AI반도체 지속적인 경쟁력 확보를 위한 대응방안
 - － 주요국의 AI반도체 차세대 기술 지원·육성 정책 동향 비교·분석

－ AI반도체 산·학·연 협력 현황 조사 및 지원방향 도출

4. 연구 내용 및 결과

- 제1장 국내외 인공지능 반도체 시장 현황 및 전망
 - － 국내외 기술별 수요처별 반도체 시장 현황과 전망, 파운드리 시장 및 전망 분석
 - － 국내외 인공지능 반도체 시장 현황 및 전망: 인공지능 반도체 개념을 설명하고, AI 반도체의 기술별 수요처별 시장 규모와 전망 분석
- 제2장 AI 반도체 선도기업 기술 동향 및 혁신전략
 - － 인공지능 반도체 기술 개요: AI 반도체의 기술적 개요와 주요 기술 트렌드 설명
 - － AI 반도체 선도기업 기술 동향: 주요 기업들의 AI 반도체 관련 기술 및 제품 개발 상황을 분석. 중앙처리장치(CPU), 그래픽처리장치(GPU), 가속처리장치(APU), FPGA, ASIC 등의 최신 동향 제공
 - － 선도기업 전략기술 분석 및 국내 인공지능 반도체 연구 혁신을 위한 정책 제언: 선도기업의 전략과 차세대 기술을 분석하고, 이를 통해 국내 연구 및 정책 방향을 제언
- 제3장 AI 반도체와 가치사슬의 변화
 - － AI 반도체와 수평적 가치 활동별 변화 현황: AI 반도체의 도입이 가치사슬의 각 활동에 어떤 변화를 가져왔는지 설명
 - － AI 반도체와 수평적 가치사슬의 변화: AI 반도체 등장에 따른 수평적 가치사슬의 변화 이슈 분석과 수평적 가치사슬의 변화 방향 예측
 - － AI 반도체와 ON Device AI: 기기 내 AI의 개념과 AI 반도체와의 관계를 설명 및 분석
 - － 활용 분야별 인공지능 반도체 기술 분석: 다양한 적용 분야에서 AI 반도체 기술이 어떻게 활용되고 있는지 분석
- 제4장 국내외 인공지능 반도체 정책 현황
 - － 국내 반도체 정책 현황: 한국의 반도체 및 AI 반도체 관련 정책 소개 및 분석.
 - － 해외 반도체 관련 주요 정책 현황: 주요 기술 선도국의 반도체 정책 개요 와 주요 내용 분석

- 제5장 인공지능 반도체 정책 방향 제언
 - － AI 반도체 등장에 따른 전 세계 반도체 시장환경의 변화 분석
 - － 최근 AI 반도체 정책 대응 방안 분석 및 향후 AI 반도체 대응 방향 제언

5. 정책적 활용 내용

- AI 반도체 경쟁력을 강화하기 위해서는 ① 특정한 수요처를 목표로, ② 수평적인 가치사슬 중 어떠한 영역에 정책적인 자원을 할당할 것인지, 그리고 ③ 활용 생태계에 서특정 기술의 정책 지원 등을 분석하여 맞춤형 지원프로그램 제언
 - － AI 반도체의 수요 예측을 통한 전략적인 중점 제품에 대한 평가 & 발굴·육성 방향
 - － AI 반도체의 수평적인 가치사슬 간 연계·성장 생태계에 대한 평가 & 조성 방향
 - － AI 반도체의 활용 생태계(클라우드, 온디바이스, 시스템 SW 등)에 대한 평가 & 강화 방향
- (AI 반도체의 수평적 가치사슬) 반도체IP, EDA, 팹리스, 디자인하우스, 파운드리, OSAT 각각에 대한 구체적이고 조밀한 구조의 지원프로그램이 요구
- (AI 반도체 수요처) 수평적인 생태계를 통해 판매되는 AI 반도체의 수요시장인 자동차, 인터스트리, 소비자 가전, 통신 별 각각 차별화된 지원프로그램도 필수
- (AI 반도체 활용 생태계) Cloud/On Device에 AI 반도체가 탑재되어 활용되기 위해서는 AI 모델개발 혹은 최적화를 지원하는 프레임워크 및 SW 등 활용 생태계가 필수

6. 기대효과

□ 향후 AI 반도체 대응 방향에 있어 정책 수립을 위한 프레임워크 제공

- 최근 AI 반도체 관련 정책에 있어 입체성과 기밀도가 부족한 상황에서 이를 강화
 - ※ AI 반도체 정책의 입체성(Three-dimensionality): 국내 AI 반도체 생태계 구축에 있어, 경쟁력을 제공하기 위해서는 아래 나열된 3가지 기준을 참조하여 필요한 입체적인 정책 방향을 도출해야 함

① AI 반도체 수평적 가치사슬

② AI 반도체 수요처

③ AI 반도체 활용 생태계

※ AI 반도체 정책의 기밀도(Density): 국내 AI 반도체 생태계 애로사항을 입체적인 관점에서 파악하고 진단하고, 그동안 충족되지 못한 Needs 해결에 도달할 수 있도록 있는 맞춤형 프로그램 제시

SUMMARY

1. Title

A Study on Global Technology and Industry Trends and Directions for Responses in the Field of Advanced AI Semiconductors

2. Objective and Importance of Research

- To strengthen the competitiveness of the Korean AI semiconductor industry, which is the core foundation industry of artificial intelligence and data ecosystems:
 - To investigate and analyze global industry trends in the AI semiconductor industry and the policies adopted by major countries to support their industries, to diagnose the competitiveness of the Korean industry, and to lay the foundation for developing strategies that strengthen the competitiveness of next-generation AI semiconductors

3. Contents and Scope of the Research

- An analysis of global AI semiconductor industry trends as well as Korean and other countries' industry trends:
 - Current state of the AI semiconductor industry and its current technology levels
 - Sources of demand for AI semiconductors and prospects for changes in demand
 - Current state of the AI semiconductor value chain and prospects for structural changes

- An analysis of AI semiconductor demand and supply chains and an investigation into the current state of next-generation technologies:
 - AI semiconductor market and supply chain structure analysis
 - An analysis of technological development trends taking global supply and demand into consideration
- Measures to secure the continuous competitiveness of the Korean AI semiconductor industry
 - A comparative analysis of major countries' policy trends to support and nurture next-generation AI semiconductor technologies
 - Investigating the current state of AI semiconductor industry-academia-research collaborations and identifying directions for support

4. Research Results

- Chapter 1: Current State and Prospects of Korean and Overseas AI Semiconductor Markets
 - An analysis of the semiconductor market status and prospects as well as the foundry market status and its prospects, by technology and by source of demand at home and abroad
 - Current state and prospects of Korean and overseas AI semiconductor markets: Explaining the concept of AI semiconductors and analyzing the sizes and prospects of AI semiconductor markets, by technology and by source of demand
- Chapter 2: Technology Trends and Innovation Strategies of Leading AI Semiconductor Companies
 - AI semiconductor technology overview: A technical overview of AI semiconductors and an account of major technology trends
 - Technology trends of AI semiconductor leaders: An analysis of technology and

product developments of major AI semiconductor companies and a description of the latest trends in central processing units (CPUs), graphics processing units (GPUs), accelerated processing units (APUs), field-programmable gate arrays (FPGAs), and application-specific integrated circuits (ASICs)

- An analysis of the strategic technologies of leading companies and policy recommendations for innovation in domestic AI semiconductor research: Analyzing the strategies and next-generation technologies of leading companies and proposing directions for domestic research and policies based on the analysis
- Chapter 3: AI Semiconductors and Value Chain Changes
 - AI semiconductors and changes as per horizontal value activity: Explaining how the introduction of AI semiconductors has changed each activity in the value chain
 - AI semiconductors and changes in horizontal value chains: An analysis of issues arising from changes in horizontal value chain changes with the emergence of AI semiconductors and predictions of the direction of changes in horizontal value chains
 - AI semiconductors and on-device AI: Explaining and analyzing the concept of on-device AI and its relationship with AI semiconductors
 - An analysis of AI semiconductor technologies by field of application: An analysis of how AI semiconductor technology is being used in a wide range of applications
- Chapter 4: Current State of Domestic and Overseas AI Semiconductor Policies
 - Korean semiconductor policies: Introduction and analysis of Korea's semiconductor and AI semiconductor policies
 - Major semiconductor policies of other countries: An overview of semiconductor policies in technologically advanced countries and an analysis of their contents
- Chapter 5: Proposals for AI Semiconductor Policy Directions
 - An analysis of changes in semiconductor market environments in the world prompted by the emergence of AI semiconductors
 - An analysis of responses to recent AI semiconductor policies and proposals for

future responses

5. Policy Suggestions for Practical Use

- (Horizontal value chain of AI semiconductors) Specific and densely-structured support programs are required for semiconductor IPs, EDAs, fabless manufacturing, design houses, foundries, and OSAT services.
- (Sources of demand for AI semiconductors) It is also essential to offer differentiated support programs for each demand market for AI semiconductors, which are sold through horizontal ecosystems, such as automobiles, industries, consumer electronics, and telecommunications.
- (AI semiconductor utilization ecosystems) In order for AI semiconductors to be installed and utilized in clouds and on-device products, it is essential to create ecosystems for utilizing AI semiconductors, such as frameworks and software supporting the development and optimization of AI models.
- To strengthen the competitiveness of AI semiconductors, it is recommended that the government develop customized support programs by ① targeting specific customers, ② analyzing what areas in the horizontal value chain it should allocate policy resources to, and ③ analyzing policy support for specific technologies in the ecosystems that utilize the technology:-
 - Evaluate and nurture key strategic products through AI semiconductor demand forecasts;
 - Evaluate and create ecosystems that link and nurture the horizontal value chains of AI semiconductors;
 - Evaluate and strengthen ecosystems that utilize AI semiconductors (e.g., clouds, on-device AI, system software).

6. Expectations

□ **A framework for designing policies to set directions for responding to future developments in the AI semiconductor landscape is expected to be established.**

- Recent AI semiconductor policies lack three-dimensionality and density.
- ※ Three-dimensionality of AI semiconductor policies: To ensure competitiveness in creating domestic AI semiconductor ecosystems, it is necessary to identify three-dimensional policy directions by referencing the three criteria listed below:-
 - ① AI semiconductor horizontal value chains,
 - ② sources of demand for AI semiconductors,
 - ③ AI semiconductor utilization ecosystems.
- ※ Density of AI semiconductor policy: This study will help identify and diagnose difficulties facing domestic AI semiconductor ecosystems from a three-dimensional perspective and propose programs customized to meet unmet needs.


제 1 장 국내외 인공지능 반도체 시장 현황 및 전망

제 1 절 국내외 반도체 시장 현황

1. 전세계 반도체 시장 현황 및 전망

- 2023년 글로벌 반도체 시장은 수요부진으로 전년 대비 11.1% 축소된 5,330억 달러 규모로 추정되며, 2023년부터 2027년까지 연평균 9.4% 성장률을 기록하여 2027년에는 7,646억 달러에 이를 것으로 전망됨
- － 분야별로 비메모리 반도체는 2022년 5.5%에서 2023년 -3.0% 마이너스 성장 전환하고, 메모리반도체는 2022년 -13.7%에 이어 2023년 -37.0%로 부진 심화
- － 이에 따라, 글로벌 반도체 시장에서 메모리가 차지하는 비중은 2022년 23.9%에서 2023년 16.9%로 7.0%p 하락할 것으로 추정됨

[그림 1-1] 글로벌 반도체 시장규모 현황 및 전망(2022년~2027년)




주: 매출 기준임

자료: Gartner(2023. 12a)

— 그러나 AI 서비스 확산에 따른 수요 증가로 2023년부터 2027년까지 비메모리 반도체 및 메모리 반도체 각각 연평균 7.0%, 19.7% 성장하여 메모리가 차지하는 비중은 2027년 24.2%로 회복할 것으로 기대됨


[그림 1-2] 글로벌 메모리 및 비메모리 반도체 시장 현황 및 전망(2022년~2027년)



주: 매출 기준임

자료: Gartner(2023. 12a)

[그림 1-3] 글로벌 메모리 및 비메모리 반도체 시장 점유율 현황 및 전망(2022년~2027년)




주: 매출 기준임

자료: Gartner(2023. 12a)

- 품목별로는 매출액 기준 2022년 가장 큰 규모를 형성한 DRAM, 마이크로프로세서, 플래시메모리(NAND)는 2023년 두 자릿수 마이너스 성장한 반면, GPU는 60% 가까운 성장률 기록
 - DRAM과 플래시메모리는 2023년 반도체 품목 중 가장 크게 전년 대비 각각 -38.5%, -37.5%씩 하락하면서 전체 반도체 시장에서 차지하는 비중도 2022년 대비 2023년 각각 DRAM은 13.1%에서 9.1%로, 플래시메모리는 9.7%에서 6.8%로 하락한 것으로 추정됨
 - 반면, GPU는 2023년 품목 중 가장 높은 성장률(58.1%)로 전체 반도체에서 차지하는 비중은 2022년 2.5%에서 2023년 4.4%로 확대된 것으로 예상되며, 2022년부터 2027년까지도 전체 반도체 품목 중 가장 높은 15.0%의 연평균 성장률 기록할 것으로 전망됨

[그림 1-4] 반도체 품목별 시장규모(2022년 및 전망, 2022년~2027년)



주: 버블의 크기는 2022년 매출액 기준임

자료: Gartner(2024. 1a)

- 수요처 별로는 자동차 분야가 2022년에 이어 2023년에도 두 자릿수의 성장률을 기록한 반면, 각각 1/3을 차지하는 통신기기와 컴퓨팅기기 분야는 두 자릿수 하락 추정
 - 자동차용 반도체 분야의 2023년부터 2027년까지 연평균 성장률은 11.4%로 수요처 중 가장 높으며, 통신 및 컴퓨팅 기기도 9.3%의 성장률로 반도체 수요를 이끌 것으로 전망됨

- 수요처별 비중의 경우, 통신기기와 컴퓨팅 기기 분야의 점유율이 유지되는 가운데 자동차 분야 비중이 2022년 11.3%에서 2027년 16.0%로 4.7%p 증가하며 수요처 중 확대폭이 가장 클 것으로 예상됨


〈표 1-1〉 수요 분야별 글로벌 반도체 시장 현황 및 전망(2022년~2027년)
(단위: 백만 달러, 전년동기 대비 성장률)

		2022년	2023년	2024년	2025년	2026년	2027년	2023~2027년 CAGR
자동차 (Automotive Electronics)	매출규모	67,530	79,287	89,571	104,583	114,900	122,173	11.4%
	성장률	23.8%	17.4%	13.0%	16.8%	9.9%	6.3%	
통신기기 (Communication Electronics)	매출규모	192,841	155,578	189,638	213,230	225,946	221,863	9.3%
	성장률	0.9%	-19.3%	21.9%	12.4%	6.0%	-1.8%	
소비자기기 (Consumer Electronics)	매출규모	66,739	59,512	68,298	73,282	75,230	75,602	6.2%
	성장률	-1.0%	-10.8%	14.8%	7.3%	2.7%	0.5%	
컴퓨팅기기 (Data Processing Electronics)	매출규모	198,764	164,652	198,560	233,892	249,726	235,357	9.3%
	성장률	-9.4%	-17.2%	20.6%	17.8%	6.8%	-5.8%	
산업, 국방/항공 (Industrial and Military/ Civil Aerospace Electronics)	매출규모	73,688	73,996	83,859	93,055	102,126	109,559	10.3%
	성장률	11.7%	0.4%	13.3%	11.0%	9.7%	7.3%	
총 합계	매출규모	599,562	533,025	629,927	718,042	767,928	764,554	9.4%
	성장률	0.2%	-11.1%	18.2%	14.0%	6.9%	-0.4%	

주: 매출 기준임

자료: Gartner(2023. 12a)

[그림 1-5] 수요 어플리케이션별 글로벌 반도체 시장점유율 현황 및 전망



주: 매출 기준임

자료: Gartner(2023. 12a)

- 글로벌 반도체 기업별로는 2023년 메모리 반도체 시장의 부진으로 삼성전자와 SK하이닉스의 순위가 하락한 가운데 GPU의 수요 확대로 NVIDIA의 순위는 2022년 12위에서 5위로 대폭 상승한 것으로 추정
 - － 삼성전자와 하이닉스는 2023년 글로벌 상위 10개 기업 중 가장 높은 30%대의 마이너스 매출 하락을 기록하여 삼성전자는 2022년 1위에서 2023년 2위로 한단계 하락하고 동기간 SK하이닉스는 4위에서 6위로 두단계 하락
 - － NVIDIA는 2023년 전년 대비 매출액이 56.4% 증가하고 점유율은 4.5%를 기록하며 4.3%의 SK하이닉스 추월

〈표 1-2〉 전세계 반도체 기업의 시장 점유율(2022년~2023년)

2022 Rank	2023 Rank	Vendor	2022 Revenue (Billions of Dollars)	2023 Revenue (Billions of Dollars)	2022-2023 Growth	2023 Market Share
2	1	Intel	58.436	48.664	-16.7%	9.1%
1	2	Samsung Electronics	63.823	39.905	-37.5%	7.5%
3	3	Qualcomm	34.780	29.015	-16.6%	5.4%
6	4	Broadcom	23.868	25.585	7.2%	4.8%
12	5	NVIDIA	15.331	23.983	56.4%	4.5%
4	6	SK hynix	33.505	22,756	-32.1%	4.3%
7	7	AMD	23.620	22.305	-5.6%	4.2%
11	8	STMicroelectronics	15.842	17.057	7.7%	3.2%
9	9	Apple	18.099	17.050	-5.8%	3.2%
8	10	Texas Instruments	18.844	16.537	-12.2%	3.1%

주: 2023년 매출액은 추정치


자료: Gartner(2023. 12b)

2. 전세계 파운드리 현황 및 전망

- 2023년 전세계 반도체 파운드리 시장은 반도체 시장 부진으로 전년 대비 10.8% 감소한 1,164억 달러 규모로 동기간 11.1% 축소된 반도체시장¹⁾ 보다 소폭 낮은 하락률을 기록할 것으로 추정

- 2023년부터 2027년까지 글로벌 파운드리 시장은 연평균 9.8% 증가할 것으로 전망되며, 이는 전체 반도체시장 성장률 9.4%를 소폭 상회하는 수준임

[그림 1-6] 글로벌 파운드리 시장규모 현황 및 전망(2022년~2027년)




주: 매출 기준임

자료: Gartner(2024. 1b)

- 수요 어플리케이션의 경우, 클라우드의 고성능 컴퓨팅 분야가 지난 10년간 수요를 견인한 PC와 스마트폰 분야를 상회하며 시장 성장을 이끌어 갈 것으로 전망
- 2023년 컴퓨팅기기 분야는 전년 대비 성장률은 -7.3%로 통신 및 소비자기기 분야의 각각 -11.5%, -15.3% 보다 낮은 하락률을 기록할 것으로 추정
- 2023년부터 2027년까지 연평균 성장률은 컴퓨팅기기(11.9%)가 소비자기기(7.9%)와 통신기기(7.4%)를 상회할 것으로 예상


1) 파운드리 분야가 제외된 규모임

[그림 1-7] 글로벌 파운드리 수요처별
성장률 추이 및 전망(2022년~2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)


[그림 1-8] 글로벌 파운드리 수요처별 비중
추이 및 전망(2022년~2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)


- 2023년 고객 기준으로는 IDM 분야 매출액이 8.6% 증가했으나, 시장의 2/3을 차지하는 팹리스업체 수요가 전년 대비 14.0% 축소되며 부진 주도

[그림 1-9] 글로벌 파운드리 고객별 성장
률 추이 및 전망(2022년~2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)


[그림 1-10] 글로벌 파운드리 고객별 비중
추이 및 전망(2022년~2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)


- 지역별로는 미국 제재로 자체 생산에 주력한 중국이 2023년 가장 낮은 마이너스 성장률을 기록하며 점유율을 확대한 것으로 추정
- 대만과 우리나라의 시장점유율이 유지되는 가운데 중국은 2023년부터 2027년까지 주요 지역 중 가장 높은 연평균 14.6%의 성장률을 기록하여 점유율은 2022년 11.8%에서 14.0%로 확대될 전망

[그림 1-11] 글로벌 파운드리 지역별 성장률 추이 및 전망 (2022년~2027년)



주: 매출 기준임
자료: Gartner(2024. 1b)

[그림 1-12] 글로벌 파운드리 지역별 비중 추이 및 전망(2022년~2027년)



주: 매출 기준임
자료: Gartner(20241b)

- 업체별 파운드리 매출액 기준, 2022년 글로벌 상위 5개업체 모두 두자릿수 성장률을 기록하였으며 TSMC가 약 60%의 점유율과 가장 높은 증가율로 시장을 선도하는 가운데 나머지 상위 4개 업체는 한 자릿수 점유율로 경쟁열위 구도 지속

〈표 1－3〉 글로벌 상위 5개 파운드리업체 매출액 및 점유율(2021년~2022년)


(단위: 백만 달러)

2021년 순위	2022년 순위	업체명	2021년	2022년	성장률
1	1	TSMC	56,674	75,798	33.7%
2	2	삼성전자	8,537	10,291	20.5%
3	3	UMC	7,606	9,356	23.0%
4	4	GlobalFoundries	6,585	8,108	23.1%
5	5	SMIC	5,443	7,273	33.6%

주: 삼성전자는 내부 거래 제외 규모임

자료: Gartner(2023. 4)

〔그림 1－13〕 글로벌 파운드리업체 점유율 추이(2021년~2022년)



주: 삼성전자는 내부 거래 매출 제외 규모임

자료: Gartner(2023. 4)

제2절 국내외 인공지능 반도체 시장 현황 및 전망

1. 인공지능 반도체 개념²⁾

- AI에 사용되는 DNN과 관련된 알고리즘 및 프로그래밍 모델을 실행하도록 특별히 설계된 장치와 관련된 반도체로 GPU, FPGA, ASIC(NPU), CPU 등이 있음
- － (GPU) 그래픽 처리 장치인 GPU(Graphic Processing Unit)는 그래픽 연산을 빠르게 처리하여 결과값을 모니터에 출력하는 연산장치로 VPU(Visual Processing Unit)이라고도 불림
- GPU는 병렬성이 우수하고 초당 처리할 수 있는 명령어의 수가 많다는 점에서 인공지능 알고리즘 구현 시 높은 성능을 보임
- 계산 효율이 높지만, 내부 메모리 용량이 CPU에 비해 높지 않아 내부 메모리 용량을 초과하는 양의 연산이 이루어져야 할 때 외부 메모리에 접근하는데 드는 시간이 많이 소요되어 효율이 급격하게 감소할 수 있음
- 최근까지도 인공지능 학습 구현을 위한 하드웨어로 GPU가 가장 많이 활용되고 있음
- NVIDIA가 가장 높은 GPU 시장점유율을 기록하고 있으며, Intel, ARM, AMD 등 전통적인 CPU 주력 기업들도 자사의 GPU를 개발하여 CPU-GPU 및 관련 소프트웨어가 모두 통합된 제품군을 제공하고 있음
- － (FPGA) FPGA(Field Programmable Gate Array)는 설계 가능 논리소자와 프로그래밍이 가능한 내부 회로가 포함된 반도체 소자
- 재설계가 가능하여 한 번 디자인한 후에도 수정을 거쳐 재설계할 수 있어 프로토타입 제작용이나 ASIC 설계 테스트용으로 사용될 수 있다는 장점이 있음
- 인공지능 모델은 application마다 구조가 달라 각각의 최적화된 하드웨어 구조 역시 다르다는 사실을 고려한다면 FPGA가 다양한 인공지능 모델에 적합한 하드웨어일 수 있음
- 높은 단위 시간당 처리량과 낮은 latency, 제작에 소요되는 시간과 비용이 낮고 전력효율이 높아 많은 기업에서 꾸준히 개발을 진행하고 있음


2) 윤성욱 외(2021)

- 대표적인 기업으로는 Xilinx, Intel, Microsoft가 있음
- (ASIC) 특정 용도용 집적회로인 ASIC(Application-Specific Integrated Circuit)는 범용 용도가 아닌 특정 용도에 맞게 맞춤 제작된 반도체로 이때 application을 인공지능으로 두어 설계된 회로를 일반적으로 NPU(Neural Processing Unit)로 지칭함
- 인공지능 구현에 많이 활용되는 GPU의 원래 목적이 인공지능 관련 연산 수행이 아니었기 때문에 면적, 전력효율, 수행 시간 면에서 인공지능 구현에 최적화가 되어있지 않음
- 이를 해결하기 위해 제작에 많은 시간과 비용이 소요됨에도 불구하고 글로벌 IT 기업을 포함한 많은 기업이 인공지능용 ASIC인 NPU 개발에 힘쓰고 있음
- 대표적인 NPU 개발 기업으로는 Google, Tesla, Amazon, GraphCore, ARM, Intel, Habana Labs(Intel), Cerebras 등이 있음
- (CPU) 중앙 처리 장치인 CPU(Central Processing Unit)은 범용 컴퓨팅 시스템을 통제하고, 프로그램의 연산을 실행·처리하는 가장 핵심적인 컴퓨터의 제어장치
- CPU는 GPU보다 코어당 성능은 우수하지만 병렬처리의 한계가 존재한다는 이유로 인공지능 반도체로 분류하지 않는 경우도 존재
- 하지만 가격이 저렴하고, 내부 메모리 용량이 높고, 모든 device에 포함되어 있으므로 접근성이 높다는 점에서 인공지능 알고리즘을 구동할 하드웨어에서 주요한 역할을 수행
- 대표적 CPU 설계 기업인 Intel, ARM, AMD는 각 사의 주력 제품인 CPU의 성능을 지속적으로 개선하여 deep learning 구동용 solution을 개발

2. 전세계 인공지능 반도체 시장 현황 및 전망

- 2023년 글로벌 인공지능 반도체 시장은 전체 반도체시장 부진에도 불구하고 생성형 AI로 촉발된 AI서비스 확산으로 전년 대비 23.3% 증가한 약 523억 달러로 추정되며, 2023년부터 2027년까지 연평균 27.9%의 고성장을 지속할 것으로 전망
- 이에 따라 전체 반도체시장에서 인공지능 반도체시장이 차지하는 비중은 2022년 7.1%에서 2023년 9.8%로 증가한 것으로 추정되며, 2027년에는 2023년의 약 두배인 18.3%까지 확대될 것으로 전망


[그림 1-14] 글로벌 AI 반도체 시장 현황 및 전망(2022년~2027년)



주: 매출 기준임

자료: Gartner(2023. 12c)

[그림 1-15] 글로벌 AI 반도체 시장이 글로벌 반도체 시장에서 차지하는 비중 추이 및 전망(2022년~2027년)



주: 매출 기준임

자료: Gartner(2023. 12c)

- 수요 어플리케이션별 글로벌 인공지능 반도체 시장을 살펴보면 2022년 기준 60% 넘는 점유율로 수요를 이끌던 통신기기를 컴퓨팅기기 분야가 빠르게 대체하여 2027년 전

체 시장의 50%를 상회할 것으로 전망

- 2023년 전년 대비 통신기기만 -9.3% 마이너스 성장하고 저장기기(143.5%), 산업기기(126.2%), 소비자기기(95.1%), 컴퓨팅기기(90.5%), 자동차(40.5%) 순으로 높은 성장률을 기록할 것으로 추정
- 2023년부터 2027년까지 통신기기와 컴퓨팅기기는 각각 연평균 10.7%, 39.9% 성장하며 전체 AI시장에서 차지하는 비중은 각각 2022년 63.3%, 24.3%에서 2027년 26.2%, 53.9%로 전환될 것으로 전망


〈표 1-4〉 수요 분야별 AI 반도체 시장 현황 및 전망(2022년~2027년)

(단위: 백만 달러)

분야		2022년	2023년	2024년	2025년	2026년	2027년	2023년~ 2027년 CAGR
자동차 (Automotive Electronics)	매출규모	3,921	5,507	7,594	10,370	12,740	14,626	27.7%
	성장률	38.0%	40.5%	37.9%	36.5%	22.9%	14.8%	
통신기기 (Communications Electronics)	매출규모	26,890	24,391	28,293	31,239	33,648	36,658	10.7%
	성장률	24.0%	-9.3%	16.0%	10.4%	7.7%	8.9%	
컴퓨팅기기 (Compute Electronics)	매출규모	10,320	19,657	27,294	38,374	56,119	75,320	39.9%
	성장률	32.8%	90.5%	38.9%	40.6%	46.2%	34.2%	
소비자기기 (Consumer Electronics)	매출규모	700	1,366	1,946	2,782	4,183	6,633	48.4%
	성장률	159.8%	95.1%	42.5%	42.9%	50.4%	58.6%	
산업 기기 (Industrial Electronics)	매출규모	603	1,365	2,209	3,482	5,012	6,286	46.5%
	성장률	152.9%	126.2%	61.9%	57.6%	43.9%	25.4%	
저장 기기 (Storage Electronics)	매출규모	16	39	80	122	191	302	67.2%
	성장률	140.7%	143.5%	108.0%	51.5%	56.9%	57.9%	
전체	매출규모	42,451	52,325	67,418	86,369	111,894	139,825	27.9%

자료: Gartner(2023. 12c)

[그림 1-16] 글로벌 AI 반도체 시장의 수요처별 비중 추이 및 전망(2022년~2027년)



자료: Gartner(2023. 12c)

- 품목별로는 2022년 기준 개별 애플리케이션/멀티미디어 프로세서(Discrete Application/Multimedia Processor)와 통합 베이스밴드/멀티미디어 프로세서(Integrated Baseband/Application Processor)가 AI반도체 시장을 양분하고 있었으나, 향후 마이크로프로세서(컴퓨팅)(Microprocessor, Compute)가 높은 수요로 시장을 견인할 것으로 예상
 - － 마이크로프로세서(컴퓨팅)는 2023년부터 2027년까지 연평균 166.8% 증가하여 전체 AI반도체 시장에서 차지하는 비중은 2022년 0.9%에서 2027년 28.9%로 대폭 확대
 - － 이는 2027년 개별 애플리케이션/멀티미디어 프로세서의 점유율(27.7%)을 추월한 것으로 품목 중 가장 큰 비중임

〈표 1－5〉 AI 반도체 종류별 시장 현황 및 전망(2022년~2027년)


(단위: 백만 달러, %)

분야		2022년	2023년	2024년	2025년	2026년	2027년	2023년~ 2027년 CAGR
Digital Signal Processor	매출규모	35	73	104	163	235	370	50.0%
	성장률	137.5%	107.8%	41.9%	56.7%	44.5%	57.6%	
Discrete Application/ Multimedia Processor	매출규모	17,602	19,886	23,612	29,017	34,303	38,771	18.2%
	성장률	20.2%	13.0%	18.7%	22.9%	18.2%	13.0%	
Discrete Graphics Processing Unit	매출규모	5,546	13,689	16,363	18,558	20,369	22,676	13.4%
	성장률	15.8%	146.8%	19.5%	13.4%	9.8%	11.3%	
FPGA	매출규모	404	764	1,236	1,688	2,233	2,630	36.2%
	성장률	105.8%	89.0%	61.7%	36.5%	32.3%	17.7%	
Integrated Baseband/Application Processor	매출규모	17,352	14,431	17,252	18,779	20,312	22,093	11.2%
	성장률	40.3%	-16.8%	19.5%	8.8%	8.2%	8.8%	
Microcontroller 32-bit	매출규모	105	210	278	464	708	894	43.7%
	성장률	135.4%	99.1%	32.4%	67.2%	52.5%	26.2%	
Microprocessor - Compute	매출규모	97	798	4,469	11,678	25,331	40,429	166.8%
	성장률	13,346.3%	726.3%	459.9%	161.3%	116.9%	59.6%	
Microprocessor - Embedded	매출규모	196	313	497	729	1,005	1,324	43.5%
	성장률	110.6%	59.9%	58.9%	46.7%	37.8%	31.8%	
기타	매출규모	1,113	2,162	3,607	5,293	7,397	10,639	48.9%
	성장률	69.8%	94.2%	66.9%	46.7%	39.8%	43.8%	

주: 매출 기준임

자료: Gartner(2023. 12c)

[그림 1-17] 글로벌 AI 반도체 시장의 품목별 비중 추이 및 전망(2022년 ~2027년)



주: 매출 기준임

자료: Gartner(2023. 12c)


제2장 AI 반도체 선도기업 기술 동향 및 혁신전략

제1절 인공지능 반도체 기술 개요

- 인공지능 알고리즘을 구동할 수 있는 프로세싱 유닛의 타입은 CPU, GPU, APU, FPGA, ASIC으로 구분할 수 있음
- CPU(중앙 처리 장치)
 - CPU는 GPU보다 코어당 성능은 우수하지만 병렬 처리의 한계성이 존재한다는 이유로 인공지능 반도체로서의 중요성이 두드러지지 않는 면이 있음
 - 하지만, 가격이 저렴하다는 점과 내부 메모리 용량이 높다는 점(수백 기가바이트), 그리고 모든 device에 포함되어 있으므로 접근성이 높다는 점에서 인공지능 알고리즘을 구동할 HW에서 빼놓을 수 없는 주요한 항목
 - 제한된 연산만을 지원하는 다른 가속기 프로세서와 비교하면 다양하고 복잡한 연산이 가능하다는 점에서 높은 활용성을 보임
 - 대표적 CPU 설계 기업인 Intel, ARM, AMD는 각 사의 주력 제품인 CPU의 성능을 지속해서 개선하여 딥러닝 워크로드 구동용 solution을 개발
- GPU(그래픽 처리 장치)
 - GPU는 병렬성이 우수하고 초당 처리할 수 있는 명령어의 수가 더 많다는 점에서 인공지능 알고리즘 구현에 있어 높은 성능을 보여온 반도체
 - 특히 인공지능 학습 구현은 최근까지도 GPU의 활용이 가장 높은 비율로 이루어지고 있음
 - 계산 효율이 높지만, 내부 메모리 용량이 CPU에 비해 높지 않아(수십 기가바이트) 내부 메모리 용량을 초과하는 양의 연산이 이루어져야 할 때 외부 메모리에 접근하는데 드는 시간이 많이 소요되어 효율이 급격하게 감소할 수 있음

- NVIDIA가 가장 높은 GPU 시장 비율을 차지하지만, Intel, ARM, AMD 등 전통적인 CPU 주력 기업들도 자사의 GPU를 개발하여 CPU-GPU 및 관련 SW가 모두 통합된 제품군을 제공하고 있음

[그림 2-1] NVIDIA vs AMD vs Intel의 데이터 센터 구축 수익 비교




자료: Visualcapitalist(2023. 8. 25.),

□ APU(가속 처리 장치)

- Accelerated processing unit(APU)는 CPU와 GPU, 그리고 메모리 컨트롤러를 단일 컴퓨터 칩에 집적하여 연산을 가속하는 마이크로프로세서 타입
- AMD의 fusion project에서 처음으로 시도된 프로세싱 유닛 타입이며 AMD의 첫 APU는 2011년 1월에 출시(Denis et al., 2011)
- 같은 해 Intel도 Sandy Bridge라는 코드네임으로 APU를 런칭하였으며 NVIDIA는 Project Denver라는 코드네임으로 자사의 APU를 런칭
- 두 프로세싱 유닛이 하나의 칩에 집적되면서 리소스를 공유할 수 있게 되고, 그 때문에 데이터 전송 속도가 빠르고 전력 소모가 낮다는 장점이 있음
- 하지만, 두 프로세싱 유닛을 하나의 칩에 집적하므로 설계 및 집적이 매우 복잡하다는 어려움이 있으며 두 유닛이 일반적으로 공통의 메모리에 접근하므로 메모리 대역폭의 제한이 있다는 특징이 있음
- 위의 설계적 어려움을 해결하기 위하여 칩렛 기반의 첨단 이중 집적 기술을 이용하며 제작하는 경향이 있으며, 메모리 대역폭을 늘리기 위하여 HBM을 적재하는 연구 움직임이 존재

[그림 2-2] 전 세계 APU 시장 매출규모



자료: Statista(2024)

□ FPGA(필드 프로그래머블 게이트 어레이)

- FPGA는 디자인을 reprogram 가능하여 한 번 디자인한 후에도 수정을 거쳐 재설계할 수 있어 프로토타입 제작용이나 ASIC 설계 테스트용으로든 사용하기에 장점이 있음
- 인공지능 모델은 application마다 구조가 달라 각각의 최적화된 하드웨어 구조 역시 다르다는 사실을 고려한다면 FPGA가 다양한 인공지능 모델에 적합한 하드웨어를 설계해볼 수 있다는 장점이 있음
- FPGA는 일반적으로 높은 단위 시간당 처리량과 낮은 latency뿐만 아니라 제작에 드는 가격과 시간이 짧고 power 효율이 높아 다양한 기업에서 꾸준히 개발을 진행하고 있음
- 2015년 Intel은 FPGA 세계 2위 기업인 Altera를 인수하였고, 2020년 10월 AMD는 FPGA 세계 1위 기업인 Xilinx 인수에 착수한 후 2022년 2월 500억 달러 규모의 Xilinx를 인수


□ ASIC(특정 용도용 집적 회로)

- ASIC은 용도에 특화된 회로를 의미하는 것으로, 이때 application을 인공지능으로 두어 설계된 회로를 일반적으로 NPU로 지칭함
- GPU의 원래 목적이 인공지능 관련 연산 수행이 아니었기 때문에 면적, 전력, 수행 시간 면에서 최적화되지 않은 여러 문제를 가짐
- 이를 해결하기 위하여 높은 제작 비용 및 시간에도 불구하고 대기업과 스타트업을 포함한 많은 기업이 인공지능용 ASIC인 NPU 개발에 힘쓰고 있음
- 대표적인 NPU 개발 기업으로는 Google, Tesla, Amazon, ARM, Intel, Habana Labs(Intel)와 같은 대기업과 SambaNova Systems, Cerebras Systems, Graphcore, Groq, Tenstorrent와 같은 신생 기업들이 있음

제2절 AI 반도체 선도기업 기술 동향

- 최근 ChatGPT와 같은 거대언어모델이 활발하게 개발되고 다양한 분야에서의 활용을 보임에 따라 인공지능 반도체의 개발 방향도 이와 같은 거대모델을 처리하기 위한 방향으로 설정되고 있음(Zhao et al., 2023)

[그림 2-3] 최근 개발된 10B 이상 크기의 대규모 언어모델(음영: 코드공개)



자료: Zhao et al.,(2023), A survey of large language models. arXiv preprint arXiv:2023.18223.

- 주로 Intel, AMD, NVIDIA과 같은 인공지능 반도체 대기업은 클라우드 서버형 컴퓨팅 유닛을 중심으로 활발하게 개발하고 있으며, Tenstorrent, Hailo, DeepX와 같은 스타트업 기업들이 엣지 기기 전용 가속기를 개발
- 클라우드 서버형 컴퓨팅 유닛은 거대 모델의 추론 및 학습, 그리고 필요할 시 엣지 디바이스와의 통신을 통한 데이터 전송 등을 담당하며, 엣지 컴퓨팅은 경량화된 거대 모델 혹은 기존의 딥러닝 모델의 추론을 제한된 디바이스의 컴퓨팅 자원을 이용하여 수행하는 역할을 담당

- 본 절에서는 인공지능 반도체의 프로세싱 유닛 타입에 따른 분류와 함께 선도기업 및 해당 기업의 팔목할 만한 기술 동향을 조사
- <표 2-1>에서는 프로세싱 유닛 타입을 CPU, GPU, APU, FPGA, ASIC으로 나누고, 타입 별 글로벌 인공지능 반도체 선도기업 및 해당 기업의 최신 인공지능용 하드웨어 제품명과 각 제품군의 사용 목적에 관해 기술

〈표 2-1〉 프로세싱 유닛 타입에 따른 인공지능 반도체 선도기업과 대표 제품

프로세싱 유닛 타입	기업	제품명
CPU	Intel	Xeon Scalable Processors
		Max Series Processors
	AMD	Ryzen 7040
	ARM	Cortex-X4
GPU	NVIDIA	H100
	AMD	Instinct MI300X
	ARM	G720
APU (CPU+GPU)	NVIDIA	GH200
	AMD	Instinct MI300A
FPGA	AMD-Xilinx	Alveo
	SambaNova	Reconfigurable Dataflow Unit(RDU)
	Intel	Intel Agilex
	Google	TPU v5e
ASIC (NPU)	Intel-Habana Labs	Gaudi3
	Cerebras	WSE-2
	GraphCore	Bow IPU
	Groq	GroqChip
	Tenstorrent	Grayskull
	IBM	NorthPole
	Kneron	KL730
	DeepX	DX-M1
	Hailo	Hailo-15


자료: 저자정리

1. 중앙 처리 장치(CPU, Central Processing Unit)

□ Intel

- 인텔은 인공지능 워크로드 수행을 위해 가속기를 내장한 Intel Xeon Scalable Processor 라인과 Intel Xeon Max Series Processor를 출시해오고 있음
- Intel Xeon Scalable Processor는 cloud용 AI 연산 처리에 최적화된 하드웨어를 제공함과 동시에, 유연한 성능 달성을 목표
 - 유연한 성능 달성이란, 다양한 core 개수, 동작 frequency, power level을 제공함으로써 클라우드, 슈퍼컴퓨터뿐만 아니라 IoT 등 에지 기기에도 이용될 수 있도록 하는 것을 의미
- 4세대 Xeon Scalable Processor
 - 2023년 1월 인텔 7공정을 사용한 4세대 Xeon Scalable Processor가 출시되었으며 당시 시장에 출시된 CPU 중 가장 많은 12개의 가속기 유닛을 내장(Intel, 2023)
 - 고성능 CPU이므로 AI 워크로드 및 데이터 분석에 활용될 수 있을 뿐만 아니라 HPC에도 활용될 수 있음
 - 최대 코어 수가 60개이며 DDR5 RDIMM 메모리를 탑재하고 PCIe를 5세대로 업그레이드 하여 장착
 - Intel Advanced Matrix Extensions(AMX)라는 인공지능에 특화된 instruction set architecture(ISA)를 개발 및 활용(Abirami et al., 2023)
 - 전 세대와 대비하여 목표 워크로드 처리에 평균 2.9배 높은 와트당 성능을 보였으며 전력 최적화 모드를 활용할 시 성능 손실 없이 최대 70W 낮은 전력으로 구동 가능

[그림 2-4] 4세대 Intel Xeon Scalable Processor




자료: Intel 웹페이지

○ Intel Xeon CPU Max Series

- 기계학습 혹은 다양한 분야에 활용될 수 있는 HPC용 프로세서
- 최초로 x86 기반 CPU에 패키지당 64GB HBM2E를 내장하여 메모리 대역폭을 최대화
- 최대 56개 코어를 포함하고 있어 코어당 1GB 이상의 HBM 용량을 활용할 수 있다는 장점
- 인텔이 자체적으로 개발한 차세대 패키징 기술인 embedded multi-die interconnect bridge(EMIB) 기술을 활용하여 CPU와 메모리를 한 패키지로 묶어 코어와 메모리 간 병목현상을 줄임(Mahajan et al., 2016)
- Xeon Scalable Processor와 마찬가지로 Intel의 AMX를 활용하였으며 AMD EPYC 7R13 2개와 비교하여 거대모델 BERT-Large를 추론할 때 최대 20배 빠른 처리 성능을 달성

[그림 2-5] HBM을 장착한 AI/HPC용 Intel CPU, Intel Max Series Processor



자료: Intel 웹페이지

□ AMD

○ Ryzen 7040 Series

- 2023년 1월 TSMC 4nm FinFET 공정으로 제조된 Ryzen 7040 Series를 공개하였으며 LPDDR5x를 탑재하고 PCIe 4.0을 지원(Subramon et al., 2023)
- 시리즈 중 일부 모델은 Ryzen AI인 AMD XDNA AI 엔진이 탑재
- XDNA AI 엔진은 edge와 클라우드까지 모두 활용 가능한 높은 configurability를 가지는 아키텍처
- 뿐만 아니라, XDNA AI 엔진은 2D AI 엔진 타일로 구성되어 있고, 디바이스 당 수십 혹은 수백 개의 AI 엔진 타일로 구성할 수 있어 높은 scalability를 가짐
- 각 AI 엔진 타일은 기계학습에 특화된 VLIW, SIMD vector processor로 구성되어 있으며 각 AI 엔진 프로세서는 1.3 GHz까지 구동 가능
- 각 엔진 타일은 프로그램 메모리와 데이터 메모리를 포함하고 있어 프로세서가 구동할 명령어와 연산 시 사용할 데이터를 모두 저장할 수 있음
- Ryzen 9 7940HS 칩을 탑재한 Asus Strix Scar 17 노트북을 플랫폼으로 시연하였을 때, Intel Core i9-13900H Raptor Lake보다 모든 벤치마크에 대하여 6%에서 41%의 성능 향상을 보임

- Apple M2 칩의 Neural Engine과 비교하였을 때는 모든 벤치마크에 대하여 1%에서 11%의 성능 향상을 보임

[그림 2-6] AMD의 XDNA AI 엔진 개념도



자료: AMD웹페이지

2. 그래픽 처리 장치(GPU, Graphics Processing Unit)

□ NVIDIA

- NVIDIA는 AI 반도체로서의 가장 높은 점유율과 입지를 다지고 있는 GPU 선도기업
- 세계적인 클라우드 컴퓨팅 환경 제공 업체인 Amazon의 AWS와 Microsoft의 Azure는 NVIDIA의 GPU를 활용하여 컴퓨팅 환경을 구성하였다고 알려져 있음


〈표 2-2〉 Amazon AWS의 인스턴스별 GPU 환경

Amazon EC2 P3	8 NVIDIA Tesla V100 GPUs
Amazon EC2 P4	8 NVIDIA Tesla A100 GPUs.
Amazon EC2 G3	4 NVIDIA Tesla M60 GPUs.
Amazon EC2 G4	4 NVIDIA T4 GPUs.
Amazon EC2 G5	8 NVIDIA A10G GPUs.

자료: Amazon 웹페이지

- Google도 Next23에서 NVIDIA와 협력하여 H100을 탑재한 슈퍼컴퓨터 A3VMs를 출시한다고 밝힘
- H100
 - GTC 2022에서 Hopper 아키텍처를 사용한 H100 GPU를 공개(Elster et al., 2022)
 - H100 GPU 출시는 PCIe와 SXM5 두 개의 폼팩터를 제공
 - PCIe는 일반적인 PC의 마더보드 PCIe 슬롯에 장착하는 방법으로 탈부착 및 설치가 간단
 - SXM5는 특화된 하드웨어와 커넥터가 필요하지만 NVSwitch를 활용하여 더 높은 성능과 multi-node 설치 용도로 적합
 - H100 SXM은 세계 최초로 4.8Gbps HBM3를 채택하였으며 3TB/s의 메모리 대역폭을 달성
 - H100 PCIe는 3.2Gbps HBM2E를 장착하였으며 2TB/s의 메모리 대역폭을 달성
 - H100 SXM은 이전 세대인 A100SXM과 비교하여 2배가 넘는 CUDA core와 528개의 Tensor core를 탑재

[그림 2-7] NVIDIA H100



자료: NVIDIA 웹페이지


- H100은 800억 개에 달하는 트랜지스터를 포함하며 TSMC 4N technology node를 이용하여 생산
- 2023년 5월, 4세대 Xeon과 H100을 활용한 데이터센터용 슈퍼컴퓨터 DGX H100을 출시

□ AMD

○ Instinct MI300X

- AMD는 AMD DCAITP에서 AMD의 CDNA3 GPU 코어를 이용하여 설계된 인공지능 반도체인 Instinct MI300X를 공개(Alok, 2020)
- Instinct MI300X는 24GB HBM3 모듈 8개를 장착하여 총 192GB 메모리 용량과 5.2TB/s의 메모리 대역폭을 가지고 있음
- Instinct MI300X에 탑재되는 HBM3은 삼성전자와 SK하이닉스가 전량 공급할 것으로 예상
- AMD는 CPU 설계부터 적극적으로 활용하던 칩렛 기술을 MI300X에도 적용하여 TSMC 5nm급 공정에서 생산된 12개의 칩렛을 결합
- 칩렛 간 연결은 인피니티 패브릭을 사용하였으며 대역폭은 896GB/s를 달성
- H100보다 2.4배 높은 메모리 밀도와 1.6배 높은 대역폭을 제공하며 마이크로소프트, 오픈 AI, 오라클, 델, 시스코 등 10개사가 MI300X를 채택할 것으로 예정되어 있음
- 2024년 AMD의 AI 반도체 매출 전망은 20억 달러로 예상되었으며, 2023년 12월 AMD가 수주한 MI300 시리즈의 물량은 25~30억 달러 수준으로 전망
- 1,750억 개 파라미터를 가지는 GPT3도 5개의 MI300X를 이용하면 모든 파라미터를 저장할 수 있다는 점을 강조

〔그림 2-8〕 AMD Instinct MI300X의 아키텍처 구조도



자료: ascii 웹페이지


3. 가속 처리 장치(APU, Accelerated Processing Unit)

□ AMD

- AMD는 CPU와 GPU를 결합한 APU의 첫 번째 세대를 Llano라는 이름으로 2011년에 출시
- 이후 2012년 2세대인 고성능 라인 Trinity와 저전력 라인 Brazos-2 출시를 시작으로 현재까지 꾸준히 APU 제품을 생산
- MI300A
 - － MI300X를 공개하기 약 반년 전 1월 CES 2023에서 AMD는 MI300A를 공개하였으며 MI300A는 MI300X의 8개의 GPU 칩셋 중 두 개를 세 개의 CPU 칩셋으로 바꾼 새로운 APU
 - － Zen4 CPU 코어 24개와 CDNA3 아키텍처 기반의 GPU, 그리고 128GB의 HBM3를 탑재
 - － TSMC 5nm를 이용하여 제작되었으며 1,460억 개의 트랜지스터를 탑재하고 있음
 - － MI300X와 마찬가지로 칩셋 기반의 디자인이므로 최첨단 패키징 기술이 요구되며

AMD는 3.5D 패키징으로 명명하고 substrate 위에 인터포저, I/O 칩렛, GPU 칩렛 (XCD) 및 CPU 칩렛(CCD)를 차례로 집적하여 패키징

[그림 2-9] AMD Instinct MI300A의 아키텍처 구조도




자료: ascii 웹페이지

□ NVIDIA

○ GH200

- 2023년 5월, ARM 기반 NVIDIA 그레이스 CPU와 호퍼 GPU 아키텍처를 결합하여 하나의 칩에 집적한 GH200 그레이스 호퍼 슈퍼칩의 정보를 공개
- CPU 메모리는 최대 480GB의 LPDDR5X이며 GPU는 7배 빠른 메모리인 HBM3 94GB 또는 8배 빠른 메모리인 HBM3E 144GB에 연결되어 있음
- NVIDIA의 NVLink 기술을 칩 간 상호 연결로 확장한 NVLink-C2C 인터커넥트 기술을 활용하면 256개의 GPU가 연결되어 단일의 GPU인 듯 기능하며 이를 이용하면 총 1엑사플롭스의 성능과 144테라바이트의 공유 메모리를 제공할 수 있음 (Ying et al., 2023)
- NVLink 기술은 최대 900GB/s의 총대역폭을 제공하며 이는 PCIe Gen5 레인보다 7배 높은 대역폭 성능

[그림 2-10] 그레이스 호퍼 슈퍼칩(GH200)의 구조도



자료: NVIDIA 웹페이지(NVIDIA Grace Hopper Superchip Data Sheet)

4. 필드 프로그래머블 게이트 어레이(FPGA, Field Programmable Gate Array)

□ Xilinx

○ Xilinx Alveo Family

- Xilinx는 다양한 application에 적용할 수 있는 data center 워크로드 용 가속기 카드인 Alveo를 출시해오고 있음
- Alveo 카드 라인업에 따라 개발할 인공지능 반도체의 사이즈를 결정하는 LUT 크기, HBM 탑재의 여부, memory 용량, 대역폭, 파워 등이 다양하므로 표적으로 하는 인공지능 애플리케이션 워크로드에 따라 적합한 카드를 선택하여 FPGA 개발을 수행할 수 있음

〈표 2-3〉 Xilinx Alveo Family 라인업

구분	Alveo U50	Alveo U55C	Alveo U200	Alveo U250	Alveo U280
LUTs	872k	1304k	892k	1341k	1079k
Dimensions	Single Slot Half Height	Single Slot Full Height	Dual Slot Full Height	Dual Slot Full Height	Dual Slot Full Height
Memory	8GB HBM2 316 GB/s	16GB HBM2 460 GB/s	64GB DDR 77GB/s	64GB DDR 77GB/s	8GB HBM2 460GB/s
Physical Interface	PCIe Gen3x16, Gen4x8, CCIX	PCIe Gen3x16, Gen4x8	PCIe Gen3x16	PCIe Gen3x16	PCIe Gen4x8 with CCIX
Power	<75W	<150W	<225W	<225W	<225W

자료: NVIDIA 웹페이지(NVIDIA Grace Hopper Superchip Data Sheet)

- 여러 카드를 PCIe로 서버에 설치하여 병렬 구동이 가능하므로 데이터센터 및 클라우드 컴퓨팅 애플리케이션에도 적합
- 인공지능 반도체 설계에 필수적인 하드웨어와 상호작용하는 소프트웨어인 runtime을 Xilinx Runtime(XRT) 라는 이름으로 제공
- XRT를 통하여 개발자들은 메모리를 할당하고 이동할 때 등 다수의 소프트웨어 기능을 함께 제공받을 수 있음
- FPGA 설계에 하드웨어 설계에 대한 높은 배경 지식을 요구하므로 Xilinx는 AMD Vivado 및 AMD Vitis라는 두 가지 개발 플랫폼을 제공함으로써 하드웨어 및 소프트웨어 개발을 용이하게 함
- Vivado는 전통적인 FPGA 개발자를 위해 design suite를 제공하며 Vitis는 설계자가 C, C++, OpenCL을 활용하여 하드웨어를 디자인할 수 있도록 소프트웨어 플랫폼을 제공

[그림 2-11] Xilinx Alveo U280




자료: AMD웹페이지

□ Sambanova

- Sambanova는 reconfigurable 로직을 활용한 고유의 아키텍처인 reconfigurable dataflow unit 아키텍처(RDA)를 활용하여 인공지능 반도체를 개발하는 스타트업 기업
- FPGA는 개발이 복잡하고 수준급의 low-level 프로그래밍을 필요로 하며 매우 긴 컴파일 타임을 소모한다는 단점이 있지만, RDA는 경량화된 프로그래밍을 통하여 configuration에 수십 마이크로초만을 소요
- Sambanova는 2023년 기준 AI chip maker 중 가장 많은 펀딩을 수주한 스타트업으로 꼽힘(Sambanova Systems, 2021)
- Sambanova는 2023년 2월 ChatGPT와 같은 Generative AI의 성공을 배경으로 삼아 “Sambanova suite for generative AI”라는 슬로건을 내세우며 차기 AI 칩 개발에 박차를 가함

[그림 2-12] 투자 수주액으로 나열한 상위 5개 AI Chip maker 및 Sambanova의 SL40L



자료: Reuters(2021. 11. 11.)

○ SN40L

- 2023년 9월 Sambanova는 5조 개의 파라미터를 저장할 수 있는 새로운 칩 SN40L을 발표
- SN40L은 TSMC 5나노 공정을 사용하여 제작되었으며 각 칩은 1,040개 코어를 가지고 있으며 1,020억 개 트랜지스터를 포함
- 메모리 중심 컴퓨팅인 거대언어모델을 처리하기 위하여 세 단계의 메모리 계층을 추가하여 차별화를 두었음
- 먼저 520MB의 온 칩 메모리가 탑재되었으며 1.5TB의 외부 메모리, 그리고 64GB의 HBM을 추가 탑재
- NVIDIA H100(80GB HBM)과 AMD MI300X(192GB HBM)보다는 적은 용량을 탑재하였지만 세 개의 메모리 층 사이에 발생하는 부하를 분할하여 처리하도록 하는 자체 소프트웨어 컴파일러를 개발

5. 특정 용도용 집적 회로(ASIC, Application-Specific Integrated Circuit)


□ Google

○ TPU v5e

- 2023년 8월, 구글은 TPU의 후속 버전인 Cloud TPU v5e를 발표


- 거대언어모델의 크기가 지난 5년 동안 매년 10배씩 증가하는 추세이므로 이에 대응하기 위한 방향으로 TPU 개발 방향이 설정
- TPU v4와 비교하여 학습 성능은 가격당 2배, 추론 성능은 가격당 2.5배를 달성
- TPU v5의 주요한 장점 중 하나는 인터커넥트로, 여러 TPU v5 칩을 연결하여 동작할 수 있는 scalability를 위하여 multislice 기술을 새롭게 개발
- 이전에는 한 슬라이스의 TPU만 사용하는 것으로 제한되어 최대 슬라이스 크기가 3,072개의 TPU v4칩으로 한정
- Multislice 기술을 이용하면 하나의 pod에 수만 개의 chip을 inter-chip interconnect (ICI)를 통하여 연결할 수 있게 되었으며 여러 개의 pod는 data center network(DCN)을 통하여 연결

[그림 2-13] Google TPU v5e AI 보드



자료: STH(2023. 11. 14)

[그림 2-14] Google의 multislice 기술도



자료: GoogleCloud(2023. 9. 1.)


□ Intel-Habana Labs

- 2019년 인텔은 인공지능 반도체 가속기 기업인 Habana Labs를 20억 달러에 인수하였으며 2022년에 Gaudi2를 출시하였으며 2023년 Gaudi3의 시제품을 공개하고 출시 예정임을 밝힘
- Gaudi2(Habana Labs, 2022)
 - 2022년 5월, 인텔은 TSMC 7nm 공정으로 제작되었으며 HBM2E 6개를 탑재한 Gaudi2를 발표
 - 경쟁사 제품인 NVIDIA의 H100보다 3배 이상의 가성비를 가지고 있고 제품 공급 측면에서도 NVIDIA 대비 빠른 공급이 가능하여 리드 타임(반도체 상품의 주문 일시와 인도 일시 사이의 경과 시간) 면에서 우수하다는 점을 강조
 - Gaudi2의 컴퓨팅 아키텍처는 프로그래머블한 tensor processor core(TPC)와 matrix multiplication engine(MME)로 구성되어 있음
 - TPC는 VLIW SIMD 프로세서로 MME에서 가속할 수 있는 operator들을 제외한 모든 operation를 가속하는 데 사용
 - MME에서 가속할 수 있는 operator는 matrix의 곱으로 lowering 가능한 모든 operator를 포함하며 fully connected layer, convolution, GEMM과 같은 연산자가

이에 속함

- DMA 엔진은 tensor shape을 변형하는 데 사용되며 transformation 엔진과 coupled 되어있음
- Gaudi2의 네트워킹 아키텍처는 24개의 100Gbps RoCE V2 RDMA NICs를 통해 2.4Tb/s의 네트워킹 대역폭을 달성하였으며 Gaudi2간의 커뮤니케이션은 direct routing 혹은 표준 이더넷 스위칭을 사용
- Gaudi2의 메모리 시스템은 6개의 HBM2E가 총 96GB의 메모리 용량을 제공하며 48MB의 로컬 SRAM이 함께 탑재되어 있음

[그림 2-15] Habana Labs의 Gaudi12 제품 사진 및 아키텍처



자료: habana(2022. 6)

○ Gaudi3

- 2023년 12월, 인텔은 TSMC 5nm 노드로 제작된 Gaudi3의 시제품을 공개하고 2024년 출시할 것임을 밝힘(Kif Leswing, 2023)
- Gaudi2 대비 BF16 자료형을 처리하는 데 처리 속도가 4배 향상되었으며 HBM 탑재 용량을 1.5배 늘려 거대언어모델 처리를 목표로 함
- HBM3 또는 HBM3E를 탑재할 것으로 예상되어 메모리 용량뿐만 아니라 메모리 대역폭 및 전송 속도의 향상을 기대할 수 있음

[그림 2-16] Gaudi2와 비교한 Gaudi3의 specification



자료: wccftech(2023. 12. 18)

□ GraphCore

○ Bow IPU

- 2022년 3월 GraphCore는 3세대 intelligent processing unit(IPU)인 Bow IPU를 출시
- Bow IPU는 이전 세대와 마찬가지로 1GB의 on-chip SRAM을 포함하지만 40% 빠른 access가 가능해져 65Tb/s 속도로 접근할 수 있음
- 또한, 이전 세대와 마찬가지로 1,472개의 IPU tile을 포함하고 있으며 각각 6개의 독립적인 프로그램 수행이 가능
- 각 IPU tile은 8,832개의 병렬적으로 수행 가능한 프로그램 스레드를 가진 IPU-Core와 900MB의 In-Processor-Memory를 포함하고 있음
- 10개의 IPU는 IPU-Link로 연결되어 320GB/s의 대역폭으로 chip 간 통신이 가능
- Bow IPU는 mixed-precision 연산에 대해 peak 350TFLOPS를 달성하였으며 FP32 연산에 대해서는 peak 87.5TFlops를 달성
- Bow IPU는 4개가 패키징 되어 Bow-2000 IPU 머신을 구성하며 Bow-2000은 4개가 패키징 되어 Bow Pod16을 구성하고, Bow Pod16은 256개가 패키징 되어 Bow Pod1024를 구성

- Bow-2000은 FP32 연산 기준 peak 350TFLOPS, Bow Pod16은 peak 1.4PFLOPS, 그리고 Bow Pod1024는 peak 89.6 PFLOPS를 달성


[그림 2-17] GraphCore의 Bow IPU(좌측) 및 Bow-2000(우측)



자료: GraphCore웹페이지

- GraphCore의 Bow IPU에서 주목할 점은, TSMC 7nm 공정으로 제작되었으며 TSMC의 3D wafer-on-wafer(WoW) 패키징 기술을 활용하였다는 점임(TSMC, 2023)
- WoW는 더 높은 die 간 interconnect density를 제공하는 패키징 기술
- 특히 상단의 wafer는 많은 수의 deep-trench capacitor cell을 가지고 있어 더 원활한 power delivery를 제공하여 더 빠르고, 더 높은 voltage에서 동작할 수 있다는 장점이 있음
- 이와 같은 차세대 패키징 기술을 활용하여 Bow IPU는 이전 세대보다 전반적인 AI 워크로드에 대해 40%까지의 성능 향상을 보임
- 특히, object detection 워크로드에 대해 29%, NLP 및 이미지 분류 워크로드에 대해 39%의 성능 향상을 보였으며 이전 세대와 비교하면 16%의 전력 효율을 달성

[그림 2-18] IPU 및 Bow IPU의 구조 및 Chip 사진




자료: GraphCore 웹사이트

□ IBM

○ NorthPole

- 2023년 10월, IBM은 뇌의 연산 방법에서 영감을 얻은 인공지능 가속기인 NorthPole을 발표(Dharmendra et al., 2023)
- NorthPole은 220억 개의 트랜지스터를 포함하고 있으며 12nm 공정으로 제작되었고 224MB의 온 칩 메모리를 포함하고 있음
- 아래 [그림 2-19]는 CPU(AMD Zen3), GPU(NVIDIA A100), TPU(Google TPUv4i), 그리고 NorthPole의 컴퓨팅 및 메모리 유닛의 레이아웃을 비교
- NorthPole은 centralized memory가 없이 분산된 on-chip 메모리를 탑재하고 있으며 16x16코어 어레이를 가지고 있어 data를 off-chip으로부터 로드할 필요가 없음


[그림 2-19] 다양한 프로세싱 유닛 타입의 compute 및 memory unit layout 비교



자료: Modha, Dharmendra S., et al.(2023)

- NorthPole의 연산기 종류로는 vector 연산기와 vector-matrix 연산기가 있으며 메모리 종류로는 partial sum을 저장하는 buffer, weight 저장 buffer, instruction을 저장하는 program buffer, 그리고 공유 메모리로 사용되는 weight/program/activation 메모리가 있음
- Core에 포함된 control unit은 8개의 thread를 포함하고 있으며 연산과 통신을 담당
- NorthPole의 네트워킹을 담당하는 NoC는 총 네 가지가 사용되며, 512-wire의 partial sum NoC는 근처 core의 vector 연산기 간 네트워킹을 담당함
- 256-wire의 activation NoC는 frame buffer에서 core로 image frame을 전달하고, core에서 frame buffer로 output frame을 전달하며, 공유 메모리 간 neuron activation을 shuffle 하는 역할을 포함
- 1024-wire의 model NoC는 synaptic weight를 weight buffer로 전송
- 256-wire의 instruction NoC는 program buffer로 instruction을 전송
- NorthPole은 ResNet50에 대해 비교한 성능에 따르면, 같은 12nm 공정을 이용하여 제작된 GPU인 V100과 비교하여 에너지 효율이 24.8배 향상된 결과를 달성함

[그림 2-20] IBM의 NorthPole 제품 사진 및 아키텍처



자료: Modha, Dharmendra S., et al.(2023)

□ Tenstorrent

○ Grayskull

- Tenstorrent는 PCI Gen4를 이용한 PCI 카드 형태의 AI 가속기인 Grayskull을 출시를 앞두고 있음
- Fast 버전인 e300, Medium 버전인 e150, Small 버전인 e75로 나뉨
- e300은 듀얼칩 PCI 카드이며 300W 소모, PCIe Gen4 16 lanes, 16GB의 DRAM과 200GB/sec의 속도를 보임
- e300의 Silicon TOPS는 600이며 소프트웨어를 이용하여 1700 TOPS까지 향상 가능
- e150은 150W 소모, PCIe Gen4 16 lanes, 8GB의 DRAM과 100GB/sec의 속도를 보이며 silicon TOPS는 360, 이에 소프트웨어를 이용하면 1000 TOPS까지 향상 가능
- e75는 75W 소모, 16 lanes의 PCIe Gen 4를 사용하였으며 8GB DRAM, 100GB/sec 속도를 보임
- e75의 Silicon TOPS는 250이며 소프트웨어를 이용한 최적화를 통하여 800 TOPS까지 향상 가능
- 삼성전자 미국 테일러 공장을 AI 칩렛 파트너로 정해 삼성전자 파운드리 4nm 공정인 SF4X를 적용해 AI 칩렛을 생산할 계획

[그림 2-21] Tenstorrent의 e300(좌측), e150(가운데), e75(우측)



자료: Tenstorrent 웹사이트

□ Groq

○ Groqchip

- Groq는 구글 출신의 엔지니어인 Jonathan Ross에 의해 2016년 설립된 인공지능 반도체 스타트업
- Groqchip은 14nm 공정으로 제조되었으며 900MHz에서 INT8 타입에 대해 750 TOPS, FP16 타입에 대해 188TFLOPS를 달성
- 칩마다 230MB의 SRAM을 포함하고 있으며 on-die memory bandwidth가 80TB/s까지 달성 가능
- PCIe Gen4 x 16 컨트롤러를 포함하며 Power는 Max 300W를 소모
- PCIe Gen4 x16 폼팩터에 Groqchip을 패키징하여 가속기를 제공
- 8개의 Groq card set를 활용하여 GroqNode를 구성하였으며 server의 CPU와 1TB의 DRAM을 메모리로 활용함으로써 INT8 타입에 대해 6 POPs, FP16 1.5PFLOPs를 달성
- Data center로의 도입을 위하여 8개의 GroqNode를 활용하여 GroqRack이라는 compute cluster를 구성하였으며 하나의 rack에 대해 네트워크의 end-to-end

- latency가 1.6us만을 소모하며 INT8 48POPs, FP16 12PFLOPs를 달성
- GroqWare라는 SW 스택을 함께 제공하며 이는 compiler, API, utilities를 포함
 - 프레임워크는 PyTorch, TensorFlow, ONNX를 지원하고 GroqView profiler, Performance estimator 등과 같은 utility tool을 제공

[그림 2-22] Groq의 chip, 카드, 노드, 랙 구성도



제3절 선도기업 전략기술 분석

- 2022년, 1,750억 개 이상의 파라미터를 가지는 ChatGPT의 등장을 시작으로 한 다양한 거대언어모델이 괄목할 만한 성과를 보이면서 인공지능 반도체 개발은 거대모델을 처리하기 위한 방향으로 개발되고 있으며, 이를 위해 글로벌 선도기업은 다양한 전략을 구축하여 대응 중

1. 메모리 용량 및 대역폭 증가를 위한 HBM 탑재

- 거대언어모델 처리는 메모리 용량 및 접근 속도에 직접적인 영향을 받는 memory-bounded 연산의 대표적인 예임
- 따라서, 기존의 DDR보다는 메모리 용량 및 접근 속도가 우수한 HBM을 탑재하는 것이 필수적인 요소가 됨

〈표 2-4〉 DDR 및 HBM의 specification 비교

	Bandwidth (Gbps)	Max Pin Data Rate (Gbps)	Interface width (bits)
LPDDR4x	136	4.266	32
LPDDR5	204	6.4	32
DDR4	200	3.2	64
GDDR6	512	16	32
HBM	128	1	1024
HBM2	256	2	1024
HBM2E	460	3.6	1024
HBM3	819	6.4	1024
HBM3E	1024	8	1024

자료: 저자 정리


- Intel의 HPC용 Max Series Processor는 최초로 x86 기반 CPU에 패키지당 64GB HBM2E를 내장하여 메모리 용량 및 대역폭을 최대화

- NVIDIA의 H100 SXM 폼팩터는 세계 최초로 4.8Gbps HBM3를 채택한 GPU이며 PCI 폼팩터는 3.2Gbps HBM2E를 장착
- AMD의 MI300X는 24GB HBM3 모듈 8개를 장착하여 총 192GB 메모리 용량과 5.2TB/s의 메모리 대역폭을 달성
- Xilinx의 Alveo 제품군 중 U50, U55C, 그리고 U280은 HBM2를 장착하였으며 각각 8GB, 16GB, 8GB의 용량과 316Gbps, 460Gbps, 460Gbps의 대역폭을 제공
- Sambanova의 SN40L은 온 칩 메모리와 외부 메모리 외에도 64GB의 HBM을 추가 탑재하여 메모리 중심 컴퓨팅에 대응
- Intel의 Gaudi2는 HBM2E 6개를 탑재하였으며 2024년 출시 예정인 Gaudi3는 1.5배 용량의 HBM3 또는 HBM3E를 탑재할 것으로 예상됨

2. 이중 집적을 위한 차세대 패키징 기술 접목

- 서로 다른 technology node 및 기술로 제작된 logic과 HBM 등의 메모리를 하나의 칩에 집적하기 위한 이중 집적 차세대 패키징 기술을 접목하는 것이 요구됨
- 병목현상을 줄이기 위하여 하나의 칩에 패키징하려는 움직임으로 인하여 고성능 저전력 반도체 생산의 수율을 높이고 효율적으로 칩을 생산하기 위한 칩렛 기반 설계 및 패키징 기술도 주목받고 있음
- Intel은 Max series processor를 제작하는 데 자체 개발한 차세대 패키징 기술인 EMIB 기술을 사용하여 CPU와 HBM 메모리를 한 패키지로 묶어 CPU와 메모리 간 병목현상을 줄임
- AMD는 과거 CPU 설계부터 칩렛 기반 설계를 적극적으로 활용하였으며 이를 MI300X에도 적용하여 12개의 칩렛을 3.5D 패키징을 활용하여 결합하여 생산
- GraphCore는 Bow IPU를 생산할 때 원활한 power delivery를 제공하여 높은 operating frequency와 높은 voltage로 동작할 수 있도록 TSMC의 3D WoW 패키징 기술을 활용

[그림 2-23] AMD Instinct MI300-series 가속기에 사용된 3.5D packaging 기술



자료: STH(2023. 12. 6)

3. 폰노이만 아키텍처 탈피 프로세서-메모리 구조 채택

- 메모리 접근 속도를 향상하는 방법으로 HBM을 채택하는 접근법 이외에 폰노이만 아키텍처를 탈피한 processor-in-memory(PIM) 혹은 near memory 구조를 채택하는 방법이 있음
- IBM은 centralized memory가 없으며 모든 컴퓨팅 유닛에 분산되어있는 on-chip memory를 탑재하여 weight나 instruction을 외부 메모리로부터 로드할 필요가 없음
- GraphCore는 in-processor-memory를 채택하여 IPU당 900MB의 in-processor-memory를 포함하고 있으며 IPU당 65.4TB/s 메모리 대역폭을 달성

4. 새로운 인터커넥트와 네트워킹 기술 접목

- 정해진 아키텍처에서 연산을 분산 및 병렬 수행하고자 하는 움직임으로 인하여 연산기 혹은 다이 간 데이터 전송의 필요성이 높아짐
- 데이터 전송 속도를 높이기 위하여 새롭게 개발한 인터커넥트와 네트워킹 기술을 접목하여 동작 성능을 높임

- Google은 multislice 기술을 새롭게 개발하여 하나의 pod에 수만 개의 TPU chip을 ICI로 연결할 수 있게 되었고, 여러 개의 pod은 DCN을 이용하여 연결할 수 있게 되었음
- NVIDIA는 NVLink-C2C 인터커넥트 기술을 보유하고 있으며 이를 이용하여 GH200 슈퍼 칩을 256개 결합하여 하나의 GPU인 듯 기능하는 것을 가능하게 하였으며 최대 900Gbps의 총대역폭을 제공하게 됨

제4절 국내 인공지능 반도체 연구 혁신을 위한 정책 제언

- 국내 팹리스 업체의 인공지능 반도체 개발 현황

 - 국내 인공지능 반도체 업체는 데이터센터용 AI 반도체를 개발하는 리벨리온, 퓨리오사AI, 사피온코리아와 엣지용 AI 반도체를 개발하는 딥엑스, 모빌린트, 오픈엣지를 포함한 다수의 기업이 존재
 - 리벨리온은 자체 개발한 AI 반도체 ‘아툼’의 도입을 위해 IBM과 함께 성능을 평가하고 있고, 거대언어모델 처리용 ‘리벨’을 24년도 출시 예정이며 23년도 하반기 1,000억 원대 투자를 유치
 - 딥엑스는 25 TOPS, 16 TOPS 등의 성능을 보이는 엣지 추론용 반도체를 출시하고 있으며 2024년 CES에서 computer hardware, embedded technology, 그리고 robotics 세 개의 부문에서 혁신상을 수상
 - 특히, 리벨리온을 포함한 퓨리오사AI, 사피온코리아 등 데이터센터용 AI 반도체 기업은 올해부터 HBM을 본격적으로 도입한 칩을 출시할 것으로 알려져 거대모델 학습 및 추론을 본격화할 예정

〈표 2－5〉 국내 데이터센터용 AI 반도체 기업의 차세대 칩 출시 계획

	리벨리온	퓨리오사AI	사피온코리아
제품명	리벨	레니게이드	X430
출시	2024년 4분기	2024년 2분기	2025년 말 or 2026년
파운드리	삼성전자	TSMC	TSMC
공정	4나노	5나노	5나노 이상(미정)
디자인하우스	삼성전자	GUC(대만)	ASICLAND
HBM	HBM3E(삼성전자)	HBM3(SK 하이닉스)	HBM3E(SK 하이닉스)

자료: ZDNET Korea(2024. 2. 7.)

- 국내 인공지능 반도체 개발 환경의 강점

 - 우리나라는 Gartner가 분류한 5가지 반도체 활용 분야의 모든 면을 아울러 삼성전자, LG전자, SK 하이닉스, 현대 자동차와 같은 세계적 기업들을 다수 보유한 국가

- 따라서 인공지능 반도체를 개발하는 국내 기업들은 자동차, 통신, 소비자 기기 등 다양한 반도체 활용 기업들로부터의 수요를 확보할 가능성을 보유
- 또한 인공지능 반도체를 개발하는 국내 팹리스 업체들은 삼성전자 공식 협력 디자인 하우스인 에이디테크놀로지, 가온칩스, 세미파이브, 코아시아 등 다수의 국내 기업들을 통하여 세계 2위 파운드리 기업인 삼성전자와의 협업이 매우 용이한 상황

[그림 2-24] 삼성전자 파운드리 공식 디자인하우스 협력 업체인 디자인 솔루션 파트너



자료: Samsung Electronics

□ 국내 인공지능 반도체 개발 현황의 한계점

- 국내 반도체 기업 간 협력 부재
 - － 인공지능 반도체 제작은 특히 HBM을 채택하는 세계적 추세를 따를 때 팹리스, 디자인 하우스, 파운드리 기업 뿐만 아니라 패키징 업체와 같은 반도체 후공정 업체와의 긴밀한 협력이 필요
 - － 예를 들어, 서로 다른 공정에서 제작되는 HBM과 로직을 하나의 제품으로 패키징하기 위하여 인터포저, 대면적의 기판, 배선, 테스트 등 다양한 후공정 기술들이 집약되어야 함
 - － 국내의 다양한 반도체 후공정 기업들이 있고 기업별로 수준 높은 기술력을 보유하고 있지만 기업 간 이해관계 상충 및 소통의 부재로 인하여 현실적으로 협력이 쉽

지 않은 실정

- 이를 극복하고 팹리스-디자인하우스-파운드리-반도체 후공정 업체 간 활발한 협력이 이루어진다면 국내 중소기업 반도체 생태계를 크게 확장할 기회가 될 수 있음
- 국내 파운드리 및 반도체 후공정 업체의 약세
 - 세계 2위 파운드리 기업인 삼성전자는 특히 인공지능 반도체의 대상 업체로서의 경쟁력이 두드러지게 낮은 편
 - AI 반도체 시장이 비교적 초기 단계로서 경쟁 강도가 높지 않아 세계 많은 팹리스 기업들이 AI 반도체 선도 기업을 선점하기 위한 사활을 걸어 파운드리 단계에서의 위험성을 최소화하고자 세계 1위 파운드리 기업인 TSMC에 수요가 집중

〈표 2-6〉 세계 AI 반도체 설계 팹리스 기업이 채택한 파운드리 업체와 technology node

파운드리	팹리스	AI 반도체 제품명	공정
TSMC	AMD	Ryzen7040	4 nm
		Instinct MI300X	5 nm
	NVIDIA	H100	4 nm
	SambaNova	SN40L	5 nm
	Habana Labs	Gaudi2	7 nm
		Gaudi3	5 nm
	Google	TPUv4	7 nm
	Cerebras	WSE-2	7 nm
	Graphcore	Bow IPU	7 nm
	퓨리오사 AI	레니게이드	5 nm(예정)
	사피온코리아	X430	5 nm ~(예정)
Samsung	Groq	GroqChip(next gen.)	4 nm(예정)
	딥엑스	DX-L1, L2, M1, H1	5 nm ~ 28 nm
	리벨리온	리벨	4 nm(예정)
Intel	Intel	Xeon Scalable Processor	intel 7(10 nm)
		Xeon Max Series	intel 7(10 nm)

자료: 저자 정리

- 반도체 후공정 업체 또한 국내 기업의 약세가 지속적인 문제로 대두되고 있으며 표 7과 같이 상위 10개의 반도체 후공정 업체에서 국내 기업이 이름을 올리지 못함
- 국내 기업의 약세로 인해 반도체 후공정 단계에서의 해외 의존도가 높아지면 장기적으로 국내 반도체 업계 전반의 경쟁력 약화로 이어질 위험이 있음
- 국내 파운드리 및 후공정 기업의 노하우 집적을 위해 전문 인력 생성, 연구 기관의 선도적 기술 제안 및 연구 수행, 팹리스의 파운드리 및 후공정 업체 채택 등의 산학연 협력이 수반되어야 함

〈표 2-7〉 상위 10개 글로벌 반도체 후공정 기업

Rank	Company	Country	2020 Revenue	2021 Revenue	2021 Market Share	2021 YoY Revenue Growth
1	ASE	대만	1,379	1,863	23.7%	35.1%
2	AmKor	미국	1,173	1,407	17.9%	19.9%
3	JCET	중국	879	1,099	14.0%	25.0%
4	SPIL	대만	910	931	11.8%	2.3%
5	PTI	대만	649	742	9.4%	14.3%
6	TFME	중국	351	591	7.5%	68.3%
7	Hua Tian	중국	284	467	5.9%	64.7%
8	KYEC	대만	256	274	3.5%	6.8%
9	ChipMOS	대만	182	251	3.2%	38.4%
10	Chipbond	대만	168	251	3.2%	49.6%

자료: TrendForce(2021)

- NVIDIA GPU의 지배적인 AI 반도체 시장 점유율 독식으로 인한 국내 기술 실증 사례 부족 및 지속적인 지원 부재
 - 국내외 많은 AI 컴퓨팅 인프라는 NVIDIA GPU를 채택하며 NVIDIA는 AI 반도체 시장의 80% 이상을 점유한 것으로 알려져 있음
 - 따라서 정부 R&D 예산 책정 부처 혹은 스타트업 투자자들은 AI 반도체 개발 기관이 비교적 막대한 비용을 투자받으면서도 일정 수준의 매출을 발생시키지 못하는 점에 대해 우려하는 시선이 있음

- NVIDIA의 GPU는 고유의 분산 컴퓨팅 구조를 이용한 아키텍처를 1990년대 후반부터 현재까지 지속해서 업그레이드하여 출시하고 있어 기술적 완성도가 높은 하드웨어임
- 반면, 대부분의 AI 반도체가 채택한 시스톨릭 어레이 구조 기반 AI 반도체 아키텍처는 불과 2016년 Google의 TPU를 시작으로부터 시작되었으며 기술적 완성도를 높이기엔 역사가 매우 짧은 편
- 따라서 국내 인공지능 반도체 개발 팹리스 업체의 제품을 채택한 AI 컴퓨팅 인프라를 구축함으로써 실증 사례를 충분하게 만들어야 하며, 이를 위해서는 지속적인 R&D 지원을 필요로 함

□ 국내 팹리스 업체의 경쟁력 혁신을 위한 정책 제언

- 국내 반도체 기업 간 협력 활성화
 - 반도체 제품 제작의 전주기를 아우르는 팹리스, 디자인하우스, 파운드리, 반도체 후공정 기업, 인공지능 반도체 수요 기업의 활발한 협력 생태계를 조성하는 정책을 제시해야 함
 - 각 기업은 소통 및 협력을 통해 각자가 보유하고 있는 기술의 고도화 및 노하우 집적을 통한 경쟁력 강화를 이룰 수 있다는 이해관계를 인지하고 서로의 공급업체이자 수요업체가 될 가능성에 관한 내용을 공유하고 공감할 수 있는 소통의 창구를 제시하는 정책 마련
 - 출연연 등 각 기업과 이해관계가 얹히지 않은 공공기관의 특성을 활용하여 다양한 국내 기업들이 하나의 프로젝트로 협력하고 성장할 기회를 제공하고, 이를 수행하는 기관과 업체에 재정적, 정책적인 지원을 마련
- 국내 파운드리 및 반도체 후공정 업체의 경쟁력 강화 지원
 - 인공지능 반도체 관련 설계 분야뿐만 아니라 소자, 장비, 차세대 패키징, 테스트, 소프트웨어 등 반도체 제작 전주기와 관련된 다양한 분야의 전문 인력 양성을 위한 정책 마련
 - 국내 파운드리 및 반도체 후공정 업체를 채택하는 수요 기업에 대한 정책적인 지원을 마련하여 국내 반도체 기업들의 상호 보완 및 성장의 생태계를 조성
- 국내 AI 반도체 기술 실증 사업 활성화 및 지속적인 지원 유지

- 국내 AI 반도체를 데이터센터에 채택하기 위한 성능 평가 인프라 구축 및 비용 지원을 통해 실증이 가능한 국산 반도체 확대 지원
- 국내 AI 반도체 채택 수요 기업과 해당 반도체 제작 업체에 대한 정책적 지원을 통해 실증 사례 확산 유도
- 기술적 역사가 짧지만 원천 기술을 확보하고자 하는 인공지능 반도체 R&D에 지속적인 투자를 유지하며 공격적인 기술 개발에 도전하는 연구자, 기관, 업체에 선제적 투자를 통한 R&D 지원

제 3 장 AI 반도체와 가치사슬의 변화

제 1 절 AI 반도체와 수평적 가치 활동별 변화 현황

1. 개요

□ 반도체의 공급망과 수평적 가치사슬 구조

- Logic, DAO(Discrete, Analog, and Optoelectronics) , Memory 등 반도체 최종재 제조를 위해서는 매우 복잡한 공급망과 가치사슬로 구성되는 가치 시스템이 요구
- － 반도체 생태계는 반도체 지식재산, 소재, 개발 도구, 생산장비 등에서부터 반도체 생산의 전공정 및 후공정에 이르기까지 광범위한 가치 활동이 존재하고 그 범위가 매우 넓음

[그림 3-1] 반도체 가치시스템



주: 1) IP(Intellectual Property): 반도체 회로를 설계하는 데 적용·활용할 수 있는

표준 반도체 설계자산(IP)(해외기업으로 ARM, Synopsys 등이 존재)

- 2) EDA(Electronic Design Automation): 복잡하고 미세한 반도체 회로를 설계(디자인)할 수 있는 필수적인 SW Tool(해외기업으로 Synopsys, Cadence, Mentor 등이 존재)
- 3) Equipment 기업: 반도체를 생산하는 장비(반도체 공정에 사용하는 기기)를 만드는 기업(해외기업으로 어플라이드 머티어리얼즈, ASML, TEL, 램리서치, KLA 등이 존재)
- 4) Material 공급기업: 반도체를 생산의 원료 및 소재(반도체 공정에 사용하는 실리콘, 화학물질)를 만드는 기업(해외기업으로 Shinetsu, SUMCO, GlobalWafers 등이 존재)
- 5) Fabless 기업: 반도체 생산시설(Fab) 없이 표준 반도체 설계자산과 자사의 IP를 기반으로 설계·개발만을 수행하는 기업(퀄컴, 브로드컴 등)
- 6) Foundry(Wafer fabrication) 기업: 팹리스가 설계한 반도체를 위탁받아 생산시설(Fab)를 가지고 생산하는 기업(TSMC, 삼성전자 등)
- 7) IDM(Integrated Device Manufacturing) 기업: 반도체 설계에서 생산까지 일괄적으로 수행하는 종합 반도체 기업(인텔, 삼성전자, SK hynix 등이 존재)
- 8) OSAT(Outsourced Semiconductor Assembly & Test): 웨이퍼를 넘겨받아 테스트 및 패키징을 수행하여 마무리하는 작업 공정

자료: SIA(2021) 재구성

□ 반도체의 수평적 가치사슬 구조

- 반도체의 수평적 가치사슬(value chain)은 공급망을 제외한 크게 설계, 생산, 조립 및 검사 등의 영역으로 이루어짐
 - 디자인하우스는 팹리스(설계전문)와 파운드리(위탁생산)를 잇는 가교의 임무를 수행하고, 팹리스가 반도체의 컴퓨터 연산 처리 구조인 회로 설계를 디자인
 - EDA/SIP은 반도체 설계 관련 SW 기술과 재사용이 가능한 IP 블록을 제공하여 반도체 관련 업체들이 좀 더 쉽게 반도체를 설계할 수 있도록 지원
 - OSAT는 가공이 끝난 웨이퍼의 패키징 및 테스트를 전문으로 처리하는 후공정
 - 팹리스가 아이디어를 내는 건축 디자이너, 디자인하우스는 이를 물리적인 설계도면으로 그림으로 그리는 설계사, 삼성전자·TSMC 같은 파운드리 기업이 도면대로 실제 건물을 짓는 시공사로 표현
- 본 연구에서는 이러한 수평적 가치사슬 영역을 기준으로 주요한 기술 생태계 영역인 SIP, EDA, Design House, Foundry, OSAT 등을 중심으로 분석
 - 반도체 설계 단계(Design): 다양한 Fabless 및 IDM 기업이 반도체 설계 SW(EDA)

와 반도체 지식자산(SIP)을 외부 전문기업으로부터 공급받아 반도체 설계와 개발 진행

- 반도체 생산 단계(Manufacturing): Foundry가 Fabless · IDM에서 디자인한 반도체 설계를 위탁받아 생산하는 전(前)공정을 담당하고, 이때 외부 전문기업이 반도체 생산에 필요한 장비와 소재를 Foundry에 공급, 그리고 최종적으로 OSAT 업체가 패키징 · 테스트 등의 후(後)공정을 담당

[그림 3-2] 반도체 수평적 가치사슬의 범위

전문화 비즈니스 모델 (Specialization Biz Model)	주요 가치사슬 활동(Value Chain activity)		
	설계(Design)	생산(Manufacturing)	
		전공정 (Front End: Wafer fabrication)	후공정 (Back End : Assembly & testing)
기업 현황			
종합반도체 기업 IDMs (Integrated Device Manufacturing)	intel, SAMSUNG, Micron, TEXAS INSTRUMENTS, NXP, infineon, SK hynix, KIOXIA, ANALOG DEVICES, ST, RENESAS		
설계전문 기업 Fabless	Qualcomm, NVIDIA, BROADCOM, AMD, MEDIATEK	-	-
생산전문 기업 Foundries (Wafer fabrication)	-	tsmc, UMC, SAMSUNG, PPG INDUSTRIES, SMIC	-
패키징 · 테스트 전문 기업 OSAT (Outsourced Semiconductor Assembly & Test)	-	-	ASE, JCET, Powertech Technology Inc., Amkor, TF 通富微电

자료: 김민식(2022)

2. SIP(Semiconductor Intellectual Propriety)

□ SIP의 이해


- SIP(반도체 IP)는 반도체의 집적회로를 설계할 때, 재사용할 수 있는 회로의 Block으로 정의할 수 있음
- 반도체 직접 회로에 특정한 회로가 IP 형태로 판매(라이선스)되어 재사용되는 이유는 다른 반도체 칩에서도 반복되어 활용될 수 있기 때문
- 팹리스, IDM이 반도체 칩을 설계·개발할 때 같은 기능이 반복된다면, 직접 개발하는 것보다 기존에 개발된 SIP를 가져다 쓰는 것이 시간·비용 측면에서 경제적

□ SIP의 활용 프로세스

- 반도체 설계 과정은 많은 부분에서 소프트웨어 개발과 유사함³⁾
 - (Front-end process) 개발하고자 하는 반도체 칩의 사양(Specification)을 정하고 HDL(Hardware Description Language)로 불리는 프로그래밍 언어를 사용하여 칩의 동작 방식을 기술하여, 주로 반도체의 기본 소자인 게이트(Gate) 간의 연결 관계를 표현하는 것으로 논리적인 회로도(Schematic)를 나타냄
 - ※ 개발된 소스 코드는 컴파일러를 통하여 RTL(Register Transfer Level)로 변환되며 이는 일종의 IL(Intermediate Language) 혹은 목적 코드(Object Code)에 해당
 - (Back-end process) 물리적 설계 공정인 후공정 단계에서는 셀의 PNR[배치(Place)와 연결(Route)] 과정을 거쳐, 웨이퍼 위에 올라갈 트랜지스터의 레이아웃을 그려보는 과정으로 물리적 설계 공정이 끝나면 레이아웃 형태의 칩은 실리콘 위에 올라가 실제 칩으로 양산

3) Kahng, A. B., Lienig, J., Markov, I. L., & Hu, J.(2011). VLSI physical design: from graph partitioning to timing closure(Vol. 312). Netherlands: Springer.

[그림 3-3] 반도체 설계 과정의 이해



자료: Kahng, A. B., Lienig, J., Markov, I. L., & Hu, J. (2011)


- 반도체 설계 과정은 이처럼 논리적 디자인(Logical Design), 물리적 디자인(Physical Design)으로 구분되고, SIP는 논리적 수준인 Soft IP와 물리적 수준인 Hard IP로 분류⁴⁾
 - Soft IP는 RTL 수준의 알고리즘으로 존재, CPU, GPU 등 프로세서가 어떻게 작동하는지를 나타내는 아키텍처 혹은 Controller 같이 작업처리를 결정하는 스케줄링 기능이기에 때문에 코드 형태로 존재
 - Hard IP는 회로 내 칩 간 소통, 칩과 외부 디바이스의 연결 등 회로의 물리적 배

4) 에스코어 인사이트 리포트(2021), 반도체 설계 자동화의 핵심, EDA(Electronic Design Automation) 트렌드

치와 연결을 다루기 때문에 실물 형태로 존재

- ※ Hard IP는 실물로 존재한다는 특징으로 인하여 파운드리가 변화하거나 공정이 미세화될 때 새로 IP를 개발해야 하여, Soft IP 대비 혁신 속도가 비교적 낮은 상황
- － Hard IP는 물리적 집적회로 형태로 판매되지만, Soft IP는 RTL 수준 코드가 판매되기 때문에, 기술력이 노출될 우려가 존재하여, SIP 공급업체들은 암호화한 코드를 고객사에게 전달하며 고객사는 결과값만 받아 IP를 활용하는 방식

[그림 3-4] SIP의 구분



자료: 한국IR협의회 기업리서치센터(2023)


□ SIP 시장 구조⁵⁾

- SIP 종류는 기능에 따라 세 가지로 구분
 - － CPU, GPU, AP 등 연산장치와 관련된 Processor IP, 칩 내외부 디바이스 사이의 연결을 돕는 Interface IP, 그리고 논리 게이트 등 설계의 기초가 되는 Foundation IP로 구분

5) IPnest(2023)

- 이 외에도 쓰임새에 따라 카메라 코덱 IP부터 보안용 IP까지 다양한 종류의 IP 존재
- SIP 시장 규모는 2021년 55억 6천만 달러 이후 2022년 66억 7천만 달러를 달성하여, 2020년 16.7% 이후, 2021년 19.4%, 2022년 20.2% 성장률 기록
 - SIP 공급기업은 반도체 설계용 특정 블록인 SIP의 라이선스나 로열티 매출로 수익을 창출
- Processor IP는 실제시장 표준으로(de facto standard) ARM 아키텍처가 거의 독과점 수준으로 스마트폰부터 자동차, TV, PC, 노트북, 서버까지 대부분 디바이스에 탑재
 - 2022년 기준 ARM의 매출액은 약 28억 달러이며, IP 시장 M/S는 41%로 추정
- Interface IP는 활용처에 따라 Memory(DDR, LPDDR, GDDR, HBM), Mobile/PC(USB, MIPI, SATA, eMMC/SD), Networking(SerDes, Ethernet), Display(HDMI/DP), Server/Storage(CXL/CCIX, PCIe), Chiplet(D2D, UCle)로 구분
 - AI 반도체와 NPU 성장으로 데이터 간 고속 연결이 중요해졌기 때문에 Interface IP 향후 성장률은 Processor IP 보다 높을 것으로 예상
 - Interface IP는 Synopsys와 Cadence가 과점 중. Synopsys는 High end 부터 Low end IP를 모두 보유. 또한 Processor IP도 보유하고 있어서 SIP 시장 M/S 약 20%로 ARM에 이은 2등 사업자
 - 반면 Cadence는 고속 연결 관련 High end Interface IP위주로 M/S 5.4%의 3등 사업자
 - Interface IP 산업 시장은 첨단 미세공정, 고단가 IP 위주 경쟁이 치열한 상황으로 공정이 미세화될수록 EDA Tool부터 장비, 인건비 등 제반 개발비용이 동반 상승
 - 최근 SIP 공급업체 간 경쟁은 첨단 미세 공정의 고속 연결 SIP 위주로 발생
 - 따라서 신생 SIP기업은 레거시 공정 일반 연결 IP, 과점사 대비 20~30% 할인된 첨단 공정 고속 연결 SIP를 공급하여 시장의 빈틈을 공략

[그림 3-5] SIP 분류별 시장규모 비중의 변화



자료: IPnest(2023)

〈표 3-1〉 SIP 시장점유율(2021~2022)

순위	Company	2021(M\$)	2022(M\$)	2022 Market Share	Cumulative Share
1	ARM(Softbank)	2,202.1	2,2741.9	41.1%	41.4%
2	Synopsys	1,076.6	1,314.8	19.7%	60.8%
3	Cadence	315.3	357.8	5.4%	66.1%
4	Imagination Technologies	153.0	188.4	2.8%	68.9%
5	Alphawave	89.9	175.0	2.6%	71.5%
6	Ceva	122.7	134.7	2.0%	73.5%
7	Verisilicon	109.4	133.6	2.0%	75.5%
8	SST	102.9	122.0	1.8%	77.3%
9	eMemory Technology	84.8	105.1	1.6%	78.9%
10	Rambus	47.7	87.9	1.3%	80.2%
	Top10 Vendors	4,304.4	5,361.2	80.3%	80.2%
	Others	1,099.8	1,316.0	19.7%	100.0%
	Total	5,522.1	6,677.2	100.0%	100.0%

자료: IPnest(2023)

□ AI 반도체와 SIP의 변화

- 최근에는 Fabless 기업이 SIP 제공 사업을 동시에 수행하거나, 반도체 설계/검증용 소프트웨어를 공급하는 EDA 전문기업이 SIP 제공 사업을 동시에 진행함
- 대표적인 기업(Fabless+SIP)은 AMD와 퀄컴이며, ① 퀄컴의 경우 QTL(Qualcomm Technology Licensing)이라는 SIP 라이선스 사업을 유지 중이며 ② AMD의 경우 Semi-Custom 사업으로, 자체적으로 개발해서 보유하고 있는 Core IP를 활용해서 특정 고객사를 위한 맞춤형 반도체 설계
- 대표적인 기업(EDA+SIP)은 Cadence, Synopsys로 이들은 EDA를 중심으로 보완적인 SIP을 제공
- ※ SIP 업종에서는 반도체를 설계하는 고객사에 최초로 SIP를 공급할 때 라이선스 매출이 발생하고, SIP를 라이선스하는 시점으로부터 2~3년 뒤에 제품 생산되어 판매에 따르는 로열티 매출이 발생
- 최근에는 AI 반도체를 개발하는 주체가 구글, 아마존, 페이스북과 같은 최종 서비스 기업, 애플과 같은 세트 업체 등 최종 수요기업으로 다변화되어, SIP 회사의 고객도 기존 Fabless 외에 다양한 수요기업과 파운드리, 디자인하우스 등으로 확장
- 자사가 원하는 성능 및 가격을 담보할 수 있는 AI 반도체를 개발하기 위한 내부 인적 역량을 확보하고, 외부에서 조달할 수 있는 EDA 및 SIP을 활용
- 소프트뱅크의 ARM Holdings와 같이 순수하게 반도체용 SIP 사업만을 영위하는 기업의 경우, 보완적인 SIP에 대해 인수합병이나 협업을 통해 통합 솔루션을 제공하는 플랫폼 전략 수행
- AI 반도체를 제대로 설계하고 양산하기 위해서는 수십에서 수백 개의 SIP를 확보해 필요한 블록을 통합해야 하는 매우 어렵고 복잡한 작업이 요구
- AI 반도체 관련 선단 첨단 미세공정에서 필요한 SIP을 신규로 개발하거나 개선하는 비용이 천문학적으로 증가(AI 반도체 SIP 개발의 복잡도 증가, AI 반도체 설계 시 필요한 검증된 SIP 확보, 연구개발 및 서비스인력의 추가 확보 등이 요구)

○ Arm 반도체 플랫폼 기업으로 전환 사례

- Arm은 대표적인 반도체 IP 기업으로, 애플, 퀄컴, 미디어텍 등 주요 AP 제조사들이 ARM의 코어텍스(Cortex) 등 SIP을 활용. 모바일 외에도 데이터센터, 인공지능(AI) 등 영역에 SIP 사용
- (Arm Total Design) Neoverse Compute Subsystems인 CSS 기반의 에코시스템으로 디자인 하우스, SIP, EDA, 파운드리 및 펌웨어 업체 등을 포함하여 협업

* ▲IP 및 EDA 툴을 통해 반도체 설계와 메모리, 보안, 주변 장치 등 통합 가속화 ▲ Arm 디자인 파트너사의 설계 서비스 제공 ▲ 주요 파운드리 공정과 패키징 기술에 최적화된 기술 제공 ▲네오버스 CSS 위한 상업용 소프트웨어 및 펌웨어 지원 등을 통해 고객사의 반도체 개발 전 과정 지원

3. EDA(Electronic Design Automation)

□ EDA의 이해

- EDA는 반도체 회로를 설계하는 컴퓨터 프로그램으로, 반도체 산업은 전자 설계 자동화(EDA) 기술로 인해 발전
- EDA 도구를 활용하여 복잡한 반도체 설계 및 개발에 있어 필요한 시간 단축, 제조 비용 절감, 제조 결함 제거, 회로 설계 및 사용 편의성 향상 등의 이점을 얻을 수 있음
- 특히 EDA는 반도체 제조 전 시뮬레이션을 돌려 회로 설계 및 오류를 판단하고, 이를 통해 문제상황을 분석하고 해결하는 역할을 수행

□ EDA의 활용 프로세스

- EDA는 반도체 칩을 설계하는 데 사용되는 소프트웨어로, EDA Tool 기반으로 반도체를 설계하는 과정에서 설계 블록인 SIP을 심어 넣어 활용
- 이러한 EDA와 SIP 상호보완적인 관계 측면에서 보면, 반도체 설계 및 생산에 있어 SIP 접근성이 중요해짐
- 파운드리(위탁생산) 업체의 경우, EDA 공급업체가 생산 프로세스 단계에 따른 설계 흐름을 EDA 개발에 반영할 수 있도록, 새로운 제조 프로세스 대한 우선적인 접근을 제공하는 경우가 많음
- 특히 반도체 칩의 사용이 더욱 보편화되고, 특정 용도로 설계된 반도체 칩이 최종

수요자에게 가치가 높아짐에 따라 EDA 및 SIP을 활용하여, 최종 반도체 수요기업이 반도체 설계에 참여할 수 있는 환경이 조성

□ EDA 시장 구조⁶⁾⁷⁾

- EDA 시장 규모는 반도체 시장의 규모가 증가함에 비례하여 증가
 - － 반도체 수요량이 증가하면, 더욱 신속하게 반도체를 설계 및 디자인할 수 있도록 EDA 설계기술의 활용도가 증가
 - － 2022년 EDA 시장의 규모는 127억 달러로 반도체 시장 규모의 2% 수준이지만, 반도체 공정 미세화로 인해 설계 비용이 커지면서 그 중요성이 증가
 - ※ 예를 들어 EDA 제공업체인 Synopsys는 2019년에 5nm 칩을 설계하는 데 드는 비용이 7nm 칩을 설계하는 데 드는 비용의 두 배가 될 것으로 추정
- 현재 반도체 설계와 테스트에 필요한 EDA Tool을 개발·공급하는 기업 중 Synopsys, Cadence, Siemens 등의 3개사가 EDA 시장을 과점
 - － 30년이 넘는 EDA Tool 전문 공급기업이며 삼성, 인텔, TSMC 등 IDM 및 파운드리(위탁생산) 기업에 필수적인 EDA 소프트웨어 제공
 - － EDA 소프트웨어를 개발하기 위해서는 반도체 산업에 대한 전문 지식이 필요하며 최고 수준의 소프트웨어 개발 역량도 갖춰야 함
 - － EDA 전문 공급 3개사의 제품은 오랜 기간 사용되면서 발전해왔고 반도체 산업의 표준 도구로 자리를 잡고 있음
- 현재 경쟁 환경에서 후발 주자가 새로운 EDA 소프트웨어 제품을 보급하는 것은 불가능한 상황
 - － 축적된 기술격차를 극복하기도 어렵거니와 반도체 업체가 새로운 EDA 소프트웨어를 사용함으로써 발생하는 위험을 감수할 이유가 없음
 - ※ 기존 디자인에서 계속 발전 및 혁신이 되는 과정이 대부분이며 또한, 기존 디자인에 대한 라이브러리 및 정보를 보유하고 있으며 관련된 내용을 확인하고 테


6) Kotra 해외시장 뉴스(2022.09.020, 美 반도체 설계의 미래, 전자설계자동화(EDA) 시장

7) 에스코어 인사이트 리포트(2021), 반도체 설계 자동화의 핵심, EDA(Electronic Design Automation) 트렌드

스트 한 결과 수치와 축적된 데이터가 중요

- 또한 EDA 분야의 신생 업체들은 새로운 혁신적인 기술을 기반으로 하는 경우가 많은데, EDA 주요 공급업체 3개 사는 이러한 매력적인 소규모 업체들을 인수하여 자사 제품에 반영함으로써 기술적 우위를 유지하는 전략을 사용
- EDA Tool의 진입장벽은 상당히 높으며 경쟁자(스타트업)가 새롭게 시장에 진입하기가 매우 어려운 상황
- 실제로 EDA 기업 중 상위 10개사가 전체 시장의 68% 정도의 비중을 차지하고 있으며 그중에서도 Cadence, Siemens, Synopsys가 전체 시장에서 차지하는 비중이 54%에 달함

[그림 3-6] Electronic Design Automation Tools(EDA) 시장 규모



자료: KOTRA(2022)

□ AI 반도체와 EDA의 변화

- EDA 공급업체들은 AI 기능이 적용된 제품 포트폴리오 확대
 - 기존 물리적 설계 관련 EDA뿐만 아니라 반도체 회로 설계의 검증, 테스트에 사용되는 EDA에도 AI가 적용
 - 나아가 반도체 설계인력의 고유 영역으로 여겨지던 논리적 설계(Logical Design)

에도 생성형 AI가 적용

- 향후 3D, Chiplet 등 첨단 패키징 시장은 빠르게 성장할 것으로 전망됨에 따라, 반도체 설계뿐만 아니라 시스템(패키지) 레벨에서 사용되는 EDA의 중요성이 증가
 - ※ 3D, Chiplet 등 패키징 과정에서 시뮬레이션 SW가 패키징 관련 EDA 기능을 제공
- AI 반도체 수요가 증가하면서 EDA Tool의 중요성이 대두
 - EDA를 활용하면 AI 반도체 설계에 걸리는 시간이 줄뿐만 아니라 오류를 감지해 불량률을 줄일 수 있음
 - EDA를 이용한 반도체 설계 검증 과정의 정확성과 효율성이 바로 반도체 개발의 중요한 역량
 - 파운드리 공정에서 지원하는 EDA 툴을 늘려 고객사들의 선택 폭을 넓히고 사업 경쟁력을 강화

4. Design House

□ Design House의 이해


- 디자인하우스는 Fabless(설계전문) 업체가 설계한 비메모리 반도체 회로를 파운드리 생산 공정에 최적화되도록 다양한 지원 서비스 제공
 - 중소 팹리스 업체가 비메모리 반도체 설계용 컴퓨터 언어인 HDL(Hardware Description Language)을 이용하여 프로그래밍한 문서 형태의 회로 설계도를 파운드리 제조 공정에서 실제 반도체 칩으로 제작하기 위한 제조용 회로 설계도면(Layout)으로 변환하고, 반도체 생산 전반 관련 지원 서비스 제공
 - ※ Fabless가 설계한 반도체 회로를 파운드리 제조 공정에서 인식할 수 있도록 변환시키는 역량이 중요
- 비메모리 반도체 설계 담당하는 팹리스와 반도체 생산을 담당하는 파운드리 기업 사이에서 가교(bridge) 역할 수행

□ Design House의 역할 현황과 변화

- 기본적으로 Fabless가 설계한 반도체 회로를 실제 파운드리 공정에 맞게 디자인 PNR[배치(Place)와 연결(Route)] 과정인 Back-end process 수행

- 또한 주요 파운드리 기업은 자사를 대신하여, Fabless의 반도체 회로를 검토하여 파운드리 공정에 최적화해줄 수 있는 역량을 갖춘 디자인 하우스를 협력 기업으로 확보 및 확대하고 있는 상황
 - 반도체 회로 설계의 완성도를 강화하기 위해서는 파운드리 생산 공정의 특성과 장단점을 가장 잘 이해하고 있는 파운드리 기업이 직접 반도체 회로설계를 최적화하여 제공하는 방식이 중요
 - 하지만, 현실적으로 파운드리 기업이 직접 수많은 Fabless의 다양한 프로젝트에 대응할 수 없는 한계가 존재
 - ※ 파운드리가 대량 양산용 반도체칩을 만들어서 주요 고객사에만 공급한다면 중간에 가교역할을 담당하는 디자인 하우스가 필요 없겠지만, 다품종 소량 생산을 원하는 다양하고 수많은 개별 Fabless를 위해서는 디자인하우스가 매우 중요
- 최근에는 SIP를 확보해 비메모리 반도체를 설계하는 Fabless가 이를 활용해 개발 기간을 단축하고, 사전에 검증된 SIP를 활용해 안정성을 확보하도록 지원
- 고사양의 반도체에 대해서는 Front-end process에 해당하는 「HDL(Hardware Description Language)을 이용하여 프로그래밍한 문서 형태의 회로 설계」영역의 서비스도 제공
- 반도체칩 최종 생산을 위한 후공정(패키징, 테스트)에서 필요한 관련 설계 전문기술도 지원
 - 후공정 패키징 설계기술, 테스트 회로 설계기술, 제품의 전원 및 신호 품질 확보를 위한 무결점 테스트 기술 등
- 결국 디자인 하우스는 비메모리 반도체의 다양화와 고기능화로 기존 『파운드리 관련 가교 서비스 제공 형태』에서, 『반도체 제조 전반을 지원하는 종합 솔루션 지원 형태』로 변화하는 중
 - 디자인 하우스가 직접 SIP 선택에서부터 회로 설계, 설계용 소프트웨어(EDA) 제공, 생산 공정에 따른 최적화, 패키징, 테스트, 유통까지 지원하는 역할로 변화

[그림 3-7] 디자인 하우스 기업의 역할과 변화



자료: 가온칩스(2022)

□ 주요 Design House 현황

- 삼성전자 파운드리 사업부 소속 디자인 하우스는 크게 DSP(Design Solution Partner)와 VDP(Virtual Design Partner)로 구분
 - VDP는 삼성전자 파운드리 사업부가 후반부 설계((Back-end process)를 감당하지 못할 때 특정 로직 설계 등 소규모 프로젝트를 담당하여, VDP 매출은 삼성전자 파운드리사업부를 통하여 발생함
 - DSP는 직접 팹리스의 프로젝트를 수주해 파운드리와 연결해주는 일반적인 디자인하우스의 비즈니스 모델로 삼성전자 파운드리사업부와 주문형 반도체(ASIC) 설계 서비스, 후공정(OSAT) 연계 및 운영 서비스, 공급망 관리 서비스 등을 지원
 - 디자인 하우스 관점에서 보면 DSP는 고객사가 팹리스며, VDP는 삼성전자 파운드리가 고객사로 DSP 업체는 적극적으로 고객사(팹리스)를 발굴하여 계약하는 반면, VDP는 삼성전자 파운드리 사업부 프로젝트에 의존

[그림 3-8] 삼성전자 파운드리 사업부의 DSP 현황



자료: 삼성전자 웹사이트, <https://semiconductor.samsung.com/kr/foundry/safe/design-service>.

- TSMC의 경우 가치사슬협력사(VCA)라는 이름으로 다자인 하우스 그룹을 운영 중
 - － VCA(Value Chain Aggregator)는 TSMC와 긴밀히 협력하여 TSMC 제공 공정 스펙을 기반으로 수요기업의 반도체 생산에 혁신을 가져올 수 있도록 다양한 설계 서비스를 제공
 - － 글로벌유니칩(GUC), 알칩 등 세계적인 디자인하우스가 포함하며 국내 기업으로는 유일하게 에이직랜드가 소속됨

[그림 3-9] TSMC의 VCA 현황

VCA Members



자료: TSMC 웹사이트, <https://www.tsmc.com/english/dedicatedFoundry/oip/value-chain-alliance>.

□ AI 반도체와 Design House의 변화

- 디자인 하우스 파트너사의 기술적 역량 확대 요구가 점점 늘어나는 추세
 - － AI 반도체의 다양화와 고기능화로 기존 반도체 제조 서비스의 부가적인 형태에서 반도체 제조 전반 서비스를 제공하는 토탈 솔루션 서비스 형태로 진화
 - － 반도체 설계 능력은 물론 공정 최적화, 패키징, 테스트, 유통 외에도 EDA 및 SIP

협업 능력까지 반도체가 설계되는 과정에서 판매되는 과정까지 전방위적으로 다양하게 요구되는 역할 수행이 요구

- 중소기업 디자인하우스의 지원 역량 확보를 위해, 중소기업 디자인하우스 간 M&A를 통한 규모 확대, 업무영역 확장 등 추진 중

5. Foundry

□ Foundry의 이해

- Fabless·IDM 등 이 설계한 반도체를 위탁 제조하는 기업 형태로 지속적인 대규모 설비투자가 필요
 - － Foundry(Wafer fabrication) 기업: 팹리스가 설계한 반도체를 위탁받아 생산시설(Fab)를 가지고 생산하는 기업(TSMC, 삼성전자 등)
- 반도체 제조(Manufacturing)는 Foundry가 Fabless·IDM에서 디자인한 반도체 설계를 위탁받아 생산하는 전(前)공정을 담당
 - － 외부 전문기업이 반도체 생산에 필요한 장비와 소재를 Foundry에 공급, 그리고 최종적으로 OSAT 업체가 패키징·테스트 등의 후(後)공정을 담당

□ Foundry의 역할 현황과 변화

- 반도체 가치사슬 활동 중 가장 많은 자본지출(Capex), 공정의 복잡성으로 인해 축적된 지식, 생태계 구조화 능력 등이 요구되는 분야가 제조단계에서 전공정(Front End)에 해당되는 웨이퍼 가공 분야(Wafer fabrication)이며 진입장벽이 높음
 - － 웨이퍼 가공 활동은 필요한 설비 규모와 값비싼 최첨단 장비 구매로 인해 자본 집약적인 영역
 - － 웨이퍼 가공에는 복잡한 요소기술과 더불어 이러한 요소기술을 실현하는 다양한 장비가 존재하는데, 이러한 장비를 조합하여 단기간에 생산공정을 구성하고 신속하게 높은 수율을 보장하는 지식 축적이 필요
- 파운드리 본원적인 기술 경쟁은 공정 미세화로, 지속적인 투자 비용이 증가할 수밖에 없어 진입장벽이 높아지고 있으며, 과점경향이 강한 특징
 - － 최근 비메모리 반도체 분야에서는 초미세 공정 전환에 따른 신규 생산설비 투자

금액 증가, 공정개발·설계비용 증가로 인해 반도체 설계에서 생산까지 비용이 지속해서 증가하는 추세

- 하지만 첨단 미세공정 기술을 요구하지 않는 레거시 분야(전력반도체, 아날로그 반도체 등 특수목적형 반도체)는 후 순위 업체에서 상대적으로 저렴한 비용으로 생산하고 있음
- 기존 IDM 업체도 생산설비 비용의 지속적인 증가로 인하여, 초미세 공정에 대한 추가적인 생산은 PurePlay Foundry 업체에 일부 생산을 위탁하고 있는 실정
- 최근 반도체 분야에서는 초미세공정 전환에 따른 신규 생산설비 증설, 최첨단의 복잡한 공정개발 및 설계 난이도 증가 때문에 반도체 설계에서 생산까지 비용이 지속해서 증가하는 추세와 더불어 복잡해지는 공급망에 대응하는 Foundry 비즈니스 모델의 중요성 증가
- 웨이퍼 가공에 있어 검증되어 사용할 수 있는 다양한 SIP, EDA 등을 협업으로 수요기업에 지원 서비스로 제공하며, 동시에 주요 소재 및 장비 공급망에 대한 밀접한 관계를 유지하는 역량(공급망 관리능력)이 필요
- Fabless·IDM의 다양한 반도체 위탁 생산수요에 대응하여 지속적인 생산설비 투자와 지원 서비스를 제공하는 역량이 중요
- 다양한 반도체를 만들고 싶어 하는 다양한 일반 수요기업(Set Maker)도 쉽게 반도체 칩을 만들 수 있도록 Foundry는 자유도와 유연성을 제공하는 생태계 구축에 노력 중
- 이외에도 TSMC, 삼성전자, 인텔 등 글로벌 파운드리 3사가 최근 최첨단 패키징(advanced packaging)에서 본격적인 투자를 시작
- TSMC는 3D 중심의 최첨단 패키징에 대규모 투자를 준비 중으로, 3D 패키징은 다른 반도체 칩을 수직으로 쌓아서 성능을 높이는 기술로 기존 패키징보다 가까이 이종의 반도체 칩을 붙여 데이터 전송 속도를 높임
- 삼성전자는 AI 반도체에 많이 쓰이는 CPU 또는 GPU 간의 칩렛(Chiplet) 연결이나 AI 가속기와 HBM를 수평으로 배치해 하나의 반도체처럼 동작하게 하는 'I-CUBE'란 2.5D 패키징 기술에 투자
- 특히 삼성전자는 파운드리에서 양산한 반도체 칩에 최첨단 패키징까지 제공하는

턴키 서비스를 제공 중

□ AI 반도체와 Foundry의 플랫폼 전략

- Foundry는 다양한 반도체를 만들고 싶은 다양한 수요기업이(일반기업, Fabless, IDM 등) 부담 없이 자사의 반도체 칩을 만들 수 있도록 자유도와 유연성을 제공하는 생태계 구축에서 중요한 축으로 대두
 - 파운드리가 AI 반도체의 성능향상을 위한 새로운 첨단 공정을 도입하면, 다양한 수요 업체가 이에 맞춰 원활히 반도체 설계를 할 수 있도록 파운드리와 협력하는 IP, EDA 등을 지원
 - 파운드리 생태계에 참여하는 다양한 기술 전문기업이 긴밀하게 협업하며 고객이 원하는 AI 반도체를 적기에 제조할 수 있도록 지원
- 대표적인 Foundry 기업은 전통적인 반도체 생산 활동에 필요한 부가적·보완적 활동을 통합하여 제공하는 플랫폼 전략을 강화하고 있음
 - 물리적인 반도체 생산 역량을 핵심기반에 두고, 다양한 IP·EDA와 함께 부가적인 서비스와의 협업을 통해 다양한 수요자 요구를 충족시키는 플랫폼 전략 강화

- Foundry 시장점유율 1위 기업인 TSMC의 Grand Alliance와 Open Innovation Platform®
 - TSMC는 이미 생산 공정에 검증되어 사용 가능한 다양한 IP, EDA Tool 등을 협업으로 제공하여, 수요회사인 일반기업, Fabless, IDM 등을 확대함으로써 협력할 수 있는 보다 많은 IP, EDA Tool 등을 다시 확보할 수 있는 선순환 구조를 갖추으로써 강력한 생태계를 구축하고 있음
 - TSMC의 Grand Alliance는 수요기업, EDA 파트너, IP 파트너, 주요 장비·재료 공급 업체의 협력에 기반을 둔 반도체 산업 혁신을 위한 인프라로 작용
 - Grand Alliance의 핵심영역인 Open Innovation Platform® 플랫폼을 통하여 비메모리 반도체 설계 커뮤니티와 생태계 파트너 간의 혁신 속도를 높이고 제조 기능, 프로세스 기술 및 지원 서비스를 위한 자체·협업 IP, EDA Tool, 설계 서비스 등을 제공
- Foundry 시장점유율 2위 기업인 삼성전자 파운드리사업부는 SAFETM(Samsung Advanced Foundry Ecosystem) 프로그램
 - 공정 설계 키트(PDK), 설계 방법론(DM)을 따르는 레퍼런스 플로우, 설계자산(IP)과 설계 지원을 포함한 인증된 핵심 설계 구성 요소를 기반으로 경쟁력 있고 강력한 단일 칩 체제(SoC) 설계를 제공

○ 후발주자인 인텔의 파운드리 에코시스템

- IFS 엑셀러레이터 에코시스템 얼라이언스는 삼성전자의 삼성 SAFE와 유사한 개념으로, IFS 엑셀러레이터 에코시스템 얼라이언스는 ▲EDA 얼라이언스 ▲IP 얼라이언스 ▲디자인 서비스 얼라이언스 ▲클라우드 얼라이언스 등으로 구성

6. OSAT

□ OSAT(Outsourced Semiconductor Assembly and Test)의 이해

- OSAT 주로 파운드로부터 Fab 가공이 끝난 웨이퍼에 패키징과 테스트를 전문적으로 처리하는 후공정 업체
- 후공정은 실리콘 웨이퍼 가공이라는 전(前)공정 이후 반도체 칩 출하 전 포장 작업으로 표현하며, 가공된 웨이퍼를 개별 칩으로 자른 뒤(다이싱·Dicing) 전기 신호가 흐르는 회로를 만들고, 외형을 가공하는 작업
- OSAT 업체는 일반적으로 파운드리가 내부적으로 후공정을 처리하고, 남은 특수영역 및 저부가가치 제품들 위주로 진행
- 최근 OSAT 업체는 최첨단 패키징을 통해 첨단 반도체 칩의 성능을 높이고 있음
 - 최첨단 패키징은 이종(異種)의 반도체 칩을 수직으로 쌓거나 수평으로 배치해 하나의 반도체처럼 작동하게 하는 후(後)공정
 - 반도체 칩을 작게 만들어 성능을 높이는 초미세공정에 한계가 오면서 반도체 기업들은 최근 최첨단 패키징을 통한 성능 극대화에 주력

□ OSAT의 중요성과 변화

- 반도체 전공정의 미세화가 한계에 이르면서 반도체 성능향상의 핵심기술 영역으로 OSAT가 발전하면서, OSAT의 가치활동 범위가 확대되고 협업이라는 요소가 필수적으로 등장
 - 첨단 미세공정 경쟁이 치열한 가운데 기술적 한계와 비용 상승이라는 한계를 극복하기 위해 멀티 다이 디자인 또는 칩렛(Chiplet) 등의 기술이 강조
 - 칩렛기술은 여러 종류의 반도체를 하나의 패키지로 조립하는 기술로, 이를 통해 각각의 반도체가 역할을 나눠 수행할 수 있도록 해 전체적인 성능을 끌어올릴 수

있음

- 칩렛 기술은 반도체 기업들이 미세공정의 한계를 극복하고, 개발 리스크를 감소시키며, 고객 중심 또는 애플리케이션별 반도체 양산을보다 신속하게 창출할 수 있는 새로운 방식을 제시
- 칩렛 기술은 반도체 설계, 검증, 테스트, 조율하는 과정은 본질적으로 더 복잡하므로 개별 기업 및 가치사슬 전체에 있어 수많은 운영상의 문제점 해결이 필요
- o 3D 혹은 2.5D 방식으로 반도체 칩을 쌓아 올리는 적층 기술과 서로 다른 반도체칩을 연결하는 이중 집적 기술이 대두되고 있는데, 이러한 적층과 이중 집적은 패키징 공정에서 진행
- 칩렛은 반도체 소자를 독립적으로 생산하고 이러한 이중 칩을 연결하는 방식으로 단일 칩에 있는 기능을 별도의 칩으로 생산하여 연결
- 설계 난이도의 어려움 및 고성능 칩과 저성능 칩 결합으로 비용 최적화

제2절 AI 반도체와 수평적 가치사슬의 변화

1. AI 반도체 등장에 따른 수평적 가치사슬의 변화 이슈

□ 기존 수평적 가치사슬

- 기존의 주요 플레이어 사이에 명확한 사업 범위에 따른 단계적인 가치사슬 형태에
서, 사업 범위와 역할, 보유역량이 주요 플레이어 사이에 겹치고 더욱더 포괄적인
영역에서 경쟁하는 동시에, 생태계 구축을 통해 협업하는 입체적인 가치사슬로 변
화하고 있음

[그림 3-10] 기존 반도체 가치시스템



자료: 삼성전자 웹페이지, <https://semiconductor.samsung.com/kr/news-events/tech-blog/from-foundry-to-fabless-an-overview-of-the-semiconductor-ecosystem/>

- 전통적인 비메모리 반도체 가치사슬은 SIP/EDA 제공·활용 → 비메모리 반도체 설계(Fabless/Design House) → 반도체 칩 양산(Foundry/OSAT) → 판매(디바이스 제조 업체/최종 수요자) 등으로 활동의 범위가 명확하게 분업화

□ AI 반도체와 수요 측면에서 변화

- 엔비디아, AMD, 인텔과 같은 글로벌 반도체 기업의 AI 반도체 칩 개발 경쟁이 격화되고 있는 가운데, 최종 수요기업인 마이크로소프트, 구글 등 주요 빅테크 기업의

자체 AI 반도체 칩(ASIC)개발 수요도 대두

- Google, Amazon, Tesla, Apple 등 전통적인 반도체 기업이 아닌 인터넷 기업, 자동차 기업 등이 자사의 제품에 탑재하기 위한 AI 반도체를 자체적으로 설계 및 개발
- 기존 반도체 산업의 가치사슬 참여 기업이 아닌 대형 인터넷 기업 등이 자사의 서비스나 최종 제품에 최적화된 AI 반도체를 조달하여 활용하기 위해, 반도체 설계 조직을 내부적으로 구축하고, AI 반도체 설계 역량을 본격적으로 갖추기 시작
- AI 서비스 경쟁이 본격화됨에 따라, AI 반도체 시장을 선점하기 위해 전통적 반도체 기업들(퀄컴, 인텔, 엔비디아)은 물론, 글로벌 빅테크들(구글, 아마존, 애플, 테슬라 등)도 기술개발에 참여 중
- 최근 생성형 AI 시장 선점을 위해 인프라 영역의 AI 반도체에 대한 국내외 빅 테크 기업의 수요가 급증함에 따라, AI 서비스 시장 선점을 위해 AI 반도체 기술을 보유한 전문업체에 대한 투자와 인수를 진행할 전망
- 기존 반도체와 AI 생태계가 융합된 특성으로 인해 주요 반도체 기업은 기존의 사업 영역을 확대하면서 융합시장 방향으로 생태계를 확장하고자 함
 - － (기존 반도체 기업) 반도체 칩의 성능을 지속해 향상하면서 전문성, 안정성, 호환성을 기반으로 다양한 활용 산업 영역에서 AI 반도체 칩 제공
- 빅테크 기업은 사업 초기에 전문성, 호환성, 안정성 측면에서 반도체 기업의 제품을 사용하지만, 자사 AI 알고리즘 수행에 최적화된 AI 반도체의 필요성으로 인해 자체 칩을 설계하는 단계를 지나서 최종적으로는 기존 반도체 생태계를 적극 활용하여 자사 AI 반도체를 양산할 전망

□ AI 반도체와 수평적인 가치사슬의 기술 공급 측면에서 변화


- AI로 인한 환경변화에 기술적으로 대응하기 위해, 기존 반도체 산업에서 AI 반도체 산출과 관련된 다양한 자원과 역량을 기업 내·외부에서 조달하거나, 협업해야만 하는 복잡한 기술환경으로 변화
- 특히 TSMC, 삼성전자 등 기존 글로벌 파운드리 업체들은 최첨단 미세공정(ex) 2나노]에서 AI 반도체 설계·제조를 위해 Design House/EDA/SIP/OSAT 파트너사와 함께 생태계를 구성하여 설계 및 시제품 생산을 진행 중

- 과거 기존 비메모리 반도체 대비 AI 반도체 개발 난이도 및 비용이 매우 커진 상황이기 때문에, AI 반도체 설계 및 생산의 실패 리스크를 줄이고자, 생태계를 중심으로 다양한 관련 기술 제공 전문기업과 파트너십을 강화할 가능성이 커짐
- AI 반도체 설계의 복잡도가 극도로 고도화됨에 따라 기존 반도체 참여 기업은 M&A를 통하여 새로운 기술을 흡수하는 동시에, AI 반도체 분야의 주도권을 조기 확보하기 위해 노력
- 기존 반도체 산업의 주요 플레이어는 과거 수행해온 사업 범위를 넘어서, AI 반도체 관련 지원 기술을 지속해 개발/업그레이드하거나 협업을 통해 보완적인 기술을 외부에서 확보하여, 적기에 AI 반도체를 생산할 수 있는 다양한 역량을 보유하는 것이 중요해짐
- AI 반도체 관련 동종 또는 보완 기술 업체를 인수·합병하여 신사업 분야 진입, 기존 사업 포트폴리오 다각화 및 경쟁력 강화가 필수적인 환경이 도래
- AI 반도체의 등장으로 반도체 생태계는 기존 반도체 생태계와 AI 관련 가치사슬이 융합된 새로운 생태계로 볼 수 있음

2. AI 반도체 등장에 따른 수평적 가치사슬의 변화 방향

- ☐ 주요 플레이어 사이에 명확한 사업 범위에 따른 기존의 단계적인 가치사슬에서, 사업 범위와 역할, 역량이 주요 플레이어 사이에 겹치고 포괄적으로 경쟁하는 좀 더 입체적인 가치사슬로 변화할 전망
- ☐ AI 반도체와 수평적 가치사슬의 변화 I
 - ASSP(Application Specific Standard Product) 칩의 경우, 직접 글로벌 경쟁력을 보유한 팹리스가 직접 Foundry와 협의

[그림 3-11] AI 반도체와 수평적 가치사슬의 변화 I



자료: 저자작성

- 기본적으로 글로벌 팹리스 업체들은 반도체 설계에 집중하고, 반도체 전(前)공정은 대만의 TSMC와 한국의 삼성전자 등 주요 파운드리에 양분하여 수주(위탁생산)를 맡기며, 후(後)공정은 BYD, 폭스콘, 실리콘웨어, KYEC 등 중국과 대만의 업체가 진행
 - － 내부에서 개발한 SIP을 중심으로 ASSP로 자리잡은 반도체 [ex] GPU, AP, MCU ..)의 경우, 파운드리에 위탁생산하고 생태계 지원 서비스를 통해 도움을 받음
 - － 파운드리는 주요 팹리스 고객에게 첨단 미세공정 기반의 AI 반도체 생산뿐 아니라, AI 반도체의 패키징과 시스템 구성 최적화에 이르기까지 폭넓은 영역을 지원


○ Intel Foundry의 시스템즈 파운드리 역할 지향

- － AI 시대를 위한 세계 최초 시스템즈 파운드리(systems foundry) 출범으로 최고의 기술, 탄력성, 지속가능성 제공
- － 반도체 설계 관련 생태계의 파트너들이 인텔의 18A(1.8나노) 공정과 첨단 패키징 기술에 대해 검증된 톨, 설계 플로우 및 IP 포트폴리오를 통해 고객 지원
- － 패키징과 테스트, 시스템 구성, 최적화와 공급망에 이르기까지 폭넓은 지원 서비스 제시
- － 실리콘에서 검증한 IP 포트폴리오, 가속기, 칩렛 표준과 소프트웨어, 2D, 2.5D, 3D 고급 패키징이 포함

□ AI 반도체와 수평적 가치사슬의 변화 II


- ASSP(Application Specific Standard Product) 칩의 경우, 중소 팹리스가 디자인하우스를 통하여 Foundry에 위탁생산
- 팹리스 업체는 고정 비용이 파운드리 대비 낮아 전 세계적으로 몇천 개의 중소 규모의 팹리스 업체들이 존재하며 미국, 대만, 중국, 한국 등에 존재
- 중소 팹리스 업체들은 반도체 주요 설계와 마케팅에만 집중하고 디자인하우스를 통해 설계, 생산, 패키징, EDA, SIP 등 다양한 서비스를 지원받음

[그림 3-12] AI 반도체와 수평적 가치사슬의 변화 II



자료: 저자작성

○ 삼성전자 파운드리 디자인하우스 가온칩스의 역할 지향




자료: 가온칩스(2022)

□ AI 반도체와 수평적 가치사슬의 변화 III

- ASIC(Application-Specific Integrated Circuit) 칩의 경우, 수요기업이 디자인하우스를 통하여 Foundry에 위탁생산
- AI 반도체 설계 능력 발전을 위해서는 결국 최종 수요자의 종합 시스템(최종 제품 Set + 최종 서비스)에 따른 설계 역량이 중요해짐
- AI 반도체의 주도권이 기존 전통적 팹리스를 넘어선 중소규모의 최종 수요기업 전체로 확대될 전망
- 기존 전통적 중소 팹리스 전문업체는 디자인하우스/SIP로 변화하거나 인수합병될 것으로 전망
- 설계 최적화 및 테스트, 기타 지원 서비스를 제공하는 디자인하우스의 역할 중요

[그림 3-13] AI 반도체와 수평적 가치사슬의 변화 III




자료: 저자작성

□ AI 반도체와 수평적 가치사슬의 변화 IV

- ASIC(Application-Specific Integrated Circuit) 칩의 경우, 수요기업이 직접 Foundry에 위탁생산
- AI 반도체 제조는 단순히 하드웨어 설계·생산에서 그치는 것이 아니라, 사용처별의 요구를 깊이 이해하고, 이러한 요구에 맞는 AI 반도체를 생산할 수 있어야 함
- 수요기업이 원하는 것은 ① 합리적인 가격, ② 사용처별 성능(사업적 필수조건: 전력소모, 수행능력, 사용 애플리케이션 ...) 등을 충족할 수 있는 맞춤형 AI 반도체
- AI 반도체의 주도권(설계능력: EDA/SIP에 대한 기본적인 이용역량)도 기존 전통적 팹리스를 넘어서 빅테크 기업 전체로 확대
- 패키징과 테스트를 전담하는 후공정업체(OSAT)의 역할이 중요해질 전망

[그림 3-14] AI 반도체와 수평적 가치사슬의 변화 IV



자료: 저자작성

제3절 AI 반도체와 ON Device AI

1. ON Device AI 이해

□ 차세대 딥러닝(Deep Learning) 기술로 온디바이스(On-Device) AI


- 학습하고 추론하는 인공지능에 관한 관심이 높아짐에 따라 앞으로는 스마트폰이나 로봇청소기, 세탁기 등에서의 사물인터넷까지 광범위하게 AI 기술 적용이 가능
- 기존 인공지능 기술은 스마트기기(smart device)에서 수집한 정보(데이터)를 중앙 클라우드 서버로 전송해 분석하고 다시 기기에 보내는 방식으로 진행
- 이와는 대조적으로 온디바이스(On-device) AI는 네트워크로 연결된 클라우드 서버를 거치지 않고 스마트기기 자체적으로 정보를 수집하고 학습 및 추론
- 온디바이스 AI는 단말기 기기 내부에서 데이터를 처리(학습 및 추론)하기 때문에 지연이 없는 빠른 작업 수행이 가능
 - － 클라우드 서버를 거치지 않기 때문에 자료수집과 전송에 걸리는 시간이 짧아져 저지연을 실현(네트워크 및 클라우드 과부하 문제 발생 해결)
- 중앙 서버를 통하지 않기 때문에 클라우드 기반 AI의 문제점으로 대두되었던 보안 문제도 해결
 - － 클라우드 서버에 데이터를 전송하지 않기 때문에 개인정보 보호
- 별도의 네트워크가 필요 없으므로 인터넷 연결이 어려운 상황에서도 실시간 학습 및 추론이 가능(다양한 재난 및 재해 환경에서 서비스 가능)
 - － 인터넷 연결이 불가능한 환경에서도 사용할 수 있어 안정성이 높음

[그림 3-15] 클라우드 서버를 사용하는 인공지능과 온디바이스 인공지능의 비교



자료: 삼성전자 웹페이지, <https://semiconductor.samsung.com/kr/news-events/tech-blog/all-about-exynos-2-an-upgraded-mobile-experience-the-important-role-of-cpu-and-npu-in-smartphones/>

[그림 3-16] 중앙집중형 AI 방식 대비 온디바이스 AI 방식



자료: 이석준(2021)

- AI 서비스를 위한 인프라 비용 문제가 대두되어 이를 해결할 수 있는 대안
 - － 생성형 AI 모델이 복잡해질수록 추론에 필요한 인프라 비용은 급격히 증가
 - － 학습과 달리 추론은 사용자 수와 사용하는 빈도(횟수 및 시간)가 중요해짐
 - － AI 모델의 추론을 전부 클라우드 방식으로 데이터센터에서 처리하면 막대한 인프라(서버, AI 반도체, 네트워크 ...) 비용이 필수적
 - － 간단한 추론은 스마트폰, PC 등 기기의 자원을 활용할 필요성이 증가

□ 엣지(Edge)에 위치하는 온디바이스와 AI

- 기존에는 클라우드 서버가 정보를 처리하는 중앙처리영역이라면 스마트폰이나 태블릿 PC 등은 사용자와 접점을 이뤄 정보를 수집하는 단말기와 같은 역할을 담당
- 하지만 이러한 클라우드 기반의 AI 서비스 처리 방식은 원격의 인공지능이 실제 데이터가 발생하고 있는 현장을 본질적으로 이해하기는 어렵다는 한계 존재
- 현장에서 직접 접촉하여 정보를 얻는 하드웨어인 엣지 디바이스에 AI가 결부된 형태인 온디바이스 AI는 실제 데이터를 얻는 환경을 직접 경험하고 학습 및 추론하기 때문에 실제 사용처에 더욱 적합한 결정을 진행할 수 있음

2. ON Device AI와 AI 반도체

□ 단말기에 탑재된 AI 모델 및 AI SW

- AI는 클라우드 서버에서 데이터를 수집하고 학습한 후, 추론한 결과를 기기에 전송하는 방식으로 진행되지만, 이러한 방식은 자료수집과 전송에 시간이 소요될 뿐만 아니라, 인터넷 연결이 불가능한 환경에서는 사용할 수 없다는 단점이 존재

- 퀄컴의 클라우드와 단말기기가 AI 연산을 분산 처리하는 『The Future of AI is Hybrid』⁸⁾
 - AI에는 모델 학습이나 추론 작업을 처리하기 위한 거대한 인프라가 필요하며, 이를 위해 클라우드를 이용
 - 동시에 AI에는 즉시성도 요구(AI가 유용해지려면 실제 행동이 일어나는 장소, 즉 모바일 기기인 엣지에서 정보를 처리)
 - 대규모 생성형 언어 모델은 학습에 수개월이 소요되며 막대한 양의 데이터를 신속하게 처리하는 성능을 가진 복잡한 서버 및 AI 반도체 하드웨어가 필요
 - 모바일 기기는 로컬 수준에서 작은 규모의 언어 모델을 처리할 수 있어, 모바일 기기가 엣지에서 간단하고 쉬운 AI 처리를 담당함으로써 클라우드는 더 크고 강력한 작업을 관리
 - 모바일 디바이스도 더 강력하고 능력 있는 AI 작업을 수행하여, 사용자들은 스마트 단말기가 있는 곳에서 생성형 AI를 빠르고 쉽게 이용할 전망

[그림 3-17] 온 디바이스 장치 중심의 하이브리드 AI 아키텍처



자료: Qualcomm(2023)

- 온 디바이스 AI는 이러한 단점을 보완하기 위해 단말기 자체에 AI 연산을 지원할 수 있는 AI 반도체를 탑재함으로써 네트워크 연결 없이도 기기 스스로 가벼운 AI 학습과 추론을 수행하는 것이 가능
- 단말기 중심의 하이브리드 AI 아키텍처에서 클라우드는 단말기가 충분히 수행할 수

8) Qualcomm(2023)

없는 AI 작업에서만 활용

- 온 디바이스 AI Model, 온 디바이스 AI SW, 온 디바이스 AI HW 등 각 기술 계층에서 온 디바이스 AI 서비스를 실현하기 위하여 노력⁹⁾
 - － (Lightweight AI Model) 단말기라는 제한된 성능과 공간에서 AI 연산의 매개변수(parameter)를 줄이면서 성능의 저하를 최소화한 AI 모델 경량화 개발¹⁰⁾
 - ※ Meta의 Llama는 GPT-3보다 적은 매개변수(parameter)로도 벤치마크에서 우수한 성능을 보였으며, Llama 2는 parameter 규모 70억개, 130억, 700억개 등 총 3개의 모델로 구분
 - ※ 가장 작은 parameter를 가진 Llama 2 모델은 단일 GPU(혹은 NPU)로 가동할 수 있으므로 생성형 AI를 단말기에서도 구현
 - ※ Llama 2는 매개변수가 최소화된 경량화된 모델임과 동시에, 오픈 소스이기 때문에, Qualcomm, Mediatek 등 주요 업체들의 Llama 2를 지원할 수 있는 수준으로 뉴럴 엔진을 설계
 - － (AI Inference SW) 엣지 AI를 위해 모델개발 혹은 최적화를 지원하는 프레임워크 및 SW 기술이 지속해 연구되고 있음¹¹⁾
 - ※ (Google) TensorFlow Lite 프레임워크를 통해 마이크로컨트롤러, 모바일 등에서 AI 모델변환, 실행, 최적화를 지원하는 모바일라이브러리 제공
 - ※ (Nvidia) 소비자 PC에서 대형언어모델(LLM)의 성능을 향상하도록 설계한 새로운 소프트웨어 도구를 출시, 저사양 GPU에 대한 접근성을 높여 PC는 물론 스마트 장치에서 가동하는 온디바이스 AI 기술 보편화를 가속하겠다는 구상
- AI의 성능은 하드웨어·시스템 SW·응용 SW의 최적화로 결정되기 때문에 하드웨어 뿐만 아니라 이를 운영하고 응용 소프트웨어를 지원하는 시스템 소프트웨어, AI 모델, 서비스까지 모두 중요

9) 이석준(2024)

10) Meta 웹페이지, <https://llama.meta.com/llama2>

11) 김병수(2023)

□ 단말기에 탑재된 AI 반도체

- AI 모델이 가벼워지고 있는 동시에, 이를 지원하는 AI 반도체(AI Neuromorphic Chip & NPU) 성능은 강화되고 있음
- ※ (삼성전자) NPU를 독자적으로 설계하고 개발에 투자하고 있는데, 2018년 엑시노스 9820에 처음으로 NPU를 탑재, 엑시노스 10시리즈(엑시노스 1080, 엑시노스 2100)에 모두 NPU가 탑재
- ※ (LG전자) 엘지는 가전 등에서 온디바이스 AI를 수행할 수 있도록 LG8111 AI SoC 솔루션을 개발
- ※ (Apple) 애플은 얼굴인식, 음성인식으로 대표되는 자사의 인공지능 서비스 품질 향상을 위해 뉴럴 엔진이라는 NPU를 독자적으로 개발하여 AP(Application Processor)와 통합된 형태로 제품을 출시하여 왔으며, XNOR를 인수하는 등 경쟁력을 지속적으로 강화
- ※ (Qualcomm) 퀄컴은 NPU 개발을 비교적 일찍부터 시작했는데, 독자적인 NPU인 제로스(Zeroth)를 개발하였으며, Hexagon이라는 DSP(Digital Signal Processing)를 탑재하여 AI 연산을 수행
- ※ (ARM) Arm은 온디바이스 AI를 위한 microNPU 제품군을 개발했는데, 클라우드부터 엣지에서 사용 가능한 고사양의 Ethos-U 시리즈와 디바이스에서 사용 가능한 저전력의 Ethos-N 시리즈를 출시

제4절 활용처 분야별 인공지능 반도체 기술 분석

- Vision, language, speech, 그리고 robotics 등 지속적인 인공지능 알고리즘의 발전은 다양한 분야에 활용될 가능성을 열었으며, 기존의 일반적인 반도체의 활용 분야에서 인공지능 알고리즘을 구동할 수 있는 반도체들은 인공지능 반도체로서의 활용 가치가 높음
- Gartner가 분류한 일반적인 반도체의 활용 분야는 아래와 같음
 - Automotive Electronics
 - － 차량용 반도체는 자동차가 스스로 운전하거나 전기로 움직일 수 있도록 각종 시스템을 제어하는 반도체¹²⁾
 - － 전기차 보급이 늘고 자율주행 기능이 발전하면서 자동차에 탑재되는 반도체 칩의 수가 증가
 - － 주로 정보 저장 용도의 메모리 반도체가 사용되기보다는 연산, 추론 등 정보 처리용 시스템 반도체가 사용
 - － 가솔린, 디젤 등 내연기관 자동차에는 평균 200~300개, 전기차에는 1,000개, 자율주행차에는 2,000개 이상의 반도체가 탑재될 전망
 - － 종류로는 ADAS용 IC, 고전류 출력을 위한 드라이버 IC, 전원 공급을 위한 파워 IC, 자동차 전장 시스템을 제어하는 MCU 등이 있음
 - Communication Electronics
 - － 통신용 반도체는 근거리 유/무선 통신, 광역 네트워크, 모뎀, 기타 통신 응용 분야에 사용되는 모든 반도체를 의미
 - － 일반적인 작업 수행용 통신 네트워크 프로세서, 음성/데이터 신호 처리용 DSP, 메모리, 송수신기 및 모뎀 등 다양한 IC들을 포함
 - － 반도체 칩 고유의 조건으로는 다양한 기능의 집적이 필요하고, 여러 신호 처리 알고리즘을 처리할 수 있는 연산기가 포함되어야 하며 디지털 및 아날로그의 혼성 신호 디자인이 필요

12) 전황수 외(2021)

- 동작 조건으로는 일반적으로 배터리 기반의 모바일 기기에서 활용되므로 저전력 동작이 필수적이며 고속 데이터 처리가 필요하며 다양한 주파수 밴드에서 동작하여야 한다는 조건이 있음
- Consumer Electronics
 - 소비자 가전용 반도체는 TV, wearable device, 셋톱박스, 비디오 게임 콘솔, 스마트 스피커 등 가전제품에 탑재되는 반도체를 의미
 - 가전제품에 가장 기본적으로 탑재되는 반도체는 OS 없이 동작하는 임베디드 시스템인 MCU이며 다양한 주변 장치와 연결되어 연산, 제어, 출력 등의 역할을 하는 저성능 저전력 반도체
 - 최근 가전제품이 인공지능 제어, 음성인식 등 다양한 인공지능 기능을 탑재하게 되면서 가전용 AI 반도체 필요성이 증가
 - 또한, 무선 통신을 통해 다양한 디바이스가 서로 연결되는 IoT 기술이 가전제품에도 활발하게 적용되면서 24시간 자료를 수집하기 위한 저전력 및 보안성이 높은 반도체에 대한 수요 증가하는 중
- Data Processing Electronics
 - 데이터 연산용 반도체는 데스크톱, 서버, 그래픽카드, 메모리 등 일반적인 컴퓨팅 유닛에 사용되는 반도체를 의미
 - ChatGPT의 출시 전후로 딥러닝 언어모델의 크기가 갈수록 거대화됨에 따라 거대 모델의 추론 및 학습을 지원하는 서버용 인공지능 반도체의 개발이 활발하게 이루어지고 있음
 - 일반적으로 컴퓨팅과 메모리 리소스를 증가시키기 위한 방향과 컴퓨팅 유닛 간, 혹은 메모리와 컴퓨팅 유닛 간의 통신 대역폭을 증가시키고 레이턴시를 감소시키기 위한 방향으로 개발되고 있음
 - 컴퓨팅과 메모리 리소스를 증가시키는 방법으로는 같은 동작을 하는 다수의 병렬 컴퓨팅 유닛과 용량이 큰 메모리인 HBM 등을 탑재하여 연산 성능을 높임
 - 컴퓨팅 유닛 간 통신 성능 향상을 위해 각 선도기업은 고유의 인터커넥트 기술을 개발하며, 메모리와 컴퓨팅 유닛 간의 통신 성능 향상을 위해서 HBM의 고대역폭을 활용하고 PIM의 구조를 활용

○ Industrial Electronics

- 산업용 반도체는 공장 자동화, 지능형 건물 시스템, 수송 등 산업 전반에 사용되는 반도체를 의미
- 공장 자동화 용 반도체는 모션 컨트롤, 로보틱스, 모터 드라이브, automatic optical inspection(AOI) 검사에 주로 사용
- 지능형 건물 시스템은 사고를 예방하기 위한 감시 시스템, 온도 및 조명 조절, 건물 보안 등의 application에 주로 사용
- 수송용 반도체는 항공기 조종, 드론, 센서 및 센서 데이터 프로세싱, 물류와 같은 시스템에 주로 사용되는 반도체

□ Gartner가 분류한 반도체의 활용 분야 중 인공지능 반도체가 활발하게 활용되고 있는 분야와 해당 분야에 요구되는 반도체 특성, 그리고 실제로 개발된 인공지능 반도체 제품의 예시는 아래와 같음

○ Automotive Electronics

- 특히 자율주행차에 적용될 차량용 반도체에 인공지능 가속기인 NPU가 탑재될 수 있으며 주로 ADAS, 카메라 기반 전면부 감지, 운전자 모니터링 등의 분야에 활용될 수 있음
- 차량용 인공지능 반도체가 일반적인 엣지 반도체와 비교하여 필요로 하는 요건은 동작 주파수, 전압, 실패허용률이 대표적임
- 차량용 인공지능 반도체의 동작 주파수는 일반적인 모바일용 가속기에 비해 높아야 하며 이는 사용자의 안전과 관련된 연산 처리 속도를 높여 빠른 감지 및 반응을 요구하기 때문
- 또한, 높은 수준의 안전성과 내구성이 필요하므로 동작 전압은 높아야 하며 실패허용률은 0%를 충족하여야 함
- NVIDIA는 2015년 자율주행에 사용될 수 있는 차량용 칩셋인 NVIDIA DRIVE를 발표하였으며 이는 차량의 다양한 센서로부터 데이터를 받아 처리하며 주변 환경을 인지하고 자율주행을 수행
- Tesla는 AI 이미지처리 능력에 특화된 완전자율주행(FSD)용 칩 설계를 수행하여

2021년 Tesla AI day에서 D1 chip을 발표

- 국내 팹리스 업체로는 텔레칩스가 오픈엠티테크놀로지의 차량용 반도체 IP인 N-Dolphin를 활용하여 ADAS용 반도체 개발을 완료
- 넥스트칩은 NPU를 내장한 차량용 인공지능 반도체인 아파치5를 공급하고 있으며 추후 아파치6을 후속 제품으로 출시할 예정

[그림 3-18] NVIDIA Drive 개념도



자료: <https://www.nvidia.com/ko-kr/self-driving-cars/>

○ Consumer Electronics

- 가전용 반도체에 인공지능이 적용될 수 있는 기능으로는 자동 가전 제어, 음성인식, 멀티모달 인터페이스가 있음
- 예를 들어, 자동 가전 제어는 이미지, 영상, 생체 기반 센서를 통해 사용자 및 공간의 상황을 인지한 후 자동으로 가전의 동작과 같은 제어를 실행하는 것
- 음성인식 및 멀티모달 인터페이스는 버튼 및 터치를 통한 가전의 제어 이외에도 음성, 영상(모션 및 얼굴 인식) 등 다양한 방법으로 가전의 제어를 수행하기 위한

기술을 의미

- 가전제품은 24시간 데이터를 수집하는 기능이 탑재되고 있고, 일반적인 사용자가 수요층이므로 가격에 매우 민감한 분야이기 때문에 가전용 인공지능 반도체는 저 전력 및 저가를 만족해야 함
- 대표적으로, 2023년 LG 전자는 자체 개발한 가전용 AI 반도체인 DQ-C 칩을 신제품 가전에 탑재하였으며 이보다 앞선 2022년에는 AI 반도체 DQ-1 칩을 냉장고에 탑재
- 국내 팹리스 기업 딥엑스는 2022년 일반 가전에 추론 기능과 제어 기능을 탑재하여 최적의 성능을 발휘할 수 있는 저가의 초저전력 AI 반도체 및 보드 개발 지원을 수행하였으며 2023년 독일에서 열린 IFA에서 밀레, 보쉬 등 현지 가전 업체에 해당 제품을 홍보

[그림 3-19] 딥엑스의 DX-M1 AI chip



자료: DeepX

○ Industrial Electronics

- 산업용 AI 반도체는 일반적으로 보안, 연결성, 신뢰성이 중요
- 응용 분야에 따라 실시간 위험 감지가 필요한 경우 낮은 지연시간이 요구되며, 높은 해상도와 높은 프레임 레이트를 가지는 비디오 처리가 필요한 경우 높은 스루풋이 요구
- 이스라엘 인공지능 반도체 기업인 Hailo는 2019년 Hailo-8 칩을, 2023년 Hailo-15 칩을 발표하며 4차 산업의 공장 자동화 중에서도 이상 탐지, 정확도 높은 sorting,

- AOI를 수반한 pick and place 분야에 활발하게 적용하고자 하는 시도를 수행 중
- Mythic은 인 메모리 컴퓨팅 아키텍처를 기본으로 하는 아날로그 컴퓨팅 솔루션인 아날로그 행렬 연산 프로세서 M1076을 출시하고, 이를 다양한 산업용 반도체에 탑재하고자 하는 노력을 기울임
 - 적용 분야는 스마트 시티, 지능형 로봇, 스마트 제조, 드론 및 항공우주를 목표로 하고 있으며 아날로그 프로세서가 제공하는 최상의 성능과 전력을 산업용 반도체 분야에 활용

[그림 3-20] Mythic의 MM1076 M.2 M Key Card 제품 사진



자료: mythic.ai

제 4 장 국내외 인공지능 반도체 정책 현황

제 1 절 국내 반도체 정책 현황

1. 우리나라의 반도체 및 인공지능 반도체 지원정책 개요

- 정부는 오랜 기간 동안 반도체 분야의 산업경쟁력을 높이고, 선도적인 국가로 발돋움하기 위해 지속해 종합적·다각적인 전략을 수립 및 추진
 - 역대 정부는 기술개발(R&D) 지원, 전문인력 양성, 대·중소기업 동반성장, 생태계 육성, 펀드조성, 세액공제, 통상환경 개선 등을 지원하는 종합계획을 범부처 차원에서 지속적으로 발표하고 세부 사업들을 추진
 - 특히 국내 메모리반도체 분야는 고도화된 기술기반의 과점산업 구조로 미세공정개발 R&D 투자 및 자본집약도가 큰 설비투자가 요구되는 종합반도체업체(IDM) 중심의 대기업이 주축이어서 정부는 세제지원 및 규제완화 등을 통해 지원

〈표 4-1〉 우리나라(인공지능) 반도체 산업 육성정책 및 주요 내용

정책/부처발표시기	주요내용
시스템반도체 및 장비산업 육성전략 [산업통상자원부(2010. 7. 31)]	시스템반도체 및 반도체장비 산업을 체계적으로 육성하기 위해 수요기업-팹리스 연계, 중소·중견 시스템반도체·장비 육성, 반도체 클러스터 조성, 인력육성정책 추진
반도체산업 재도약 전략 [산업통상자원부(2013. 10. 23)]	반도체를 성장동력으로 지속 육성하기 위해, 메모리, 시스템반도체, 장비·소재, 인력·인프라 분야 집중 지원
지능형반도체 전문인력 양성사업 [산업통상자원부(2016. 9. 29)]	기업수요에 맞는 고용연계형 석사급 반도체 전문인력 양성하고, 바로 취업으로 이어질 수 있는 생태계 구축
반도체 희망펀드 조성 [산업통상자원부(2016. 10. 27)]	삼성전자, SK하이닉스, 정책금융기관 등이 2천억 규모의 반도체펀드를 조성하여 팹리스, 소재/장비기업에 투자

정책/부처발표시기	주요내용
시스템반도체 산업경쟁력 강화방안 [산업통상자원부(2017. 3. 30)]	시스템반도체 선도국으로 도약, 시스템반도체 R&D 및 인재 양성, 글로벌 수요연계 지원
시스템반도체 비전과 전략 [관계부처 합동(2019. 4. 30)]	시스템반도체 전반을 본격 육성하고 종합반도체 강국으로 도 약, 팹리스 성장기반구축 및 파운드리 경쟁력 제고
인공지능 국가전략 [과학기술정보통신부 (2019. 12. 17)]	IT강국을 넘어 인공지능(AI) 강국 달성을 위해 경제·사회 전 반의 혁신을 위한 9대전략 제시. 특히 AI 반도체 및 신개념 반도체(PIM) 개발에 전략 투자
인공지능 반도체산업 발전전략 [관계부처 합동(2020. 10. 12)]	인공지능 반도체 관련 기술개발(R&D) 강화, 기술사업화, 인 력양성, 금융지원, 기반구축, 생태계 구축 지원을 통해 인공 지능·종합반도체 강국 실현
시스템반도체 기술혁신 지원 [관계부처 합동(2021. 2. 1)]	K-팹리스 성장지원, 유망시장 선점, 신시장도전(AI 반도체, PIM반도체), 예타준비사업(K-센서, 차세대 PIM반도체) 추진
K-반도체전략 [대한민국 정책브리핑 (2021. 5. 13)]	K-반도체 벨트를 구축해 세계 최대·최첨단 반도체 공급망을 구축하고, 2030년까지 510조원 이상의 민간투자자로 초격차 유 지, 반도체 인력 3만 6000명 육성
인공지능(AI) 반도체 산업 성장 지원대책 [과기정통부(2022. 6)]	• 인공지능반도체 첨단기술 연구에 향후 5년간 1조 200억원 투입 • 국산 인공지능반도체 초기수요 창출을 위한 대형 가늌터 구축 및 공공사업 적용 확대 • 차세대 반도체 상용화 위한 대기업과 산·학·연 간 첨단 공 정기술 협력 • 인공지능반도체 전문인력 7,000명 이상 양성
반도체 관련 인재 양성방안 [관계부처 합동(2022. 7)]	향후 10년간 약 13만 명의 신규 인력수요에 대응해 기술발전 을 선도할 반도체 혁신인재를 2031년까지 15만 명 이상 양성
국산 인공지능 반도체를 활용한 케이(K)-클라우드 추진방안 [과기정통부(2022.12)]	세계 최고 수준의 초고속·저전력 국산 인공지능반도체를 개 발, 이를 데이터센터에 적용해 국내 인터넷기반자원공유 경 쟁력을 강화하고, 국민들에게 향상된 인공지능 및 인터넷기 반자원공유 서비스를 제공하기 위한 정책

- ☐ 최근 반도체 산업에서 파운드리 영역이 차지하는 중요성이 높아지고 시장 규모도 확
대되고 있어, 파운드리 경쟁력 제고를 위한 정부차원의 노력도 이어지고 있음
- ☐ 또한 국내 시스템반도체 산업은 팹리스, 테스트, 패키징 등 분야별 혁신기업 및 중소
기업들이 많이 있어 생태계 구축, R&D지원, 기술사업화, 투자연계, 기반조성 등 다양
한 성장지원 및 생태계 조성을 위한 정책을 이어지고 있음

- 특히 인공지능 기술 및 데이터 생태계 기반이 되는 인공지능 반도체의 기술력 및 기능이 통신, IoT, 자동차, 가전 등 다양한 산업경쟁력의 관건이 되어감에 따라, 정부는 인공지능 반도체 산업을 전략적으로 육성하기 위해 집중적인 투자를 시작


2. 국내 반도체 산업 육성을 위한 주요 전략 및 내용

가. 시스템반도체 비전과 전략(2019. 4)

- 정부는 시스템반도체 산업을 육성하고 2030년까지 종합반도체 강국으로 도약하기 위한 5대 중점대책을 수립하고, 이를 통해 2030년까지 1) 파운드리 세계 1위, 2) 팹리스시장 점유율 10% 달성, 3) 2.7만명의 신규일자리를 창출할 계획을 발표
 - 정부는 구체적으로 시스템반도체 산업육성을 위해 ① 팹리스 지원, ② 파운드리 지원, ③ 생태계 구축, ④ 인력양성, ⑤ 기술지원 등 5개 분야에 대해 집중적인 중점대책을 수립
 - ① (팹리스 성장기반 구축) 수요를 창출하고 성장 단계별 지원을 강화하는 정책 마련
 - 대대적 수요창출(5대 시장 수요연계, 공공수요 2,600만 개·2,400억 원 이상 발굴, 5G와 시스템반도체 연계)
 - 전용펀드(1,000억 원) 신설, 스케일업펀드
 - 우수기업연구소 선정 등 스케일업 지원, 반도체 설계툴 지원(추경 46억원),
 - 창업부터 성장단계까지 원스톱 서비스 제공을 통해 글로벌 수준 성장기반 마련
 - ② (파운드리 지원) 첨단 및 틈새시장을 동시공략해서 파운드리 세계 1위 도전
 - 대표기업은 하이테크(High-Tech) 첨단분야에서, 중견기업은 미들테크(Middle-Tech) 틈새시장을 공략하고, 기업의 투자를 뒷받침할 수 있도록 세제·금융 지원 확대
 - ③ (생태계 구축) 팹리스와 파운드리가 상생 협력할 수 있는 생태계를 조성
 - 디자인하우스 육성, 팹리스의 파운드리 공정 활용확대 등 정부-업계 공동으로 상생협력 생태계 조성
 - ④ (인력양성) 정부와 민간이 합동으로 대규모 인력을 양성하여 학사, 석·박사, 기업 수요 맞춤형 실무인력 1.7만 명 양성(2030년까지)

- 계약학과 신설(연·고대, 2021~, 80명(기존정원 외) 및 단계적 확대
 - 반도체설계·공정기술 R&D(정부, 기업 1:1 매칭) 지원
 - 폴리텍대학(안성)의 반도체 특화형 전환, 대학 공정실습 Fab시설 확충(추경 100억)
- ⑤ (기술개발) 산업의 패러다임을 바꾸는 차세대 반도체 기술을 확보
- AI 반도체 등 차세대(Next Generation) 반도체 기술개발에 향후 10년간 1조원 투자
 - 국가 핵심기술의 해외유출방지 시스템 정비

[그림 4-1] '시스템반도체 비전과 전략' 정책의 구조



자료: 과학기술정보통신부(2019. 4. 30)

나. 글로벌 K-팹리스 육성을 위한 '시스템반도체 기술혁신 지원' 전략(2021. 2)

- 정부는 2021년 2월, 종합반도체 강국으로 도약을 위해 국내 팹리스 업체들의 경쟁력 제고가 시급하다고 판단하고, 국내 팹리스 기업의 성장기반을 구축, 유망분야 및 시장에 도전하기 위한 '시스템반도체 기술혁신 지원' 전략을 발표
- 과거 정부는 시스템반도체 비전과 전략(2019. 4), 인공지능 반도체 산업 발전전략(2020. 10)을 발표 이후 차세대 반도체 경쟁력 제고를 위해 R&D지원, 자금지원, 인력양성, 기술사업화 등 전방위적인 정책 지원을 이어오고 있음

- 그런데도 국내 시스템반도체 업체(팹리스 등)들의 글로벌 경쟁력은 미미한 수준으로, 전력반도체 및 AI 반도체 등 차세대 반도체를 해외수입에 의존
- 동 전략에서는 전방위적인 '팹리스의 성장기반 구축'을 지원하고, 미래수요 기반의 '유망시장 선점'을 지원하고, AI 반도체 등 '미래 신기술시장을 선점'하기 위한 정책 추진에 중점
- ① (팹리스 성장 지원) 팹리스의 지속 가능한 성장을 위해 국내·외 시장 맞춤형 R&D를 추진하고 수요 연계형 공동 R&D를 강화하는 정책 추진
 - 글로벌 K-팹리스 육성을 위한 챌린지형 R&D·
 - 설계, 소자, 공정 등 밸류체인 전반의 수요기업 기반 R&D를 통해 국내 수요-공급을 연계하는 대규모 프로젝트 추진
 - 중소 팹리스의 창업·스케일업 촉진
- ② (유망시장 선점) 모바일, 자동차, 헬스케어 등 미래 수요를 기반으로 성장 가능성이 높은 분야의 도전적 R&D를 추진하고, 특히 전력 반도체, 센서 등 핵심 유망품목 적극 지원
 - 미래 전력 반도체 역량강화 및 기술선점·차세대 센서 R&D 신설 및 전주기 지원 체계 마련
- ④ (新시장 도전) AI 반도체 분야 초격차 기술력 확보를 위한 범부처 R&D를 추진하고, 원천기술 개발, 응용기술 개발, 사업화·실증 연계 전주기 지원
 - AI 반도체 플래그십 프로젝트(설계·소자·공정 기술혁신 프로젝트) 추진
 - 세계 최고 메모리 기반 신개념 PIM 반도체(메모리+프로세서 통합) 개발
 - 기술·사업화 장벽 해소 및 실증 지원을 통해 초기 시장 창출 견인
- ⑤ (예타 준비사업) 동 전략을 원활하게 추진하기 위해 예타를 통해 대규모 사업추진
 - 시장선도를 위한 K-Sensor 기술개발 사업
 - 차세대 PIM반도체 기술개발사업

다. K-반도체 전략(2021. 5월)¹³⁾

□ 정부는 2021년 5월 'K-반도체 전략'을 발표하여, 2030년까지 세계 최고의 반도체 공

13) 산업통상자원부(2021. 7. 1)

급망을 구축하기 위해 K반도체 벨트조성, 인프라 지원확대, 반도체 성장기반 강화, 반도체 위기대응력 제고 등 4대 추진전략을 발표

- ① (전략1: 공급망 안정화) 전략1) 국내 반도체 공급망 보완을 위해 △ 소부장 특화단지, △첨단장비 연합기지, △첨단 패키징 플랫폼, △팹리스 밸리 조성 등을 통해 'K-반도체 벨트' 구축
- ② (전략2: 반도체 제조 중심지 도약) 국내 반도체 제조 중심지 도약을 위해 △ 세계 지원, △금융지원, △규제개선, △기반구축 등을 통해 인프라 구축 지원 확대
- ③ (전략3: 인력·시장·기술 확보) 반도체 산업의 성장을 위해 △ 인력양성, △연대·협력, △기술개발 등을 뒷받침하는 역량강화 생태계 조성
- ④ (전략4: 국내산업 생태계 보호) 국내 생태계 보호를 위한 반도체 위기대응력을 제고하기 위해 △ 특별법 제정, △車반도체 수급, △핵심기술 보호 △탄소중립 등 반도체 현안에 적극 대응

〈표 4-2〉 『K-반도체 전략』의 핵심 전략과 주요 내용

	핵심전략	분야	주요 내용
전략 1	K-반도체 벨트조성	제조	첨단 메모리, 파운드리 제조시설이 집중 위치한 국내 최고의 선도형 반도체 단지 조성
		소부장	소부장 특화단지를 조성하고 50여개 협력사 유치, 메모리 양산 팹 연계 소부장 공급망 확보, 테스트-양산 원스톱 지원
		장비	화성, 용인, 천안은 글로벌 장비 기업과의 전략적 협업을 통해 첨단장비 연합기지 구축된 첨단 패키징 플랫폼 조성
		패키징	제품 소형화·고성능화 등 패키징 핵심역량 강화를 위해 실증·분석측정 장비가 구축된 첨단 패키징 플랫폼 조성
		설계	테크노밸리(제1판교)-설계지원센터(제2판교)-차세대 반도체 복합단지(제3판교) 등을 연결하는 팹리스 밸리 조성
전략 2	인프라 지원확대	세계	핵심전략기술 신설을 통해 R&D 및 시설투자를 통해 세계 인센티브 대폭 강화
		금융	국내 반도체 제조기업, 중소·중견 소부장 기업 등에 금융지원 확대. '반도체 등 설비투자 특별자금'을 신설

	핵심전략	분야	주요 내용
전략 2	인프라 지원확대	규제	반도체 설비의 신속한 구축을 위해 고압가스안전관리법, 온실가스 배출권 규정, 화학물질관리법 등 규제 합리화
		기반	반도체 제조시설의 적기 건설과 원활한 운영을 위해 선제적 용수물량 확보, 전력 인프라 구축 및 공공폐수처리 지원
전략 3	반도체 성장기반 강화	인력	전주기 신규 전문인력 확보, 핵심인력의 해외 유출 방지를 위한 정책적·제도적 지원→ 반도체 산업인력 3.6만명 육성
		생태계	반도체 전방산업(수요-공급), 후방산업(소·부·장-소자)의 연대·협력 생태계 강화
		기술	차세대 전력 반도체, 인공지능 반도체, 첨단 센서, 소재·부품·장비 등 다각적인 반도체 新산업 기술역량 제고
전략 4	반도체 위기 대응력 제고	특별법 제정	반도체업계, 반도체 특별법 제정 건의, 특별법 제정 여부 및 입법방향을 국회 및 관계부처와 논의
		차(車) 반도체	단기 수급 안정화를 적극 추진하고, 중장기적으로 미래차 핵심 반도체 개발을 위한 협력모델 발굴
		기술보호	국가핵심기술 지정 확대, 기술·인력 보안관리 강화, 기술안보 강화를 위한 범정부 협의체 구축 추진
		탄소중립	온실가스 감축을 위해 선제적 대응을 위한 R&D 지원 및 인증·실증 기반 강화

자료: 관계부처 합동(2021. 5. 13)

라. 반도체 인력 양성 추진 전략(2022. 7. 8)

□ 정부는 향후 10년간 약 13만 명의 신규 인력수요에 대응해 기술발전을 선도할 반도체 혁신인재를 2031년까지 15만 명 이상 양성하는 “반도체 관련 인재 양성방안”을 발표

○ 본 반도체 인력 양성 추진 정책방안은 3대 분야 10대 과제로 구성되

- (1) 과감한 규제혁파와 지원으로 반도체 관련 정원 확대(양적 확대),
- (2) 고급인력 양성에 주력하면서 반도체 인재 양성 저변 확보(질적 제고),
- (3) 반도체 인재양성 중장기 지원기반 구축(기반 조성) 등으로 구성된 3대 분야와 더불어 3대 분야별 10과제가 매칭되어 제시

(1) 과감한 규제혁파와 지원으로 반도체 관련 정원 확대(양적 확대)

① 산업수요 대응을 위한 대학 정원 규제혁신

※ 반도체 등 첨단분야 학과 신·증설 규제 완화, 계약정원제 도입·운영

- ② 반도체 등 첨단산업 교원 및 대학 운영 규제 혁신
 - ※ 산업현장 전문가를 교수자원으로 적극 활용, 수업 운영요건 완화, 사내대학 운영 활성화
- ③ 과감한 지원, 규제 특례를 통해 반도체 특성화 학과(전공) 육성
 - ※ 반도체 세부 분야별 특성화대학원을 지정·지원, 반도체 특성화대학(원)을 신규 지정, 반도체 분야 계약학과 확대, 직업계고 학과·교육과정 등 재구조화 지원
- (2) 고급인력 양성에 주력하면서 반도체 인재 양성 저변 확보(질적 제고)
 - ④ 고급 전문인재: 반도체 기술 초격차를 이끌어낼 핵심 전문인재 육성,
 - ※ 연구개발 투자 확대 및 반도체 세부분야 전문가 양성, 최고급 인재 유입·양성을 위한 연구개발·교육환경 개선, 산·학·연 프로젝트 및 인적교류 활성화
 - ⑤ 융복합인재: 초학문적 인재 육성을 위한 융합교육과정 활성화
 - ※ [단기] 반도체 분야 단기 집중과정 운영, [중기] 반도체 전공 트랙 운영 활성화
 - ⑥ 실무인재: 산업현장에 즉시 투입가능한 맞춤형 실무인재 양성
 - ※ [단기] 직업계고 반도체 분야 단기 실무과정 확대 및 실습기반 확충, [중기] 현장 맞춤형 교육과정 개선
 - ⑦ 재직자: 수준별 직업훈련과정 대폭 확대
 - ※ [단기] 실습기반이 갖추어진 시설에서 단기 실무 교육과정 제공, [중기] 재직자·경력자 전환교육을 통해 중·고급 인재로 육성
- (3) 반도체 인재양성 중장기 지원기반 구축(기반 조성)
 - ⑧ 거점: 전국단위 대학·인프라 연계를 통한 연구·교육 집중 지원
 - ※ 대학 기반 전국 단위 반도체 연구·교육·실습 HUB 구축, 국가나노인프라 고도화를 통한 반도체 전문인력 양성 강화
 - ⑨ 협업: 범부처·민관합동 인재양성 협업체계 구축
 - ※ 국가차원 인재양성 아젠다 발굴 및 정책 수립, 인적자원 관리·지원 체제 구축
 - ⑩ 균형: 지역 및 중소기업 균형성장 및 상생 지원체계
 - ※ 지역 균형성장 지원체계 조성, 중소기업 균형성장·상생 지원체계 조성

[그림 4-2] 정책효과 전망



자료: 관계부처합동(2022. 7. 8)

3. 인공지능 반도체 산업 육성을 위한 정책 현황

가. 인공지능 국가전략(2019. 12. 17)

- 정부는 'IT 강국을 넘어 AI 강국으로' 도약하기 위해 2030년까지 '디지털 경쟁력 세계 3위', 'AI를 통한 지능화 경제효과 455조원 창출', '삶의질 세계 10위' 등 3대 목표를 달성하기 위해, 3대 분야의 9대 전략과 100대 실행과제를 마련
- 인공지능 국가전략의 비전 및 목표 달성을 위해 ① AI 인프라 확충, ② AI 기술경쟁력 확보(AI 반도체 관련), ③ 과감한 규제혁신 및 법제도 정비, ④ 글로벌을 지향하는 AI 스타트업 육성, ⑤ 세계 최고의 AI 인재 양성 및 전 국민 AI 교육, ⑥ 산업 전반의 AI 활용 전면화, ⑦ 최고의 디지털 정부 구축, ⑧ 포용적 일자리 안전망 구축, 역기능 방지 및 AI 윤리체계 마련 등 9대 추진전략을 세우고, 추진방안을 마련하여 발표
- 특히, 인공지능 국가전략(2019. 12)의 9대 전략 중 'AI 기술경쟁력 확보' 전략은 세계 최고의 메모리 반도체 경쟁력을 지렛대로 활용하여 AI 반도체 경쟁력 세계 1위를 목표로, AI 반도체 핵심기술 확보와 신개념 반도체(PIM) 개발에 대한 전략 투자를 강화하겠다는 내용을 담고 있음

〈표 4-3〉 AI 기술경쟁력 확보를 위한 세부정책

주제	세부내용
① 신개념 AI 반도체(PIM)개발	－ AI 반도체 핵심기술*(설계·미래소자·장비 및 공정 등) 및 신개념 AI 반도체(PIM) 개발 등 AI 반도체 세계 1위 도약 * 차세대 지능형 반도체 1조 96억 원 투자('20~'29)
② 차세대 AI 연구개발	－ 창의적·도전적 차세대 AI 연구개발* 선제 투자('20~) * 차세대 AI 개발사업 예타 추진 → '30년까지 핵심기술 5개 이상 확보
③ AI 기초연구 강화	－ 지식표현 및 추론, 기계학습 알고리즘, 인지과학 등 AI 기초연구 강화('20. 예타 추진)
④ 혁신적 방식의 AI R&D 확대	－ 선의의 경쟁과 창의적 도전을 촉진할 혁신적 방식의 AI R&D* 확대 * 서바이벌 방식의 '경쟁형', 국가 사회 현안을 AI로 해결하는 '챌린지형(경진대회)'

자료: 과학기술정보통신부(2019. 12. 17)

나. 인공지능 반도체산업 발전전략(2020. 10. 12)

- 정부는 2020년 10월 12일, 관계부처 합동으로 인공지능 반도체 선도국가 도약으로 인공지능·종합반도체 강국 달성을 위한 '인공지능 반도체 산업 발전전략' 발표
 - 정부는 인공지능 반도체의 독자적 기술력 확보(~2022), 세계적 산업경쟁력 확보(~2026) 및 인공지능(AI) 반도체를 제2의 D램으로 육성(~2030)한다는 목표를 수립하고, 목표를 달성하기 위해 2대 전략과 12개 추진과제를 마련
 - 그리고 본 정책의 기대효과로 2026년까지 AI 반도체 시장점유율 10%, 혁신기업 10개, 고급인재 1천 명 달성, 2030년 AI 반도체 시장점유율 20%, 혁신기업 20개, 고급인재 3천 명 달성 등을 이루하고자 하였음

[그림 4-3] 인공지능(AI) 반도체 산업 발전전략 목표 및 추진전략



자료: 관계부처 합동(2020. 10. 12)

- 동 전략을 추진하기 위해 기술개발(R&D) 강화, 기술사업화, 인력양성, 금융지원, 기반구축, 생태계 구축 등의 분야에 대해 2가지의 전략과 12개의 세부 추진과제를 제시

〈표 4-4〉 인공지능(AI) 반도체 산업 발전전략의 12개 세부과제

‘제1전략: 퍼스트무버형 혁신 기술·인재 확보’		
	1. 세계 최고 기술력에 도전	
		1-1. 인공지능 반도체 플래그십 프로젝트
		1-2. 세계 최고 메모리 기반 신개념 반도체 개발
	2. 초기수요와 연계한 기술·사업화 장벽 해소	
		2-1. 국가 인공지능·데이터 인프라를 통한 시범 도입·확산
		2-2. 맞춤형 Tech Jump-up 프로그램 지원
	3. 인공지능 반도체 차세대 전문인재 양성	
		3-1. 인공지능 반도체 고급인재 확보
		3-2. 실무·융합인력 양성 및 저변 확산

‘제2전략: 혁신성장형 산업 생태계 활성화’		
	1. 민간·공공분야 초기 시장창출	
		1-1. 혁신기업 육성을 위한 수요·공급
		1-2. D.N.A 서비스 혁신과 연계한 공공분야 초기시장 창출
	2. 연대·협력의 밸류체인 구축	
		2-1. 설계 역량 강화를 위한 연대·협력 생태계 조성
		2-2. 첨단 파운드리 소·부·장 경쟁력
	3. 기업 성장 인프라 강화	
		3-1. 혁신기업 Scale-up을 위한 대규모 성장자금 확보
		3-2. 인공지능 반도체 팹리스 집중 지원체계 구축


자료: 관계부처 합동(2020. 10. 12)

다. 인공지능(AI) 반도체 산업 성장 지원대책(2022.6.27)

- 정부는 인공지능반도체 기업과의 간담회에서 제기된 반도체 업계의 정책수요를 바탕으로 산·학·연 논의를 거쳐 지원대책을 마련
 - 첫째, 인공지능 반도체 초격차 기술력을 확보하기 위하여, 인공지능반도체 첨단기술 연구개발(R&D)에 예타사업을 포함하여 향후 5년간 1조 200억원을 투입하고 미국 등 선도국과 공동연구를 확대한다고 지원대책을 발표
 - － 주요 투자 분야로는 ① 신(新)소자와 설계기술을 융합한 차세대 NPU, ② 연산(프로세서)과 저장(메모리) 기능을 통합한 PIM반도체(Processing In Memory), ③ 반도체 성능을 극대화하는 시스템소프트웨어, ④ NPU와 PIM의 장점을 결합하여 시스템 성능을 극대화 하기 위한 초거대인공지능 시스템 등으로 제시
 - 둘째, 국산 인공지능 반도체 초기 시장수요를 창출한다. 반도체 최대 수요처 중 하나인 데이터센터를 국산 인공지능반도체로 구축하는 사업(NPU Farm 구축 및 실증)을 '23년 신설하고 인공지능 개발자에 컴퓨팅 파워를 무상 제공할 계획
 - － 인공지능 제품·서비스 개발에 국산 인공지능반도체를 활용하고 성능을 검증하는 ‘인공지능+ Chip 프로젝트’를 신규 추진
 - － 아울러, 지능형 CCTV, 스마트시티 등 각 부처·지자체가 구축하는 공공사업에도 국산 칩이 적용·확산될 수 있도록 협의해 나갈 계획
 - 셋째, 대기업이 참여하는 산·학·연 협력 생태계를 조성한다. 대학·연구소가 첨단

- 상용 공정에 최적화된 반도체를 설계할 수 있도록 대기업과의 협력을 강화
- PIM반도체를 개발하는 정부사업에 참여하는 연구기관에 대해 삼성전자와 SK하이닉스가 기술자문을 제공하고, 성과가 우수한 연구 결과물의 반도체 생산 공정 적용을 검토할 예정
- NPU를 개발하는 정부사업의 연구 결과물 중 삼성전자 협력업체(디자인하우스)에서 검증하여 우수 설계기술(IP)로 평가된 경우 삼성전자 파운드리 설계기술 데이터베이스(IP 풀)에 포함하고 다양한 팹리스 기업 제품에 적용될 수 있도록 지원
- 특히, 정부 정보통신기술 연구개발 기획과정에 삼성전자·SK하이닉스가 참여하여 유망기술에 대한 수요를 제기하고 기획결과를 검증
- 더불어 PIM 반도체설계연구센터(PIM HUB)와 삼성전자·SK하이닉스 간 상호 협력과전 및 공동연구를 추진하는 등 연구개발·인력 교류도 지속 확대할 계획
- 넷째, 인공지능 반도체 전문인력 7,000명을 양성한다. 인공지능반도체 관련 다양한 학과(전기전자공학, 컴퓨터공학, 물리학 등)가 공동으로 교육과정을 구성·운영하는 '인공지능반도체 연합전공(학부)' 개설(3개교), 대학·연구소가 보유한 반도체 시험생산 설비의 고도화 및 이와 연계한 반도체 설계·제작 교육(학부생 대상) 신설 등을 추진
- 특히, 연구 중심의 석·박사 고급인재 양성을 위해 '인공지능반도체 대학원'을 '23년 신설(3개교)하고 참여 학생 중 우수 석·박사 학생을 해외 대학에 단기(6개월~1년) 파견하는 프로그램도 운영할 계획

〔그림 4-4〕 인공지능(AI) 반도체 산업 성장 지원대책 개요



자료: 과학기술정보통신부(2022. 6. 27)

라. 국산 인공지능반도체를 활용한 케이(K)-클라우드 추진방안(2022. 12. 12)

- ‘케이-클라우드’ 추진방안은 세계 최고 수준의 초고속·저전력 국산 인공지능반도체를 개발, 이를 데이터센터에 적용해 국내 인터넷기반자원공유 경쟁력을 강화하고, 국민들에게 향상된 인공지능 및 인터넷기반자원공유 서비스를 제공하기 위한 정책
- 첫째, 국산 인공지능반도체를 3단계에 걸쳐 고도화, 세계 최고 수준의 기술을 확보
 - 세계 최고 수준의 초고속·저전력 국산 인공지능반도체 개발을 위해, 기존 인공지능반도체 사업을 종합하고 체계화하여 '23년부터 '30년까지 총 8,262억원(예정)을 투자하는 고도화 이행안을 마련
 - ※ 1단계('23~'25)로 현재 상용화 초기 단계에 있는 국산 NPU를 지속적으로 고도화(추론→학습)하고 데이터센터에 적용하여 성공 실적 확보 및 초기 시장 창출을 지원

- ※ 2단계('26~'28)에서는 디램 기반 상용 펌(PIM)과 국산 NPU를 집합(패키징)하여 세계적 수준의 연산 성능을 저전력으로 구현(DRAM 기반 PIM)
- ※ 3단계('29~'30)에서는 비휘발성 메모리(Non-Volatile Memory)를 활용, 아날로그 엠에이시(MAC) 연산 기반의 NPU·PIM을 개발하여 극저전력화를 달성
- 둘째, 국산 인공지능반도체를 데이터센터에 적용하기 위한 소프트웨어 예타사업을 추진
 - 인공지능반도체 사업들은 프로세서(HW) 개발을 목표로 진행되고 있어, 엔피유·펌 등 단계별로 고도화한 국산 인공지능반도체를 데이터센터에 적용하기 위해서는 추가적인 소프트웨어 개발이 필요
 - 이에 신규 예타사업을 추진하여, 국산 인공지능반도체에서 기저학습 등 인공지능 알고리즘을 초고속·극저전력으로 실행하는 컴파일러, 라이브러리, 인공지능 모형 자동 병렬화 기술 등과, 이를 상용 인터넷기반자원공유에 적용하기 위한 가상머신(VM) 및 컨테이너, 가상 서버 클러스터 기술 등을 개발할 계획
- 셋째, 단계별로 국산 인공지능반도체의 데이터센터 적용 및 인공지능·인터넷기반 자원공유 서비스 제공을 추진
 - 인공지능반도체 고도화 단계별로 이를 데이터센터에 적용하고 인터넷기반자원공유 기반 인공지능서비스까지 제공하는 실증사업을 함께 추진
 - 2023부터 시작되는 1단계 실증사업으로는 국산 NPU 데이터센터 구축사업(신규)과 기존의 인공지능·인터넷기반자원공유 서비스 개발 사업을 연계하여 '23년에 428억원(안), '25년까지 3년간 약 1천억원(잠정)을 투자
 - 실증사업에서의 인공지능·인터넷기반자원공유 서비스는 우선 사회·경제적 파급력과 수요가 높은 4개 분야(안전·보건·교육·국방 등)를 중심으로 추진하고, 이를 바탕으로 성장 가능성이 높은 주요 분야*까지 확대할 계획
- 넷째, 산·학·연 협력 강화를 위한 추진체계를 마련
 - 케이-클라우드' 추진을 위한 민·관 협업 창구 마련 및 주요 과제 발굴을 위해, '국산 인공지능반도체 기반의 케이-클라우드 얼라이언스'를 구성
 - 또한 인공지능반도체 기업과 대학이 협력하여 교육과정을 개발하는 '인공지능반도체 대학원'을 신설, 현장에서 요구되는 설계역량을 갖춘 최고급 인재를 양성

(’23년~, 3개교 신설)

- 2·3단계 펌(PIM) 고도화·실증을 위한 메모리 반도체 대기업과 산·학·연 간 기술 연계 등을 위해 ‘펌 허브(설계연구센터, 한국과기원)’의 역할을 강화
- 관련 분야(인공지능반도체·인터넷기반자원공유·인공지능 등) 협업 강화를 위해 연구개발 지원기관인 한국전자통신연구원(ETRI)과 정보통신기획평가원(IITP) 조 직을 강화

[그림 4-5] 케이-클라우드 추진방안 개요



자료: 과학기술정보통신부(2022. 12. 12)

제2절 해외 반도체 관련 주요 정책 현황

1. 주요 기술 선도국의 반도체 관련 정책 개요(2021년~2023년)

- 주요 기술 선도국은 반도체 등의 첨단 산업에서 중국 의존도가 높아짐을 국가안보의 위협으로 인지하고, 자국 중심의 공급망 개편을 지속해 추진
 - 아울러 디지털전환 등 대외환경 변화와 반도체에 관한 기술 안보 관점에서의 인식 변화로 자국 중심의 공급망 확보와 기술 경쟁 우위 확보를 위한 지속적인 지원정책, 통상정책을 수립하여 추진하여 이를 강화
 - 미국, 중국, EU, 일본 등 주요 반도체 기술 선도국가는 반도체 육성 및 보호 관련 정책을 지속해서 발표하고 있으며, 반도체 가치사슬 변화 및 공급망 재편 과정에서 확고한 포지셔닝을 차지하기 위해 다양한 정책적인 대안들을 수립
- 주요 기술 선도국에서 반도체는 국가적 차원의 핵심기술로 자리매김
 - 반도체의 활용 분야의 빠른 확산으로, 기존 PC 부품에서 모바일, 엣지컴퓨팅, 모빌리티, 통신 네트워크, 가전 등으로 수요가 기하급수적으로 증가하고 있어, 반도체 분야는 기술 개발 및 무역·통상 측면에서 기술 안보적 전략자산 관점으로 급격한 인식변화가 이루어지고 있음
 - 하지만 이미 코로나19 팬데믹과 기후 변화 및 자연재해로 수요예측 변동성 및 공급망 불안 등으로 취약성이 높아졌음
 - 반도체 수요분야에 대한 모니터링과 더불어 반도체 공급망의 중요성이 증가함에 따라 주요 선도국가는 반도체 제조 기반 확보 및 초격차 기술 강화를 위한 다양한 정책을 마련 중
 - 특히 주요 기술 선도국 사이에 반도체 관련 기술을 무기로 국가안보 문제를 해결하기 위해, 경쟁국에 대한 최첨단 반도체 기술 개발 및 제품 이전 가능성을 차단하는 동시에 동맹국의 참여를 끌어내는 등 반도체산업을 둘러싼 환경 변화가 진행
 - 주요 기술 선진국은 기술주권 및 자국중심주의를 앞세워 자국 내 공급망 강화 및 확보와 더불어 반도체 관련 첨단기술을 선점하기 위한 정부 지원정책, 통상정책을 강력하게 추진

2. 미국

- 글로벌 반도체 시장의 기술을 선도하며 기술 개발을 주도 중인 미국은 꾸준한 정부 및 민간투자와 경쟁국에 대한 지속적인 견제를 바탕으로 기술 지도력을 유지
 - 최근 미국은 보조금 또는 세액공제 등을 통한 국내 R&D 및 제조시설 지원, 엄격한 수출관리를 통한 기술 통제, 동맹국을 중심으로 하는 글로벌 연대 등으로 반도체 정책을 강화
 - 반도체과학법안은 미국이 지난 반세기 수행한 산업정책 중에서 가장 큰 규모의 예산으로 진행
 - － 2022년 8월 바이든 대통령은 「반도체과학법(Chips and Science Act)」을 제정하여 자국 반도체 산업역량 강화를 위해 정부예산을 편성(반도체 기금)하여 투자를 지원¹⁴⁾
 - － 우선 반도체 R&D, 제조 및 인력양성에 약 520억 달러의 자금을 편성, 이중 반도체 제조시설 지원에 390억 달러를 지원하는 등 인센티브(보조금) 포함¹⁵⁾
 - － 반도체과학법안에는 반도체 관련 투자기업에 25% 공제를 지원하는 내용도 포함되어 있으며, 이를 통해 국내 공급 확보 및 고속터널 제조 일자리 창출 등 민간 투자 촉진을 유도
 - 한편, 인센티브(보조금)에 대한 엄격한 보조금 신청요건과 더불어 2023년 상무부는 가드레일 세부 규정을 발표
 - － 보조금을 받은 기업이 우려 대상 국가(중국, 러시아, 이란, 북한 등)에 향후 10년간 반도체 시설에 대한 투자를 금지하는 가드레일 조항을 적용하는 등 주요 경쟁국 반도체 첨단기술 개발을 견제¹⁶⁾
 - － 이에 따르면 보조금 수혜기업은 중국 등 경쟁국 레거시(Legacy) 반도체 시설 확장(material expansion)을 10년간 10% 미만 확장, 투자 10만 달러 미만(누적)으로 제한
 - － 또한 보조금 수혜기업은 우려국내 첨단반도체(레거시外 반도체) 시설 확장을 10년간 5%, 10만 달러 미만(누적)으로 제한하며, 보조금 수혜기업은 우려국 단체와

14) KISTEP(2023)

15) KITA(2023)

16) 한국수출입은행(2023)

공동연구 및 기술 라이선싱도 제한

- 2022년 8월 이후에는 첨단 AI·반도체 기술에 대한 동맹국 외 중국, 러시아 등의 경쟁국 접근을 차단하는 수출관리규정(통제정책)을 강화
 - － 2022년 8월, 상무부 산하 산업안보국은 반도체 관련 품목을 수출통제 리스트에 추가
 - － 2022년 10월에는 수출관리규정을 개정하여 중국의 고성능 첨단 반도체(AI 반도체, GPU, 슈퍼컴퓨팅) 구매 및 생산능력을 제한하기 위해 수출통제(반도체 장비 및 관련 소프트웨어·기술)를 강화
 - － 아울러 2023년 10월 대중국 반도체 수출통제에 대한 확대보완 조치를 발표,¹⁷⁾¹⁸⁾ 이에 따르면 기존 수출통제의 주요 구성 요소였던 ① 첨단 반도체 제조 관련 품목과 ② 첨단 컴퓨팅 관련 반도체 제재가 모두 확대되었으며, 이와 함께 ③ Entity List에 13개 AI 반도체 중국기업이 추가
- 2023년 8월 바이든 행정부는 위공지능·반도체·양자기술 등 첨단 기술 분야의 중국 기업들에 대한 미국의 투자를 제한하는 투자제한 행정명령을 발표¹⁹⁾
 - － 이에 따라 2024년 1월부터 시행되는 행정명령에서 위공지능·반도체·양자기술 등 분야에서 미국 기업의 대중국 투자를 금지

3. 중국

- 중국은 국가 경쟁력 제고를 위한 국가차원 전략 정책에 반도체를 주요 중점분야로 지정
 - 국가전략 정책인 중국제조 2025(2015년), 제13차 5개년 국가과학기술 혁신 계획(2016년), 제13차 5개년 국가 전략적 신흥산업 발전계획(2016년), 제14차 5개년 계획(2021년) 등에서 전략육성 분야의 하나로 반도체를 선정
 - 다양한 국가 지원정책(국가전략 수립, 펀드 운용, 세제지원 강화 등)을 통해 반도체 자급화를 지속하여 추진 중이나, 최근 미국 중심의 주요 기술 동맹국의 견제받고 있

17) KIEP(2023)

18) 한국수출입은행(2023)

19) KB금융지주경영연구소(2023)

어 목표를 달성이 쉽지 않은 상황

- 2021년 14차 5개년 계획·2035 중장기 목표의 7대 전략육성(인공지능, 양자정보기술, 반도체, 뇌과학, 유전자 바이오 기술, 임상의학, 심해·극지·우주 분야) 분야 중 하나로 반도체 분야를 선정하여 대대적인 지원을 추진 중이나 자립화율은 증가하지 못하고 있음²⁰⁾

- － 이에 따르면 대규모 펀드와 각종 세제지원 등 전방위적인 자국 반도체 산업 육성 정책을 추진 중이나, 여전히 자립화율은 10% 중반 수준으로 정체한 상황
- － 14차 5개년 계획은 중국제조 2025로 널리 알려진 13차 5개년 계획의 후속 국가전략으로 미국의 반도체 제재 분야(반도체 설계툴, 주요 소재·장비, 제조기술, 화합물 반도체 등)에 대한 전략적 지원·개발이 이루어질 것으로 전망
- － 반도체 기술에서는 반도체 설계 도구, 핵심 소재, 첨단제조기술, IGBT, MEMS, 첨단 메모리 기술, SiC·GaN 등 3세대 반도체 강조

□ 2022년 10월, 미국의 제재 강화 이후 중국은 과학기술업무 컨트롤타워를 설치하고 187조원 규모의 반도체산업 지원 패키지를 마련²¹⁾

- 중국은 1조 위안(187조 원) 이상의 대규모 추가 보조금 지원을 발표했으며 지원 방향도 포괄적 대규모 지원에서 선별 기업에 대한 지원 확대로 변화
- 미국의 기술 봉쇄에 대응하기 위해 신형 거국체제(新型舉國體制) 제시 및 공산당 산하에 과학기술 부문 정책을 주도할 중앙과학기술위원회를 신설

□ 2022년 12월에는 미국의 수출 통제 강화 조치로 중국에 직접적인 피해가 발생하자, 중국은 미국의 대중국 수출 통제 및 관련 조치를 WTO에 제소²²⁾

- 중국 상무부는 미국의 반도체 관련 통제 조치가 글로벌 공급망의 안정성을 위협하고 세계 경제에 혼란을 일으키고 있다고 주장하며 WTO에 분쟁협의를 요청
- 2023년 6월에는 최첨단 반도체 장비의 수출통제와 관련해 미국·일본·네덜란드를 3 국가를 조사해 줄 것을 세계무역기구(WTO)에 촉구

20) KISTEP(2023)

21) 한국수출입은행(2023)

22) KITA(2023)

- 미국·일본·네덜란드의 대중국 반도체 수출 통제·규제가 세계무역기구의 형평성과 투명성 원칙을 위반하였다고 조사와 감시강화를 요구

- 2023년 8월에는 미국의 대중국 수출통제·규제에 맞서 갈륨(Ga) 및 저마늄(Ge) 등 소재의 수출통제·규제를 시행하며 원자재 무기화²³⁾
 - 중국은 전 세계 갈륨 및 저마늄 생산의 약 90% 이상을 차지하는 최대 생산국으로 수출통제 시 원자재 가격 상승으로 이어지며 반도체·디스플레이의 제조비용 상승이 우려

4. EU

- 2022년 EU는 반도체 산업의 육성을 통해 현재 10% 수준의 세계시장 점유율을 2030년까지 20%를 달성을 목표로, 민간·공공협력을 통해 총 430억 유로를 투자하는 유럽반도체법안(European Chips Act)에 제언²⁴⁾
 - 유럽반도체법은 반도체 제조시설에 대한 투자, EU 전지역의 반도체 허브 구축, 새로운 반도체 기술 시범 운영, 설계 및 기술 역량 개선, 기업의 자금 조달 및 자본에 대한 접근성 향상 등의 내용을 포함
 - 주로 반도체 기술개발 역량 강화와 EU의 생산능력 확보, 공급망 모니터링 및 위기관리 체계 등의 도입이 주요 내용
 - 유럽반도체법안은 공급망 위기에 대응하기 위한 권고(Recommendation: EU와 회원국 간 반도체 시장 상황 모니터링을 통한 조기경보 및 정보공유 체계 구축)와 첨단 반도체 기술개발·생산확대를 주요 골자로 하는 중장기계획인 규정(Regulation: 연구·혁신, 설계·생산, 공급안정, 위기관리, 국제협력 등 주요 부문별 정책 방향 제안)으로 구성²⁵⁾
 - 반도체 공급난 대응과 EU 역내 생산역량 강화를 위해 유럽반도체법의 입법 활동을 전개하고 있음

23) KB금융지주경영연구소(2023)

24) KITA(2023)

25) KISTEP(2023)

- 유럽반도체법안의 차질 없는 이행을 위해 반도체 이니셔티브(Chips for Europe Initiative)를 발족하고, 유럽 내 집적기술·설계 능력, 접근성 높은 파일럿 라인, 설계·생산·장비 기업 간 협력체계 등 확보를 통해 산업생태계 강화를 추진²⁶⁾
- 이외에도 유럽공통관심 주요 프로젝트(Important Project of Common European Interest, IPCEI)를 통해 AI 프로세서, 엣지컴퓨팅, 모빌리티, 5G·6G 등 기술개발 프로젝트 지원하여 반도체 산업에 보조금을 지원

5. 일본²⁷⁾

- 2021년 6월 일본 경제산업성은 「반도체·디지털 산업 전략」제정을 통해 반도체 산업 부흥을 위한 단계별 로드맵을 설정했으며, 2023년 4월 「반도체·디지털 산업 전략(개정안)」 발표로 로드맵을 구체화
- 지난 20여 년간 쇠퇴한 일본 반도체 산업의 재부흥과 디지털전환 등 대외환경 변화에 대응하기 위한 전략
- 반도체를 디지털 인프라, 디지털 산업과 함께 3가지 핵심기술 요소로 설정하였으며, 국내 반도체 생산 기반을 강화하고(1단계), 차세대 반도체 설계기술을 확보하며(2단계), 나아가 미래 기술의 연구개발을 추진(3단계)하는 것이 목표
 - － 1단계의 경우, 대만 및 미국과 연계하여, 일본 국내 반도체 생산 기반 강화하는 것이 목표로, 대만 TSMC와 일본 텐소, 소니 반도체 솔루션 합작회사인 JASM(Japan Advanced Semiconductor Manufacturing)는 일본의 반도체 산업전략 1단계의 핵심 프로젝트
 - ※ JASM의 쿠마모토현 제1공장은 소니 그룹의 이미지센서 사업에 들어갈 반도체 28nm 세대가 중심이고, 제2공장은 12nm 세대의 양산을 통해 자동차의 화상처리용 IC 등 용도에 대응할 것으로 예상
 - － 2단계의 경우, 대만 및 벨기에와 연계하여, 차세대 반도체 설계기술을 개발하는 것이 목표

26) KOTRA(2003a)

27) KOTRA(2003b)

- ※ 차세대 반도체(Beyond 2nm) 설계 기술 개발을 위해 개방형 연구개발 거점 구축하고, 향후 차세대 반도체를 양산할 수 있는 거점 구축을 위해 반도체연구기관 LSTC와 Rapidus社 설립을 지원
- ※ Rapidus사는 도요타자동차, 소니, 키옥시아 등 일본 주요기업 8개사 출자로 출범, 2027년까지 차세대 로직 반도체 개발을 목표로 하여 10년 간 5조 엔의 설비 투자가 계획 중이며, 일본 정부는 700억 엔 지원을 결정
- ※ Rapidus사는 미국 IBM과 2nm 노드 반도체의 공동 개발 파트너십을 체결했으며, 유럽 최고 수준의 반도체 연구개발 생태계를 형성하고 있는 벨기에 imec과 차세대 반도체 개발에 관한 MOC(협력각서)를 체결
- 3단계의 경우, 다양한 국가와 연계하여, 차세대 반도체 설계기술을 개발하는 것이 목표
- ※ 반도체·디지털 산업전략 3단계는 광전 융합이나 양자 등 기술의 연구개발을 목표로 하며, 2단계 차세대 로직 반도체 설계 이후의 단계
- ※ 2030년 이후 본격적으로 구현될 전망인 양자컴퓨터 등 새로운 사례 적용을 염두에 두고 장기적 연구개발을 진행하는 것이 3단계 전략으로 이를 위해 미국, EU, 벨기에, 네덜란드, 영국, 한국, 대만 등과 차세대 반도체 실용화 사례를 창출하고, 공동연구를 추진할 계획

제5장 인공지능 반도체 정책적 대응 방향 제언

□ AI 반도체 등장에 따른 전 세계 반도체 시장 환경의 변화

- AI 서비스를 지원하는 AI 컴퓨팅 인프라 계층 중 반도체의 중요성이 강화
 - － 방대한 양의 데이터를 학습·추론하는 AI 서비스를 위해 기존 연산 반도체보다 빠르고, 저전력의 효율적 처리가 가능한 AI 컴퓨팅을 지원하는 AI 반도체가 요구
- ChatGPT·ON Device AI 등 다양한 산업에서 활용되는 기기 및 애플리케이션의 첨단·지능화로 AI 반도체 수요가 급증하고 있으며, AI 반도체가 기존 반도체 시장 성장을 견인할 전망
- AI 컴퓨팅 인프라에서 반도체 계층은 현재 GPU·메모리 중심으로 구조화되어 있지만, 전력 사용량 급증과 더불어 구매 단가 증가 등으로 활용 비용이 급증함에 따라 지속 가능성에 의문점이 대두 ▷ AI 연산에 최적화된 고성능·저전력 NPU에 주목
- 최근 글로벌 빅테크는 자사 기기·서비스에 특화된 '맞춤형 AI 반도체'를 자체 설계하여, 수요기업이 직접 Foundry에 위탁생산하는 수요가 증가하고 있음
- AI 반도체의 등장에 따른 기존 반도체 가치사슬에서 혁신이 발생하고 있으며, 기존 반도체 생태계에 근본적인 기술 및 비즈니스 모델 변화가 요구되고 있음
 - － 반도체 IP, EDA, Foundry, OAST, Design House 등 수평적 가치사슬 활동 영역에서 AI 반도체 제공을 위한 다양한 기술적인 혁신이 발생
 - － 다양한 수요처를 중심으로 AI 반도체를 활용하는 기기 중심의 온디바이스 AI가 주목받고 있음
 - － 다양한 수요처에 AI 반도체가 탑재되어 활용되기 위해서는 AI 모델개발 혹은 최적화를 지원하는 프레임워크 및 SW 등 활용 생태계가 요구

□ 최근 AI 반도체 정책 대응 방안

- 최근 정부(2024. 1. 15)는 “세계 최대·최고 반도체 메가 클러스터” 조성방안 발표 (관계부처 합동)

- 이러한 정책 중 반도체 생태계 관련 AI 반도체와 직접적인 관련이 있는 정책 프로그램은 『팹리스 육성으로 반도체 밸류체인 완성』 영역
- 파운드리 강점 기반으로 팹리스 육성을 통한 반도체 밸류체인 완성 → 업계 애로 사항인 ❶ 네트워킹, ❷ 자금, ❸ 시제품 제작기회 해결 주력
 - '30년 시스템 반도체 점유율 10%(現 3%), 글로벌 TOP 50 팹리스 10개 육성(現 1개)
- (네트워킹) 집적단지 조성 및 기술교류회 신설
- (스케일업 금융지원) 팹리스 스케일업, 운영자금 안정화 지원 강화
- (시제품 제작·검증지원) 개발 비용 지원 및 파운드리 기업과의 협력 강화
- “세계 최대·최고 반도체 메가 클러스터” 조성방안 중 『팹리스 육성으로 반도체 밸류체인 완성』이라는 수평적 가치사슬에 대한 프로그램을 지원할 예정

□ 향후 AI 반도체 대응 방향에 있어 AI 반도체 정책 수립을 위한 프레임워크 제시

- 최근 AI 반도체 관련 정책에 있어 입체성과 기밀도가 부족한 상황으로 이를 강화

※ AI 반도체 정책의 입체성(Three-dimensionality)

- 국내 AI 반도체 생태계 구축에 있어, 경쟁력을 제공하기 위해서는 아래 나열된 3가지 기준을 참조하여 필요한 입체적인 정책 방향을 도출해야 함

① AI 반도체 수평적 가치사슬, ② AI 반도체 수요처, ③ AI 반도체 활용 생태계

※ AI 반도체 정책의 기밀도(Density)

- 국내 AI 반도체 생태계 애로사항을 입체적인 관점에서 파악하고 진단하고, 그동안 충족되지 못한 Needs 해결에 도달할 수 있도록 있는 맞춤형 프로그램 제시

- AI 반도체 경쟁력을 강화하기 위해서는 ①특정한 수요처를 목표로, ②수평적인 가치사슬 중 어떠한 영역에 정책적인 자원을 할당할 것인지, 그리고 ③활용 생태계에서 특정 기술의 정책 지원 등을 분석하여 맞춤형 지원프로그램 제안
 - AI 반도체의 수요 예측을 통한 전략적인 중점 제품에 대한 평가 & 발굴·육성 방향
 - AI 반도체의 수평적인 가치사슬 간 연계·성장 생태계에 대한 평가 & 조성 방향
 - AI 반도체의 활용 생태계(클라우드, 온디바이스, 시스템 SW 등)에 대한 평가 & 강화 방향

- (AI 반도체의 수평적 가치사슬) 반도체IP, EDA, 펌리스, 디자인하우스, 파운드리, OSAT 각각에 대한 구체적이고 조밀한 구조의 지원프로그램이 요구
- (AI 반도체 수요처) 수평적인 생태계를 통해 판매되는 AI 반도체의 수요시장인 자동차, 인더스트리, 소비자 가전, 통신 별 각각 차별화된 지원프로그램도 필수
- (AI 반도체 활용 생태계) Cloud/On Device에 AI 반도체가 탑재되어 활용되기 위해서는 AI 모델개발 혹은 최적화를 지원하는 프레임워크 및 SW 등 활용 생태계가 필수
－ (차량용 AI 반도체 예시)
- ① 완성차/모듈부품(수요 기업). 자동차용 반도체IP, 펌리스, 디자인하우스, 파운드리, 패키징 사이의 협업을 바탕으로 한 비즈니스 모델로 진화가 요구
- ② 특히 동작 온도, 전압, 수명 등 측면에서 고도의 기술력(신뢰성)이 요구, 특히 다 품종 소량 생산으로 수익성 창출이 어려워 신규 투자가 어려움
- ③ 자동차용 AI 반도체를 탑재하여 활용할 수 있도록 SW 프로그래밍 플랫폼 제공

참 고 문 헌

[국내 문헌]

가온칩스(2022), Investor Relationship 2022

과학기술정보통신부(2019. 12. 17), “IT 강국을 넘어 AI 강국으로”.

_____ (2021. 12. 14), “정보통신기술(ICT) 수출, 역대 최고 월수출액 달성”.

관계부처 합동(2019. 4. 30), “시스템반도체 비전과 전략”.

_____ (2020. 10. 12), “인공지능반도체산업발전전략”.

_____ (2021. 2. 1), “시스템반도체 기술혁신 지원”.

_____ (2021. 5. 13), “K-반도체 전략”.

_____ (2022. 7. 8), “반도체 인력 양성 추진 전략”.

_____ (2022. 6. 27), “인공지능(AI) 반도체 산업 성장 지원대책”.

_____ (2022. 12. 12), “국산 인공지능반도체를 활용한 케이(K)-클라우드 추진방안”.

_____ (2024. 1. 15), “세계 최대·최고 반도체 메가 클러스터 조성방안”.

김민식(2022), 반도체 분야의 기술주권 강화에 대한 시사점, ICT 통계 분석 22-02호, KISDI.

김병수(2023), AI 반도체 개발 현황과 방향

나수엽 외(2020), “미국의 「외국인투자위험심사현대화법(FIRRMA)」 발효와 미국의 대중 투자규제”.

대한민국 정책브리핑(2021. 5. 13), “K-반도체 벨트 구축”. 기업 510조 투자·정부 전방위 지원”.

박민숙, 김영선(2020), “중국 「수출 금지·제한 기술목록」 조정의 주요 내용 및 시사점”. 세계경제 포커스 3-33. 대외경제정책연구원.

산업통상자원부(2010. 7. 31), “반도체 KOREA, 제2의 도약”.

_____ (2013. 10. 23), “반도체산업 재도약 전략”.

_____ (2016. 9. 29), “반도체 설계인력, 기업과 대학이 함께 키워나간다”.

_____ (2016. 10. 27), “반도체, 같이살자, 2천억 규모 반도체 희망펀드 조성”.

_____ (2017. 3. 30), “4차 산업혁명 시대 시스템반도체 선도국으로 도약”.

_____ (2019. 5. 1), “시스템반도체 비전과 전략 발표”.

_____ (2021. 7. 1), “「케이(K)-반도체 전략」, 반도체 성장기반 본격 조성”.

수출입은행 해외경제연구소(2020. 12), “시스템반도체산업 현황 및 전망”, 《2020 ISSUE REPORT》.

이석준 (2021), 온디바이스 AI 하드웨어 및 소프트웨어 기술개발 동향, 주간기술동향.

윤성욱 외(2021), 인공지능 반도체 산업 확산 가속화 방안, 정책연구21-22, 정보통신정책연구원.

오윤미(2021), “대만 반도체 전략의 주요 내용과 전망”, 세계경제 포커스 4-47, 대외경제정책연구원.

연원호(2021a), “미국 바이든 행정부의 대중국 정책 전망과 시사점”, 세계경제포커스 4-15, 대외경제정책연구원.

연원호(2021b), “미중 갈등과 중국의 반도체 산업 육성 전략 및 전망”, 세계경제 포커스 4-39, 대외경제정책연구원.

전황수, 김현탁, 노태문(2021), 차량용 반도체 공급망 생태계, ETRI.

한국IR협의회 기업리서치센터(2023), 오픈엣지테크놀로지.

통계청, “국가통계포털-ICT수출입통계:IT산업별/월별 수출 현황”.

<https://kosis.kr/search/search.do>.

e나라지표, “ICT수출입동향”,

https://www.index.go.kr/potal/main/EachDtlPageDetail.do?idx_cd=2782

IITP(2021), “2020 ICT기술수준조사 및 기술경쟁력 분석 보고서”.

KB금융지주경영연구소(2023), 미국의 對중 규제 강화와 한국 반도체 산업 영향

KITA(2020. 9. 21), “중국, ‘신뢰할 수 없는 기업 명단’ 관한 규정 발표”. 한국무역협회.

_____ (2023), 미국과 EU의 반도체 산업 육성 전략과 시사점

KOTRA(2022), 美 반도체 설계의 미래, 전자설계자동화(EDA) 시장

_____ (2003a), 유럽반도체법(European Chips Act) 관련 입법 동향

_____ (2003b), 일본의 신 반도체 산업 전략과 글로벌 공급망 구축」 재구성

KISTEP(2023), 2023 인공지능 반도체

KIEP(2023), 미국 반도체 수출통제 확대조치의 영향과 시사점
KITA(2023), 미국과 EU의 반도체 산업 육성 전략과 시사점
한국수출입은행(2023), 미중 반도체 전쟁에 따른 산업재편 및 영향

[해외 문헌]

Abirami P. et. al.(2023) "Scalable End-to-End Enterprise AI on 4th Gen Intel(R) Xeon(R) Scalable Processors," whitepaper.

Alok, G.(2020), Architecture apocalypse dream architecture for deep learning inference and compute-versal ai core. Embedded World.

Elster, Anne C., and Tor A. Haugdahl(2022), "Nvidia hopper gpu and grace cpu highlights." Computing in Science & Engineering 24.2: 95-100.

Foley, Denis, et al(2011), "AMD'S "LLANO" Fusion APU," 2011 IEEE Hot Chips 23 Symposium(HCS), IEEE.

Gartner(2023. 4). "Market Share: Semiconductor Foundry, Worldwide, 2022"
_____(2023. 12a), "Semiconductor Forecast Database, Worldwide, 4Q23 Update"
_____(2023. 12b), "Market Share Analysis: Semiconductors, Worldwide, 2023 (Preliminary)".
_____(2023. 12c), "Forecast: AI Semiconductors, Worldwide, 2021~2027, 4Q23 Update".
_____(2024. 1a), "Forecast Analysis: Semiconductors and Electronics, Worldwide".
_____(2024. 1b) "Forecast: Semiconductor Foundry Revenue, Supply and Demand, Worldwide, 4Q23 Update".

Groq(2023). Groq-Product-Z_Fold-V4_Dec22-Letter.

habana(2022. 6). HABANA® GAUDI®2 WHITE PAPER.

Qualcomm(2023). The future of AI is hybrid.

IPnest(2023). Design IP revenues.

Kahng, A. B., Lienig, J., Markov, I. L., & Hu, J. (2011). VLSI physical design: from graph partitioning to timing closure (Vol. 312). Netherlands: Springer.

Kif Leswing(2023), "Intel unveils new AI chip to compete with Nvidia and AMD", CNBC, <https://www.cnbc.com/2023/12/14/intel-unveils-gaudi3-ai-chip-to-compete-with-nvidia-and-amd.html>

Mahajan, Ravi, et al(2016). "Embedded multi-die interconnect bridge(EMIB)--a high density, high bandwidth packaging interconnect." 2016 IEEE 66th Electronic Components and Technology Conference(ECTC). IEEE.

Modha, Dharmendra S., et al.(2023). "Neural inference at the frontier of energy, space, and time." Science 382.6668: 329-335.

Nellis, S.(2021), "AI chip startup Cerebras Systems raises \$250 million in funding." Reuters.

Sambanova Systems(2021), "Accelerated computing with a reconfigurable dataflowarchitecture," whitepaper, <https://sambanova.ai/>, April 2021.

SIA(2021), Strengthening the Global Semiconductor Value Chain in an uncertain era.

Subramon, Mahesh, David Kramer, and Indrani Paul(2023), "AMD Ryzen™ 7040 Series: Technology Overview." 2023 IEEE Hot Chips 35 Symposium(HCS). IEEE Computer Society.

Statista(2023), "Most funded artificial intelligence(AI) chip startup companies worldwide 2021."

TrendForce(2021), Revenue of Top 10 OSAT Companies for 2Q21 Reaches US\$7.88 Billion Due to Strong Demand and Increased Package/Test Prices.

Wei, Ying, et al(2023), "9.3 NVLink-C2C: A Coherent Off Package Chip-to-Chip Interconnect with 40Gbps/pin Single-ended Signaling." 2023 IEEE International Solid-State Circuits Conference(ISSCC). IEEE.

Zhao, W. X., et. al.(2023), A survey of large language models. arXiv preprint arXiv:2303.18223.

[URL]

Amazon 웹사이트, <https://docs.aws.amazon.com/dlami/latest/devguide/gpu.html>.

AMD 웹사이트, <https://www.amd.com/ko/technologies/xdna.html#xdna2>.

AMD웹페이지, <https://www.xilinx.com/products/boards-and-kits/alveo/u280.html>

ascii 웹페이지, <https://ascii.jp/elem/000/004/143/4143496/>

GoogleCloud(2023. 9. 1). “How to scale AI training to up to tens of thousands of Cloud TPU chips with Multislice”,

<https://cloud.google.com/blog/products/compute/using-cloud-tpu-multislice-to-scale-ai-workloads?hl=en>.

GraphCore웹페이지,

<https://www.graphcore.ai/bow-processors> & <https://www.graphcore.ai/products/bow-2000>

GraphCore웹페이지,

<https://www.graphcore.ai/products/ipu> & <https://www.graphcore.ai/bow-processors>.

Intel, “4th Gen Intel Xeon Sprints into the Market,”

<https://www.intel.com/content/www/us/en/newsroom/news/4th-gen-intel-xeon-sprints-into-market.html>.

Intel 웹페이지,

<https://www.intel.com/content/www/us/en/newsroom/resources/press-kit-4th-gen-intel-xeon-scalable-processors.html#gs.7wqy8q>.

Intel GAUDI, <https://habana.ai/>.

NVIDIA, “NVIDIA DGX GH200,”

<https://resources.nvidia.com/en-us-dgx-gh200/nvidia-dgx-gh200-datasheet-web-us>.

NVIDIA 웹페이지(NVIDIA Grace Hopper Superchip Data Sheet),

<https://resources.nvidia.com/en-us-grace-cpu/grace-hopper-superchip>.

NVIDIA 웹페이지, <https://www.nvidia.com/ko-kr/data-center/h100/>

Reuters(2021. 11. 11). “AI chip startup Cerebras Systems raises \$250 million in funding”

<https://www.reuters.com/technology/ai-chip-startup-cerebras-systems-raises-250-million-funding-2021-11-10/>.

Visual Capitalist, “Nvidia vs. AMD vs. Intel: Comparing AI Chip Sales,”

Statista(2024). “Accelerated processing unit (APU) market revenue worldwide from 2017 to 2025”, <https://www.statista.com/statistics/1131401/global-ap-market-revenue/>

<https://www.visualcapitalist.com/nvidia-vs-amd-vs-intel-comparing-ai-chip-sales/>.

Tenstorrent 웹사이트, <https://tenstorrent.com/cards/>

STH(2023. 11. 14). "Google Brings TPU v5e AI Board to SC23",
<https://www.servethehome.com/google-brings-tpu-v5e-ai-board-to-sc23/>

STH(2023. 12. 6), "AMD Instinct MI300X GPU and MI300A APUs Launched for AI Era",
<https://www.servethehome.com/amd-instinct-mi300x-gpu-and-mi300a-apus-launched-for-ai-era/6/>.

Tenstorrent, <https://tenstorrent.com/cards/#grayskull>.

TSMC, https://www.tsmc.com/english/dedicatedFoundry/technology/platform_HPC_tech_WLSI.

TSMC, <https://www.tsmc.com/english/dedicatedFoundry/oip/value-chain-alliance>.

SAMSUNG, <https://semiconductor.samsung.com/kr/foundry/safe/design-service>.

Visualcapitalist(2023. 8. 25.), "Visual Capitalist, "Nvidia vs. AMD vs. Intel: Comparing AI Chip Sales," <https://www.visualcapitalist.com/nvidia-vs-amd-vs-intel-comparing-ai-chip-sales/>

wccftech(2023. 12. 18), "Intel Gaudi 3 AI Accelerator Reportedly Built On TSMC 5nm Node, Faster Than NVIDIA H100",
<https://wccftech.com/intel-gaudi-3-ai-accelerator-tsmc-5nm-node-faster-than-nvidia-h100/>.

ZDNET Korea(2024. 2. 7.), "토종 AI 반도체 3사 옥석 가려야..."상용화 점검해야 할 때",
<https://zdnet.co.kr/view/?no=20240207161531>.

● 저 자 소 개 ●

윤 성 욱

- KAIST 경영공학 박사
- 현 정보통신정책연구원 연구위원

오 정 숙

- 고려대학교 경영학 석사
- 현 정보통신정책연구원 부연구위원

김 민 식

- 고려대학교 이학 박사
- 현 정보통신정책연구원 부연구위원

방송통신정책연구 RS-2023-00260453

AI반도체 글로벌 첨단 기술·산업 동향 조사 및
대응방향 연구

(A Study on Global Technology and Industry
Trends and Directions for Responses in the Field
of Advanced AI Semiconductors)

2024년 2월 일 인쇄

2024년 2월 일 발행

발행인 과학기술정보통신부 장관

발행처 과학기술정보통신부

세종특별자치시 갈매로 477 정부세종청사

Homepage: www.msit.go.kr

인 쇄 인 성 문 화